ingenieur
wissenschaften
htw saar

Hochschule für
Technik und Wirtschaft
des Saarlandes
University of
Applied Sciences

Bachelor-Thesis

zur Erlangung des akademischen Grades
Bachelor of Science (B. Sc.)
an der Hochschule für Technik und Wirtschaft des Saarlandes
im Studiengang Praktische Informatik
der Fakultät für Ingenieurwissenschaften

Evaluierung lokaler KI-Modelle auf Android für BCI-Anwendungen

vorgelegt von
Ahmed Chaabo

betreut und begutachtet von
Prof. Dr. rer. nat. Dr. rer. med. habil. Daniel J. Strauss
Tobias Grün M.Sc.

Saarbrücken, Tag. Monat Jahr

Selbständigkeitserklärung

Ich versichere, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ich erkläre hiermit weiterhin, dass die vorgelegte Arbeit zuvor weder von mir noch von einer anderen Person an dieser oder einer anderen Hochschule eingereicht wurde.

Darüber hinaus ist mir bekannt, dass die Unrichtigkeit dieser Erklärung eine Benotung der Arbeit mit der Note „nicht ausreichend“ zur Folge hat und einen Ausschluss von der Erbringung weiterer Prüfungsleistungen zur Folge haben kann.

Saarbrücken, Tag. Monat Jahr

Ahmed Chaabo

KI-Verzeichnis

Im Folgenden werden die im Rahmen dieser Arbeit eingesetzten KI-basierten Hilfsmittel sowie Art und Umfang ihrer Nutzung offengelegt. Die inhaltliche Verantwortung für die gesamte Arbeit liegt beim Verfasser. KI-Werkzeuge wurden ausschließlich unterstützend eingesetzt; alle damit erzeugten oder überarbeiteten Inhalte wurden geprüft, angepasst und verantwortet.

Nr.	KI-Werkzeug	Art der Nutzung	Betroffene Abschnitte
1	Claude (Anthropic)	Rechtschreib- und Grammatikkorrektur sowie verbesserte Formulierungsvorschläge.	Gesamte Arbeit
2	Claude (Anthropic)	Unterstützung bei der Konzeption von Entwürfen für Kapitel.	Gesamte Arbeit
3	Claude (Anthropic)	Unterstützung bei der Konzeption oder Erstellung von Entwürfen für Abbildungen, Listings, Tabellen oder Formeln.	Abb. 4.x, 5.x, 6.x, A.x; Tab. 6.x, B.1; Lis. 5.x; For. 2.2, 4.x
4	Claude (Anthropic)	Unterstützung bei Programmcode durch Vorschläge (u. a. Pseudocode), Korrekturen und Optimierungen sowie Erstellung der Kommentare und Aufräumen des Quellcodes.	Gekennzeichnete Stellen; Kommentare und Aufräumen im gesamten Quellcode der Erweiterung
5	DeepL (DeepL SE)	Übersetzung von Textpassagen aus dem Englischen ins Deutsche.	Alle englischsprachigen Quellen (Literaturverzeichnis)
6	Perplexity (Perplexity AI) / NotebookLM (Google)	Quellenrecherche (Perplexity) und Auffinden von Textstellen in den Quellen (NotebookLM) als erster Schritt, anschließend vom Verfasser in der Originalquelle geprüft.	Literaturverzeichnis; Quellenbelege

Zusammenfassung

Diese Bachelorarbeit behandelt die Eignung lokaler Sprachmodelle für mobile Brain-Computer-Interface-Anwendungen (BCI). Untersucht werden drei lokal auf einem Android-Gerät ausgeführte Sprachmodelle, die in drei festgelegten Anwendungsszenarien anhand von Latenz, Ressourcenverbrauch, Stabilität und Ausgabequalität verglichen werden. In der bestehenden Applikation wurden Daten der Elektroenzephalographie (EEG) von einem tragbaren mobilen BCI-Gerät (Unicorn Hybrid Black) erfasst und anschließend visualisiert und gespeichert. Solche Signale sind komplex und erfordern Fachwissen, um sie einwandfrei deuten zu können. Speziell im Lehrkontext, in dem das Gerät eingesetzt wird, fehlt diese Erfahrung häufig. Lokale Sprachmodelle könnten hier unterstützen, indem sie die aufbereiteten Messwerte in verständliche Sprache überführen. Problematisch ist, dass solche Modelle auf ressourcenbeschränkten Geräten laufen, sodass ihre Tauglichkeit offen bleibt. Daher ergibt sich die Forschungsfrage, inwieweit sich lokal auf Android-Geräten ausgeführte Sprachmodelle für die Verarbeitung von EEG-Daten im Rahmen mobiler Brain-Computer-Interface-Anwendungen eignen.

Aus diesem Grund wurde die Anwendung um drei Kernkomponenten erweitert. Darunter fallen die Merkmalsextraktion, bei der die rohen EEG-Daten in eine für das Modell verständliche Form gebracht werden, die Anbindung lokaler Sprachmodelle (Gemma 3 1B, Gemma 2 2B, Qwen 2.5 1.5B) und die Implementierung einer Benutzeroberfläche. Zusätzlich wurde ein Benchmark implementiert, der für das automatisierte Messen der Latenz, des Ressourcenverbrauchs und der Stabilität der Modelle zuständig ist. Die bestehende Anwendung wird dabei selbst nicht bewertet. Sie dient als Messumgebung für den Vergleich der Modelle.

Die Ergebnisse zeigen, dass die Verarbeitung der EEG-Daten durch alle drei getesteten Modelle stabil ist. Die Modellgröße bestimmt zwar die Zeit bis zum ersten Token (TTFT), Geschwindigkeit und Speicher, aber nicht automatisch Qualität oder Akkuverbrauch. Keines der getesteten Modelle ist gleichzeitig in allen Bereichen überlegen. Die passende Modellwahl hängt davon ab, welcher Einsatzzweck verfolgt wird. Während Qwen 2.5 1.5B nicht überzeugen kann, schneiden die beiden Gemma-Modelle deutlich besser ab, wobei der Prompt an Gemma 2 2B ausgerichtet wurde und Qwen dadurch vermutlich stärker im Nachteil ist, da es auf einer anderen Architektur beruht. Für schnelle Antworten auf ressourcenärmeren Geräten ist Gemma 3 1B die beste Wahl. Wenn Zeit keine Rolle spielt und die Antwort ohnehin im Hintergrund erzeugt wird, liefert Gemma 2 2B die höhere Ausgabequalität. Diese Ergebnisse gelten für den in dieser Arbeit untersuchten Rahmen, also für das verwendete Testgerät, die beschriebene Prompt-Struktur, die gewählte Konfiguration und die drei betrachteten Anwendungsszenarien.

Die Modelle eignen sich unter den untersuchten Bedingungen für die Verarbeitung von EEG-Daten in mobilen BCI-Anwendungen. Sie übernehmen dabei eine unterstützende Funktion, während die Deutung beim Nutzer bleibt, und lassen Raum für weiterführende Untersuchungen.

If the human brain were so simple that we could understand it,
we would be so simple that we couldn't.

— Emerson M. Pugh

Danksagung

Ich bedanke mich bei meinen Betreuern, Prof. Dr. rer. nat. Dr. rer. med. habil. Daniel J. Strauss und Tobias Grün M.Sc., für die Unterstützung und die Möglichkeit, diese Arbeit im Rahmen des Projekts UnicornART zu schreiben.

Zudem gilt mein besonderer Dank meiner Familie und meinen Freunden, die mich während der Zeit im Studium motiviert und mir den Rücken gestärkt haben.

Inhaltsverzeichnis

1 Einleitung **1**
- 1.1 Motivation . . . 1
- 1.2 Zielsetzung . . . 2
- 1.3 Aufbau der Arbeit . . . 2

2 Grundlagen **3**
- 2.1 Elektroenzephalographie (EEG) . . . 3
- 2.2 Frequenzbänder . . . 3
- 2.3 Frequenzanalyse . . . 4
  - 2.3.1 Fourier-Transformation . . . 4
  - 2.3.2 Fensterung und spektrale Leckage . . . 5
  - 2.3.3 Welch-Methode . . . 5
- 2.4 Lokale Sprachmodelle auf mobilen Geräten . . . 5
  - 2.4.1 Large Language Models . . . 6
  - 2.4.2 On-Device-Inferenz und Quantisierung . . . 6
  - 2.4.3 Modell und Laufzeitumgebung . . . 7
  - 2.4.4 Systemintegrierte und frei deploybare Modelle . . . 7
- 2.5 Brain-Computer-Interface (BCI) . . . 8

3 Stand der Technik und Ausgangslage **9**
- 3.1 On-Device-Inferenz-Lösungen . . . 9
  - 3.1.1 Systemintegrierte Lösung . . . 9
  - 3.1.2 Frei deploybare Lösung . . . 9
- 3.2 Die Gemma-Modellfamilie . . . 10
- 3.3 Die Qwen-Modellfamilie . . . 11
- 3.4 Bestehende Anwendung . . . 11
  - 3.4.1 Unicorn Hybrid Black . . . 11
  - 3.4.2 Datenübertragung und Anbindung . . . 12
  - 3.4.3 Funktionsumfang der Anwendung . . . 12
  - 3.4.4 Beitrag dieser Arbeit . . . 12

4 Methodik **15**
- 4.1 Merkmalsextraktion . . . 15
  - 4.1.1 Segmentierung . . . 16
  - 4.1.2 Spektrale Merkmale . . . 17
  - 4.1.3 Zeitstatistische Merkmale . . . 18
  - 4.1.4 Aufbereitung für das Sprachmodell . . . 18
- 4.2 Modellauswahl . . . 19
- 4.3 Anwendungsszenarien . . . 20
- 4.4 Messprotokoll (Benchmark) . . . 20
  - 4.4.1 Metriken . . . 21
  - 4.4.2 Messbedingungen . . . 22

5 Implementierung **25**
5.1 Architektur . . . 25
5.2 Implementierung der Merkmalsextraktion . . . 27
5.2.1 Vorbereitung . . . 27
5.2.2 Validierung . . . 28
5.2.3 Segmentierung . . . 28
5.2.4 Spektrale Merkmale (Welch-Methode) . . . 29
5.2.5 Zuordnung zu den Frequenzbändern . . . 31
5.2.6 Zeitstatistische Merkmale . . . 31
5.2.7 Ergebnis . . . 32
5.2.8 Aufbereitung für das Sprachmodell . . . 32
5.3 Integration des Sprachmodells . . . 34
5.3.1 Modellauswahl und Pfade . . . 34
5.3.2 Laden und Konfiguration . . . 34
5.3.3 Streamende Ausgabe . . . 35
5.3.4 Zählen der Token . . . 36
5.3.5 Freigabe . . . 36
5.4 Prompt-Design und iterative Optimierung . . . 36
5.5 Benutzeroberfläche . . . 38
5.5.1 Analyse-Dialog . . . 39
5.5.2 Ergebnis-Ansicht . . . 39
5.5.3 Benchmark-Dialog . . . 42
5.6 Benchmark . . . 43
5.6.1 Ablauf . . . 44
5.6.2 Messung je Konfiguration . . . 44
5.6.3 Erfassung der Ressourcen . . . 45
5.6.4 Protokollierung . . . 46

6 Evaluation **47**
6.1 Durchführung der Messungen . . . 47
6.2 Latenz . . . 47
6.3 Ressourcenverbrauch . . . 49
6.4 Stabilität . . . 50
6.5 Ausgabequalität . . . 50
6.6 Zusammenfassende Gegenüberstellung . . . 52

7 Diskussion **53**
7.1 Einordnung der Ergebnisse . . . 53
7.2 Einschränkungen . . . 55
7.3 Handlungsempfehlungen . . . 56
7.3.1 Allgemeine Empfehlungen . . . 56
7.3.2 Modellempfehlung . . . 56

8 Fazit und Ausblick **59**
8.1 Fazit . . . 59
8.2 Ausblick . . . 60

Literatur **63**

Abbildungsverzeichnis **67**

Tabellenverzeichnis **67**

Listings **68**

Abkürzungsverzeichnis **69**

A Aufbereitete Feature-Texte der Evaluation **73**

B Rohdaten der Benchmark-Messungen **75**

1 Einleitung

Lokal ausgeführte Sprachmodelle lassen sich inzwischen mit Gehirn-Computer-Schnittstellen verbinden. Es entstehen neue Möglichkeiten durch die Kombination beider Technologien. So können lokale Sprachmodelle für die Verarbeitung von Elektroenzephalographie (EEG)-Daten auf einem mobilen Android-Gerät verwendet werden. Die vorliegende Arbeit untersucht, wie dieser Fall in der Praxis funktioniert. Dieses Kapitel gibt einen Überblick über die Motivation, Zielsetzung und den Aufbau der Arbeit.

1.1 Motivation

Ein EEG wird verwendet, um nicht-invasive Aufzeichnungen des Gehirns zu erstellen, und zwar mithilfe der elektrischen Aktivität [4]. Eine Gehirn-Computer-Schnittstelle, ein sogenanntes Brain-Computer-Interface (BCI), zielt anhand dieser Grundlage darauf ab, kognitive Zustände in Echtzeit zu identifizieren, um unter anderem eine Steuerung und Kommunikation ohne den Einsatz von Muskeln zu ermöglichen [4, 43]. Vor allem Menschen, die körperlich stark beeinträchtigt sind, können von BCI-Systemen profitieren. Gelähmten Personen ist es unter anderem so möglich, BCI-basierte Buchstabiersysteme zu nutzen, die ein wichtiger Kommunikationskanal sind [4].

Übliche EEG-Laborhardware, wie sie stationär verwendet wird, ist groß und unpraktisch für den Gebrauch außerhalb einer Laborumgebung [4]. Kabellose, am Kopf getragene EEG-Geräte wie das Unicorn Hybrid Black ermöglichen dagegen Messungen außerhalb des Labors [4, 9]. Dennoch ist das Deuten der aufgezeichneten Signale komplex [4]. Deutlich wird es im Lehrkontext, bei dem das Unicorn Hybrid Black zum Einsatz kommt, zum Beispiel in Vorlesungen zu Gehirn-Computer-Schnittstellen. Dort werden Messungen durchgeführt, die jedoch trotz des Signalverlaufs schwer zu verstehen sind und nur mit entsprechender Erfahrung eingeordnet werden können.

Große Sprachmodelle, sogenannte Large Language Models (LLMs), haben die Verarbeitung natürlicher Sprache stark geprägt [44]. Durch die Kombination lokaler Sprachmodelle und der aufbereiteten EEG-Daten ist es möglich, verständliche Beschreibungen zu erzeugen. Ein solches Modell soll dabei eine unterstützende Funktion übernehmen.

Für die vorliegende Arbeit ist die lokale Ausführung eine Voraussetzung. In diesem Umfeld gibt es keine Garantie für eine Internetverbindung oder einen Zugang zu einem Cloud-Dienst. Hinzu kommt, dass die EEG-Aufzeichnungen der Nutzer das Gerät nicht verlassen sollen. Eine lokale Verarbeitung kommt ohne Netzanbindung aus und hält die Daten auf dem Gerät [44].

Der Betrieb solcher Modelle auf Mobilgeräten stößt jedoch an Grenzen bei Rechenleistung und Arbeitsspeicher [44]. Die Motivation dieser Arbeit liegt damit darin, eine Lücke zu füllen, die zwischen dem mobilen Aufzeichnen und dem Verständnis der Daten im Lehrkontext entsteht. Genau da sollen lokal ausgeführte Sprachmodelle ansetzen, um

unterstützend zu wirken. Inwieweit sich lokale Sprachmodelle unter diesen ressourcenbeschränkten Bedingungen tatsächlich für die Verarbeitung von EEG-Daten eignen, ist bislang offen.

1.2 Zielsetzung

Das Ziel dieser Arbeit ist die Untersuchung, ob und inwieweit sich lokal auf Android-Geräten ausgeführte Sprachmodelle für die Verarbeitung von EEG-Daten im Rahmen mobiler Brain-Computer-Interface-Anwendungen eignen. Damit stellt sich folgende Forschungsfrage:

> *Inwieweit eignen sich lokal auf Android-Geräten ausgeführte Sprachmodelle für die Verarbeitung von EEG-Daten im Rahmen mobiler Brain-Computer-Interface-Anwendungen?*

Um diese Frage zu beantworten, wird eine bestehende Android-EEG-Anwendung um lokale Sprachmodelle erweitert, die dann aufbereitete EEG-Merkmale in verständliche, textuelle Beschreibungen übersetzen. Dabei werden drei verschiedene Anwendungsszenarien sowie drei verschiedene Sprachmodelle mit unterschiedlicher Größe und unterschiedlichem Hersteller betrachtet. So sollte erkennbar sein, wie viel Einfluss die verschiedenen Modellgrößen sowie Hersteller haben.

Die Eignung wird anhand verschiedener Kriterien bewertet. Dazu zählen Latenz, Ressourcenverbrauch, Stabilität sowie die Qualität der ausgegebenen Texte. Darüber hinaus werden praktische Einschränkungen wie die Geräteabhängigkeit systemintegrierter Modelle dokumentiert. Das Ergebnis dieser Arbeit liefert einen systematischen Vergleich, aus dem sich Handlungsempfehlungen für den Einsatz lokaler Sprachmodelle in mobilen BCI-Anwendungen ableiten lassen.

Der Fokus liegt dabei nicht auf dem Training der Modelle, sondern auf ihrer Integration, Leistungsfähigkeit und ihren Grenzen im mobilen Einsatz.

1.3 Aufbau der Arbeit

Es liegen acht Kapitel vor. Nach dieser Einleitung vermittelt Kapitel 2 das Wissen, das für das Verständnis der Arbeit erforderlich ist. Kapitel 3 beschreibt den derzeitigen Stand der Technik sowie die Ausgangslage, auf der die Arbeit aufbaut. Anschließend erläutert Kapitel 4 das Vorgehen, mit dem die Forschungsfrage beantwortet werden soll, und Kapitel 5 zeigt, wie die Anwendung konkret umgesetzt wurde. Die Ergebnisse der Evaluation folgen in Kapitel 6 und werden in Kapitel 7 zusammen mit den praktischen Einschränkungen diskutiert. Kapitel 8 schließt die Arbeit mit einem Fazit und einem Ausblick auf mögliche Weiterentwicklungen ab.

2 Grundlagen

Im Weiteren wird alles benötigte Wissen vermittelt, um dieser Arbeit folgen zu können. Dabei werden folgende zentrale Konzepte vorgestellt, auf denen die weiteren Kapitel aufbauen. Dazu zählen die Elektroenzephalographie mit ihren Frequenzbändern, die Verfahren zur Frequenzanalyse, die Ausführung lokaler Sprachmodelle auf mobilen Geräten sowie die Gehirn-Computer-Schnittstelle als Anwendungsrahmen.

2.1 Elektroenzephalographie (EEG)

Das EEG ist ein Verfahren, das die elektrische Aktivität des menschlichen Gehirns aufzeichnet. Die Signale sind Spannungsschwankungen im Mikrovoltbereich, die durch die synchrone Aktivität von Neuronen entstehen [4]. Die Messung erfolgt über Elektroden, die auf der Kopfhaut platziert werden und die Potenzialdifferenzen zwischen verschiedenen Punkten erfassen [1].

EEG-Signale haben sehr geringe Amplitudenwerte, die im Mikrovoltbereich liegen. Deswegen müssen sie beim Erfassen verstärkt werden [1, 4]. Das Frequenzspektrum liegt meistens in einem Bereich, der sich von 0,1 Hz bis 100 Hz erstreckt [1]. Ein EEG-Signal ist in seiner Rohform stark verrauscht und hat dadurch ein geringes Signal-Rausch-Verhältnis (SNR) [4]. Die erwarteten neuronalen Aktivitäten sind schwach und werden deswegen leicht von amplitudenstarken physiologischen Artefakten wie Muskel- oder Augenbewegungen sowie von technischen Störeinflüssen überlagert. Das kann zu Verzerrungen des originalen Signals führen [1].

2.2 Frequenzbänder

Frequenzbänder sind Frequenzbereiche, in welche die Gehirnwellen nach ihrer Frequenz eingeteilt werden. Die elektrischen Schwingungen werden in Hertz (Hz) gemessen, also in Ausschlägen pro Sekunde [1]. Die Auswertung der jeweiligen Frequenzbänder wird zur Beurteilung der Gehirnaktivitäten verwendet [1].

Das EEG-Spektrum wird in fünf Frequenzbänder unterteilt [1]. Die Bandgrenzen werden nicht einheitlich gezogen. Amer und Belhaouari geben für Alpha 8 bis 12 Hz an [1], das Glossar der International Federation of Clinical Neurophysiology dagegen 8 bis 13 Hz [25, 26]. Für diese Arbeit werden durchgehend die Grenzen des Glossars verwendet.

Tabelle 2.1 fasst die fünf Bänder mit ihren Frequenzbereichen und den zugeordneten Zuständen zusammen.

Tabelle 2.1: Die fünf EEG-Frequenzbänder mit ihren Frequenzbereichen und zugeordneten Zuständen. Die Bereiche folgen dem Glossar der International Federation of Clinical Neurophysiology [25, 26], die Zustände [1]. Auf dieser Einteilung beruht die spätere Zuordnung der Leistungswerte.

Band	**Frequenzbereich**	**Assoziierter Zustand**
Delta	0,5–4 Hz	Tiefer, sehr entspannter und erholsamer Zustand
Theta	4–8 Hz	Leichte Schlafphase oder Meditation; Zustand zwischen Schlaf und Wachsein
Alpha	8–13 Hz	Ruhiger, stressfreier Zustand; in der Großhirnrinde deutlich nachweisbar, am ausgeprägtesten bei geschlossenen Augen
Beta	13–30 Hz	Aktives Denken und Problemlösen
Gamma	ab 30 Hz	Konzentration und Multitasking

2.3 Frequenzanalyse

Wichtig ist es zu bestimmen, welche Frequenzbänder in EEG-Signalen wie stark vertreten sind. Im Folgenden wird beschrieben, welche Verfahren dafür nötig sind.

2.3.1 Fourier-Transformation

Die Fast Fourier Transform (FFT) ist ein mathematisches Verfahren, das komplexe Signale in ihre sinusförmigen Bestandteile zerlegt und sie vom Zeitbereich in den Frequenzbereich überführt (Abbildung 2.1) [1]. Dies wird verwendet, um bei der Analyse der Gehirnströme die spektralen Eigenschaften von Signalen zu untersuchen und Frequenzspitzen (Peaks) zu berechnen [1].

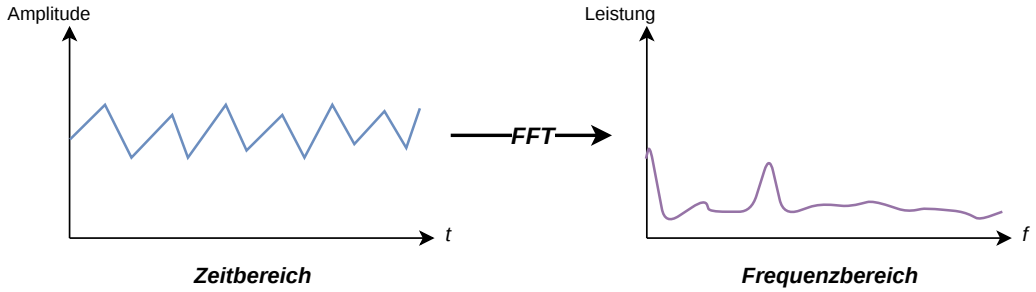


Abbildung 2.1: Überführung eines Signals vom Zeit- in den Frequenzbereich mittels FFT. Der Signalverlauf wird dabei in seine Frequenzanteile zerlegt (erstellt mit draw.io).

Das Ergebnis der FFT ist je Frequenz-Bin eine komplexe Zahl, bestehend aus einem Real- und einem Imaginärteil. Der Realteil beschreibt die Amplitude des Kosinus-Anteils und der Imaginärteil die Amplitude des Sinus-Anteils der jeweiligen Frequenz. Indem man,

wie in der folgenden Gleichung, die Summe der quadrierten Real- und Imaginärteile berechnet, erhält man die Leistung eines Bins [39].

$$P = \mathrm{Re}^2 + \mathrm{Im}^2 \tag{2.1}$$

Der Zusatz „schnell“ bezieht sich auf den Rechenaufwand. Die FFT zerlegt das Signal dafür wiederholt in zwei Hälften. Bei 256 Werten sind das acht Stufen, auf denen jeweils jeder Wert einmal verarbeitet wird. Der Aufwand liegt damit in der Größenordnung von $N \log_2 N$. Die direkte Berechnung müsste dagegen für jeden der N Ausgabewerte alle N Eingabewerte durchlaufen und wächst proportional zu N^2 [39]. Damit sich die Zerlegung vollständig durchführen lässt, wird die Fenstergröße N in dieser Arbeit als Zweierpotenz gewählt.
Ein Merkmal der FFT ist die Frequenzauflösung Δf, die angibt, wie genau die einzelnen Frequenzstützstellen unterteilt werden können. Die Auflösung ergibt sich aus der Abtastrate f_s und der Anzahl der Werte N pro Fenster [28]:

$$\Delta f = \frac{f_s}{N}. \tag{2.2}$$

Je größer das Fenster N gewählt wird, desto kleiner wird Δf und desto feiner ist folglich die Auflösung [24]. Daraus lässt sich ableiten, dass jeder Bin für eine bestimmte Frequenz steht.

2.3.2 Fensterung und spektrale Leckage

Die Fensterung ist ein Verfahren, um Signale zu analysieren, deren Frequenzen sich im Laufe der Zeit verändern [1]. Die Auswertung geschieht in zeitlich verschiebbaren Fenstern statt im gesamten Signal auf einmal [1]. Wenn ein Signal für die Datenverarbeitung abgeschnitten wird, entsteht eine spektrale Leckage. Dies geschieht häufig dann, wenn die Länge des erfassten Signalabschnitts kein exaktes Vielfaches der eigentlichen Signalperiode ist. Durch dieses harte Abschneiden wird die Energie des Signals im Frequenzspektrum verfälscht und auf einen breiteren Frequenzbereich verteilt, was zu Störfrequenzen führt. Um diese Leckage auszugleichen, nutzt man die Fensterfunktion, bei der man die Stärke des Signals an den Rändern des Fensters sanft abschwächt [24].

2.3.3 Welch-Methode

Um Frequenzspektren robuster zu schätzen und Rauschen zu reduzieren, wird die Welch-Methode verwendet [24]. Es ist ein Rechenverfahren, das in drei Schritten vorgeht:

1. Das ursprüngliche Signal wird in mehrere kürzere Fenster unterteilt, die sich teilweise überlappen dürfen [24].
2. Auf jedes Fenster wird eine Fensterfunktion angewendet, um dann für jedes Fenster einzeln das Spektrum zu berechnen [24].
3. Ganz am Ende werden die Einzelspektren zu einem Durchschnittswert gemittelt [24].

2.4 Lokale Sprachmodelle auf mobilen Geräten

Im folgenden Abschnitt werden die relevanten Grundlagen dargestellt, die für das Ausführen von Sprachmodellen auf mobilen Geräten notwendig sind. Zunächst werden große Sprachmodelle, deren Vor- und Nachteile sowie die Quantisierung vorgestellt.

2.4.1 Large Language Models

LLMs haben die Verarbeitung natürlicher Sprache (Natural Language Processing) stark verändert. Die Modelle basieren auf der sogenannten Transformer-Architektur [44]. Sie beinhalten den Self-Attention-Mechanismus (Selbstaufmerksamkeit), der globale Abhängigkeiten zwischen Ein- und Ausgabesequenzen modelliert [40]. Die hohe Leistungsfähigkeit der Modelle wird durch die gelernten Werte von Milliarden von Parametern erreicht. Sie sind stark im Sprachverstehen, in der Textsynthese, im logischen Schlussfolgern und in der generativen Texterstellung [44]. Dies stellt Herausforderungen dar, unter anderem, wie man sie auf ressourcenbeschränkten Endgeräten wie Smartphones (sogenannten Edge-Geräten) zum Laufen bringen möchte. So benötigen LLMs viel Speicherplatz und Rechenleistung [44].

In der maschinellen Sprachverarbeitung werden Texte in Token zerlegt, die als kleinste Informationseinheiten dienen. So wird im Fachartikel [22] gesagt: „Ein Token kann für ein einzelnes Zeichen, einen Teil eines Wortes (z. B. ein Suffix oder Präfix), ein ganzes Wort oder sogar eine kurze, aus mehreren Wörtern bestehende Phrase stehen.“ Damit die benötigte Rechenleistung reduziert wird, enthält jedes Token eine eindeutige numerische Identifikationsnummer (ID), anhand derer das Modell die Sprache lernt und verarbeitet [22].

Das Kontextfenster ist die maximale Anzahl an Token, die das Modell gleichzeitig verarbeiten kann [22]. Es ist sozusagen das Arbeitsgedächtnis des Modells. Sollte das Kontextfenster überschritten werden, werden die älteren Informationen gekürzt oder zusammengefasst, damit das Modell weiterhin im selben Kontext arbeiten kann [22]. Die Kontextgröße ist die maximale Summe der Eingabe- und Ausgabe-Token, die ein Modell verarbeiten kann [17].

2.4.2 On-Device-Inferenz und Quantisierung

On-Device-Inferenz beschreibt die lokale Ausführung von KI-Modellen direkt auf den Endgeräten (beispielsweise einem Smartphone), anstatt die Daten zur Verarbeitung an einen externen Cloud-Server zu senden [44]. Hierbei gibt es wesentliche Vorteile. Zum einen verlassen die Daten das Gerät nicht, wodurch die Privatsphäre geschützt wird [44]. Hinzu kommt, dass lokale Ausführungen offline laufen können und daher keine Internetverbindung benötigen [44]. So erspart man sich zusätzlich Kosten, die durch Cloud-Dienste entstehen würden [44].

Jedoch gibt es neben den Vorteilen auch Nachteile. Es gibt Herausforderungen, die man zu bewältigen hat. Ein großer Aspekt ist dabei die begrenzte Speicher- und Rechenleistung des Endgeräts, da sie bestimmt, ob ein lokales Modell überhaupt ausgeführt werden kann. LLMs sind sehr große Sprachmodelle, die wegen ihrer hohen Anzahl an Parametern ausreichend großen Arbeitsspeicher (RAM) und Rechenkapazität benötigen. Oft ist dies mehr, als herkömmliche Smartphones bieten, was im Extremfall zu einem Speicherüberlauf führt, im Englischen als memory overflow oder Out of Memory (OOM) bezeichnet [19, 44]. OOM beschreibt einen Zustand, in dem kein Arbeitsspeicher mehr für neue Objekte verfügbar ist [19].

Ein weiterer Punkt ist das Problem mit der Vielfalt der Geräte. Da es viele Variationen mit unterschiedlichen Prozessoren und Spezialchips gibt, ist die Programmierung einer einheitlichen Lösung, die auf allen Endgeräten funktioniert, herausfordernd [44].

Zusätzlich gibt es das Phänomen des katastrophalen Vergessens, bei dem ein Modell unweigerlich zuvor erlerntes Wissen vergisst, wenn es neue Informationen lernt [44].

Ein weiteres Problem ist das Thermal Throttling, also ein Schutzmechanismus mobiler Geräte, der automatisch bei Überhitzung die Rechenleistung drosselt und dadurch die Latenz der Modelle erhöhen kann [45].
In dieser Arbeit spielen nicht alle Punkte eine gleich große Rolle. Datenschutz und Offline-Fähigkeit sind hier keine offenen Fragen, sondern der Grund für die lokale Ausführung. Die Herausforderung liegt bei den übrigen Punkten: Speicher und Rechenleistung entscheiden darüber, ob, welches und wie ein Modell auf dem Testgerät läuft (Abschnitt 4.4.1), die Drosselung kann die gemessenen Latenzen beeinflussen [45] und die Gerätevielfalt kann die Übertragbarkeit begrenzen. Das katastrophale Vergessen spielt hierzu keine Rolle, da alle Modelle unverändert übernommen werden.

Damit diese Modelle auf Mobilgeräten laufen können, ist die sogenannte Quantisierung ein notwendiges Verfahren. Die Dateigröße des Modells wird reduziert, indem die Genauigkeit der gespeicherten Zahlenwerte künstlich verringert wird. Wechselt man beispielsweise von einer 32-Bit- auf eine 8-Bit-Speicherung, sinkt der Arbeitsspeicherbedarf und es kommt zu schnelleren Berechnungen auf dem Endgerät [44]. Dieser Gewinn an Speicher- und Recheneffizienz kann jedoch zu Leistungseinbußen und Genauigkeitsverlusten führen [44]. Sprachmodelle reagieren aufgrund ihrer Architektur empfindlich auf eine verringerte numerische Präzision [44].

2.4.3 Modell und Laufzeitumgebung

Der Unterschied zwischen einem Modell und einer Runtime (Laufzeitumgebung) lässt sich wie folgt beschreiben: Ein Modell ist die Basis, die durch das Training Fähigkeiten wie Textverständnis, logisches Schließen oder die Generierung von Inhalten erlernt hat [44], wohingegen die Runtime die Software ist, die das Modell auf dem Endgerät ausführt [17, 44]. Sie stellt die notwendigen Ressourcen und Schnittstellen bereit, um das Modell zu betreiben [44].

2.4.4 Systemintegrierte und frei deploybare Modelle

Grundsätzlich lassen sich zwei Kategorien lokaler Sprachmodelle unterscheiden. Zum einen gibt es systemintegrierte Modelle, die fest im Betriebssystem verankert sind. Ein Beispiel hierfür ist Gemini Nano, das über den Android-Systemdienst AICore ausgeführt und lokal verwaltet wird [15]. Entwickler müssen dafür keine eigene Runtime bereitstellen und greifen über standardisierte Programmierschnittstelles (APIs) auf das Modell zu [15]. Da das Betriebssystem die Verwaltung und Aktualisierung übernimmt, verringert sich der Speicher- und Ressourcenbedarf der einzelnen Applikation [15].

Zum anderen gibt es frei deploybare Modelle. Sie werden von Entwicklern gemeinsam mit einer passenden Runtime als Paket auf das Endgerät gebracht und in der Applikation ausgeführt [17, 21]. Dadurch sind sie unabhängiger von spezifischen Systemvorgaben oder vorinstallierten Systemdiensten und daher flexibler. Für die technische Umsetzung werden sogenannte „Task Bundles“ genutzt, also Dateiformate wie .task oder .litertlm [17]. Diese bündeln das eigentliche Modell mit den für die Textzerlegung nötigen Tokenizer-Parametern, um die Ende-zu-Ende-Verarbeitung zu ermöglichen [17].

2.5 Brain-Computer-Interface (BCI)

Ein BCI, zu Deutsch Gehirn-Computer-Schnittstelle, beschreibt eine Technologie, die eine Kommunikation zwischen Gehirn und Computer (externem Gerät) ermöglicht [4]. Häufig von einem EEG gemessen, werden mentale Zustände und Absichten in Echtzeit erkannt. Durch ein BCI kann die natürliche Ausgabe des Zentralnervensystems ersetzt, wiederhergestellt, verbessert, ergänzt oder optimiert werden [43]. Häufig geht es dabei um Steuerungsbefehle, die ohne den Einsatz von Muskeln auskommen [4].

Ein BCI-System erfasst die Gehirndaten und verarbeitet diese Signale. Häufig geschieht dies in einem geschlossenen System, in dem der Nutzer auf Basis der Klassifizierung eine unmittelbare Rückmeldung erhält [4].

Vor allem körperlich stark beeinträchtigte Menschen profitieren von BCI-Systemen. Zu den bekannten Beispielen zählen die folgenden [1, 4]. Spezielle Systeme ermöglichen es gelähmten Personen, mit der Umwelt zu kommunizieren. BCI-Systeme erlauben eine Steuerung von Prothesen, Rollstühlen oder dem Cursor eines Computerbildschirms rein mit Gedanken. Auch bei der Fehlerüberwachung können anhand der Gehirnaktivität die Absichten einer Notbremsung erkannt und ausgeführt werden, noch bevor das Bremspedal physisch betätigt wird.

Diese Arbeit setzt auf einem solchen EEG-basierten BCI auf und ergänzt es um ein lokales Sprachmodell, das die Messwerte in verständlichen Text überführt. Sie setzt erst nach der Aufnahme an und wertet bereits gespeicherte Sessions aus. Im folgenden Kapitel werden Modelle und Software-Frameworks vorgestellt, die für den mobilen Einsatz optimiert sind.

3 Stand der Technik und Ausgangslage

Während Kapitel 2 die allgemeinen Konzepte behandelt, werden in diesem Kapitel aktuell verfügbare Systeme betrachtet und ausgewählt, welche in dieser Arbeit verwendet werden. Zunächst werden die Lösungen für die Ausführung auf dem Endgerät gegenübergestellt, anschließend die verwendeten Sprachmodelle aus der Gemma-Familie sowie Qwen vorgestellt. Schließlich wird die bestehende Anwendung genauer erläutert und der Beitrag dieser Arbeit aufgezeigt.

3.1 On-Device-Inferenz-Lösungen

Um ein Sprachmodell lokal auf einem Mobilgerät auszuführen, wird eine Laufzeitumgebung benötigt. Dafür stehen unterschiedliche Lösungen zur Verfügung. Diese lassen sich, wie in Abschnitt 2.4.4 dargestellt, in systemintegrierte und frei deploybare Ansätze einteilen. Beide werden im Folgenden betrachtet.

3.1.1 Systemintegrierte Lösung

Das systemintegrierte Modell Gemini Nano ist stark an die Hardware gebunden, da AICore spezifische On-Device-Hardwarekomponenten nutzt, um die Inferenz zu beschleunigen [15]. Aus diesem Grund setzt Gemini Nano bestimmte von Google freigegebene Hardware voraus. Das für diese Arbeit verwendete Testgerät Samsung Galaxy S23 erfüllt diese Anforderungen nicht, sodass Gemini Nano nicht genutzt werden kann [20].

Die Möglichkeit einer virtuellen Testumgebung wie eines Android-Emulators ist ausgeschlossen, da die physische Präsenz der Gerätehardware benötigt wird [15, 44].

Aufgrund dieser Einschränkungen steht die systemintegrierte Lösung Gemini Nano für diese Arbeit nicht zur Verfügung. Deshalb wird im Folgenden die frei deploybare Lösung betrachtet, die auf dem Testgerät Samsung Galaxy S23 genutzt werden kann.

3.1.2 Frei deploybare Lösung

Die MediaPipe LLM Inference API ist eine von Google bereitgestellte, frei deploybare Lösung für die lokale Ausführung von Sprachmodellen auf mobilen Geräten [17]. Abhängig vom Modelltyp und den Einstellungen können die Berechnungen entweder auf dem Hauptprozessor (CPU) oder dem Grafikprozessor (GPU) des mobilen Geräts durchgeführt werden [17]. Über sie lassen sich auch mehrere Parameter an der Textgenerierung ändern, darunter die maximale Anzahl an Tokens aus Eingabe und Ausgabe, die Anzahl der wahrscheinlichsten Kandidaten (Top-K), die Zufälligkeit der Auswahl (Temperatur) sowie ein Zufallsstartwert. Darüber hinaus kann ein Low-Rank Adaptation (LoRA)-Modell eingebunden werden, um bei Bedarf ein Modell an seine Aufgaben anzupassen [17].

Die Schnittstelle unterstützt von Haus aus kompakte, speziell für mobile Geräte entwickelte Modelle. Dazu gehört insbesondere die Gemma-Familie von Google, wie Gemma 3 1B und Gemma 2 2B [17]. Darüber hinaus lassen sich über die LiteRT-Community vorkonvertierte Modelle im MediaPipe-Format einbinden [17], darunter Qwen 2.5 1.5B [31]. Diese drei Modelle werden für den weiteren Verlauf der Arbeit verwendet und sind in Abbildung 3.1 zusammengefasst.

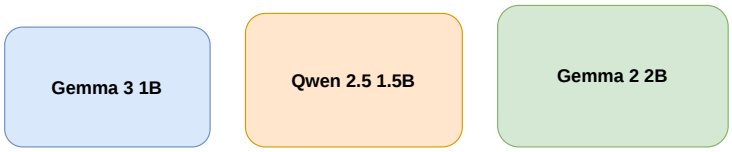


Abbildung 3.1: Übersicht der drei verwendeten Sprachmodelle. Sie unterscheiden sich in Größe und Hersteller, laufen aber über dieselbe Laufzeitumgebung (erstellt mit draw.io).

Unabhängig von der hier genutzten MediaPipe-Laufzeitumgebung gibt es weitere frei deploybare Modelle anderer Anbieter wie zum Beispiel DeepSeek-R1 [5] oder die Llama-Modelle von Meta [32].

Zusätzlich zu MediaPipe existieren weitere Android-kompatible Laufzeitumgebungen. Beispiele sind llama.cpp oder MNN [21]. Nichtsdestotrotz wird in dieser Arbeit MediaPipe verwendet, da in diesem Fall mehrere Aspekte dafür sprechen. Die Bibliothek lässt sich zum einen als offizielle Android-Schnittstelle von Google direkt in die bestehende Java-Anwendung einbinden [17]. llama.cpp ist dagegen eine C++-Bibliothek [21], deren Einbindung in eine Java-Anwendung mit zusätzlichem Aufwand verbunden ist. Zum anderen liegen die Modelle im passenden `.task`-Format vor [17, 29–31], sodass sich alle drei Modelle unter derselben Laufzeitumgebung mit identischen Parametern ausführen lassen. Die Kombination aus der einfachen Integration und den identischen Parametern der verfügbaren Modelle hat schlussendlich zu dieser Entscheidung geführt.

3.2 Die Gemma-Modellfamilie

Die Gemma-Modellfamilie gehört zu den frei deploybaren und ressourcenschonenden Modellen, die vom Gemma-Team bei Google DeepMind entwickelt wurden [11]. Neben der freien Zugänglichkeit der Modelle zeichnen sie sich durch eine ressourcenschonende Ausführung auf herkömmlicher Standardhardware wie Smartphones aus [10, 11]. Um unterschiedlichen technischen Anforderungen gerecht zu werden, sind die Modelle zudem in mehreren Größen verfügbar. Diese werden in Milliarden von Parametern gemessen. So bietet die zweite Generation (Gemma 2) Varianten mit 2, 9 und 27 Milliarden Parametern [10]. Die dritte Generation (Gemma 3) erweitert diese Skalierung auf Modelle mit 1, 4, 12 und 27 Milliarden Parametern [11]. Die aktuellste Generation (Gemma 4) bietet sogar Modelle mit bis zu 31 Milliarden Parametern [12]. Auch der Funktionsumfang wurde erweitert. Seit der dritten Generation sind auch multimodale Eingaben möglich, sodass neben Text auch Bilder verarbeitet werden können [11]. Fähigkeiten zur Verarbeitung unterschiedlicher Sprachen und zur Erfassen deutlich längerer Textzusammenhänge wurden verbessert [11]. Die neueste Version Gemma 4 unterstützt noch größere Kontextfenster von bis zu 256.000 Tokens und besitzt einen integrierten „Thinking-Modus“ für logisches Schlussfolgern [12]. Neben der Basisversion gibt es die Modelle auch in einer speziell angepassten Form, die gezielt für das Führen von Dialogen und das präzise Befolgen

von Anweisungen trainiert wurde [10, 11]. Gemma 2 und Gemma 3 verwenden einen SentencePiece-Tokenizer mit jeweils ca. 256.000 und 262.000 Vokabulareinträgen [10, 11].

3.3 Die Qwen-Modellfamilie

Als drittes Modell wird Qwen des Herstellers Alibaba herangezogen. Genauso wie die Gemma-Modelle ist es frei deploybar. Jedoch stammt es von einem anderen Hersteller und gehört damit nicht zur selben Modellfamilie [35]. Die Generation Qwen2.5 ist in abgestuften Konfigurationen von 0,5 bis 72 Milliarden Parametern verfügbar, wobei die kompakten Varianten gezielt für ressourcenbeschränkte Edge-Szenarien und mobile Endgeräte konzipiert sind [35]. Mit 1,5 Milliarden Parametern liegt die in dieser Arbeit verwendete Variante von Qwen genau zwischen Gemma 3 1B und Gemma 2 2B. Qwen 2.5 nutzt hingegen Byte-Level Byte-Pair Encoding (BBPE) mit einem Vokabular von 151.643 regulären Tokens [35] und damit ein anderes Verfahren sowie ein deutlich kleineres Vokabular als die Modelle von Google. Die neueste Generation der Familie ist Qwen3, die einen Thinking-Modus und einen Non-Thinking-Modus in einem einheitlichen Modell vereint [36].

3.4 Bestehende Anwendung

Im Folgenden wird die bestehende Anwendung vorgestellt, die als Grundlage für die Implementierung der neuen Funktionalität dient.

3.4.1 Unicorn Hybrid Black

Das in dieser Arbeit verwendete Unicorn Hybrid Black ist eine mobile BCI-Plattform der Firma g.tec [9]. Das Aufnahmegerät erfasst die elektrische Aktivität des Gehirns über acht Elektroden auf der Kopfhaut mit einer Abtastrate von 250 Hz [8]. Durch die Kompaktheit des Geräts, bei der die drahtlose und tragbare Bauform im Vordergrund steht, eignet es sich für den mobilen Einsatz. Abbildung 3.2 zeigt die markierten Komponenten des Geräts, die für die Messungen dieser Arbeit verwendet wurden.

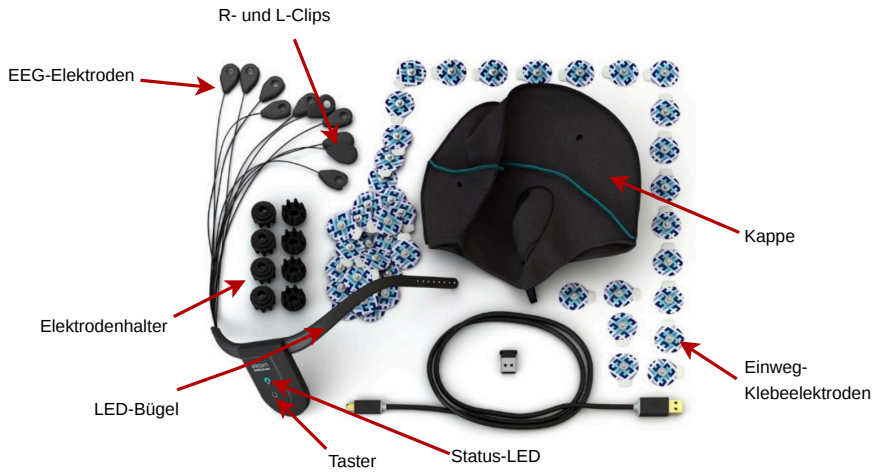


Abbildung 3.2: Komponenten des verwendeten EEG-Geräts g.tec Unicorn Hybrid Black (eigene Beschriftung, erstellt mit draw.io) [9].

3.4.2 Datenübertragung und Anbindung

Die Übertragung der Messdaten an das Endgerät erfolgt drahtlos über Bluetooth, wobei jedes Sample aus den jeweils folgenden 17 Werten besteht [7].

Tabelle 3.1: Aufbau eines Samples des Unicorn Hybrid Black. Von den 17 Werten werden nur die acht EEG-Kanäle und das Gültigkeitskennzeichen ausgewertet [7]

Werte	Bezeichnung	Anzahl
1–8	EEG-Kanäle	8
9–11	Beschleunigungssensor (x, y, z)	3
12–14	Gyroskop (x, y, z)	3
15	Batteriestand	1
16	Counter (fortlaufender Zähler)	1
17	Validation Indicator (valid-Flag)	1
	Gesamt	**17**

3.4.3 Funktionsumfang der Anwendung

Die als Grundlage für diese Arbeit genutzte Anwendung ist das Ergebnis eines Projektes aus einem vorangegangenen Praktikum. Sie bildet deren Basis, indem sie über die Unicorn Android API [6] eine Verbindung mit dem Unicorn Hybrid Black aufbaut, EEG-Daten aufnimmt und/oder speichert. Diese Daten werden zugleich als Zeitverlauf oder als Live-FFT visualisiert. Die Daten können dauerhaft gespeichert und zusätzlich als .db- oder .json-Datei exportiert werden. Der Datenpfad verläuft dabei vom Gerät über Bluetooth zu einem Hintergrunddienst, der die eingehenden Samples in der Datenbank ablegt.

3.4.4 Beitrag dieser Arbeit

Sprachmodelle sind immer häufiger bei der Auswertung von EEG-Daten im Einsatz [3]. Sie werden unter anderem zur Erzeugung von Befundtexten oder zur Deutung von Signalen verwendet [3]. Als zukünftige Richtung nennen Babu u. a. eine echtzeitfähige Ausführung mit geringer Latenz, wie durch Quantisierung [3]. Für einen Einsatz in der Praxis müssen dazu der Speicherbedarf, die Stabilität und die Qualität des erzeugten Textes angemessen ausfallen.

Bei Kim u. a. werden die aus dem EEG berechneten Merkmale als Text an GPT-3 übergeben [27]. Dieses wird über die Schnittstelle von OpenAI angesprochen und weitgehend nachtrainiert [27]. Bei Murhekar u. a. werden von einem kleinen Modul auf dem Gerät aus dem EEG Schlüsselwörter erzeugt, die an ein ausgelagertes, nicht nachtrainiertes Sprachmodell weitergegeben werden [33]. Guo u. a. messen die Leistung von Sprachmodellen auf Android-Smartphones, beziehen sich dabei aber nicht auf EEG-Daten [21]. Am nächsten an dieser Arbeit sind Wang u. a., denn sie übergeben aufbereitete Sensordaten von Wearables als Text an kleine Sprachmodelle und vergleichen diese auf einem Smartphone [41]. Dort werden aber nur nachtrainierte Modelle eingesetzt [41].

Keiner dieser Ansätze verbindet die lokale Ausführung eines unveränderten Sprachmodells mit aufbereiteten Merkmalen als Eingabe. Die Wahl einer bereits quantisiert veröffentlichten Variante sowie Laufzeitparameter wie Kontextgröße oder Top-K gelten dabei nicht als Anpassung, da sie die Gewichte unberührt lassen.

Tabelle 3.2 stellt die Arbeiten danach gegenüber, wo das Sprachmodell ausgeführt wird, ob es angepasst wurde, wie die Eingabe erfolgt und ob mehrere Modelle auf dem Endgerät verglichen werden. Als Anpassung gilt dabei eine Veränderung der Gewichte, wie durch Fine-Tuning oder LoRA.

Tabelle 3.2: Gegenüberstellung nach Ausführungsort, Modellanpassung, Eingabe und Modellvergleich auf dem Endgerät.

Arbeit	**Modell lokal**	**Sprachmodell angepasst**	**Eingabe**	**Vergleich**
Kim u. a. [27]	nein	ja	Merkmale	nein
Murhekar u. a. [33]	nein	nein	Schlüsselwörter	nein
Guo u. a. [21]	ja	nein	kein EEG	ja
Wang u. a. [41]	ja	ja	kein EEG	ja
Diese Arbeit	ja	nein	Merkmale	ja

Offen ist damit, ob unveränderte, frei verfügbare Sprachmodelle ausreichen, um aufbereitete EEG-Merkmale zu analysieren. Der Beitrag dieser Arbeit ist daher der systematische Vergleich dreier solcher Modelle unter identischen technischen Bedingungen anhand von Latenz, Ressourcenverbrauch, Stabilität und Ausgabequalität.

Die bestehende Anwendung wird um vier neue Komponenten erweitert. Davon sind drei Kernkomponenten, die an der Verarbeitung der EEG-Daten durch lokale Sprachmodelle arbeiten: die Schicht zur Merkmalsextraktion (`features`), die Anbindung eines oder mehrerer Sprachmodelle (`llm`) und die Benutzeroberfläche zur KI-gestützten Analyse (`analyse`). Darüber hinaus wird für die in der Evaluation benötigten Messungen ein Benchmark implementiert, bei dem systematisch und automatisiert gemessen wird (`benchmark`). Wie die Komponenten zusammenspielen, zeigt Abbildung 5.1. Im Originalcode wurden nur minimale Änderungen vorgenommen.

4 Methodik

In diesem Kapitel wird das Vorgehen beschrieben, mit dem die Forschungsfrage beantwortet werden soll. Dabei wird als Erstes die Merkmalsextraktion näher erläutert, bei der die rohen EEG-Daten in kompakte Kennzahlen überführt werden. Anschließend wird die Modellauswahl beschrieben und die Anwendungsszenarien definiert. Abschließend folgt das Messprotokoll, das die Vorgehensweise der Messungen und die erfassten Metriken beschreibt.

4.1 Merkmalsextraktion

Ein Sprachmodell kann keine EEG-Rohdaten verarbeiten, da bei einer Abtastrate von 250 Hz und acht Kanälen bereits in kurzer Zeit eine große, unstrukturierte Zahlenmenge entsteht. Bei einer nur einminütigen Aufnahme ergeben sich beispielsweise

$$\underbrace{8}_{\text{Kanäle}} \times \underbrace{250}_{\text{Hz}} \times \underbrace{60}_{\text{Sekunden}} = 120\,000 \text{ Werte.} \tag{4.1}$$

Solche Mengen an Daten können den Kontext des Modells überschreiten und geben dem Modell einen geringen Mehrwert, daraus auf Informationen zu schließen, weshalb die Daten vorher erst in eine kompaktere Form umgewandelt werden müssen (Abbildung 4.1). Die kompaktere Form samt ihren Merkmalen ist für das Modell verständlicher, tokensparsamer und kann besser verarbeitet werden.



Abbildung 4.1: Datenfluss der Merkmalsextraktion von den Rohdaten bis zum Text. Jede Stufe verdichtet die Daten weiter, bis eine für das Modell nutzbare Beschreibung entsteht (erstellt mit draw.io).

4.1.1 Segmentierung

Würden die Merkmale als ein einziger Mittelwert über die gesamte Aufnahme berechnet, ginge der zeitliche Verlauf der Session verloren. Aus diesem Grund wird jede Session in mehrere gleich große Segmente aufgeteilt (Abbildung 4.2). Da das Signal mit einer konstanten Abtastrate von 250 Hz aufgenommen wird, entspricht eine gleiche Anzahl an Samples automatisch einer gleichen Zeitdauer. Die Segmentierung wird daher Sample-basiert durchgeführt. Dadurch ist es leichter nachvollziehbar, wie sich die Signalcharakteristik zwischen Beginn und Ende der Aufnahme verändert. Durch dieses Verfahren wird die Analyse robuster gegenüber Artefakten, da diese nur einen Teil der Session betreffen und nicht die gesamte Aufnahme verfälschen. Die Wahl auf genau vier Segmente ist hierbei ein Kompromiss. Gleichzeitig wird so eine niedrige Komplexität mit der Möglichkeit verbunden, einen feinen zeitlichen Verlauf abzubilden. Mehr Segmente würden den aufbereiteten Text für die Modelle vergrößern, da je Segment ein eigener Block entsteht (Abschnitt 4.1.4), und somit die Anzahl der Eingabe-Tokens erhöhen. Weniger Segmente könnten zu einem zu groben Zeitverlauf führen.

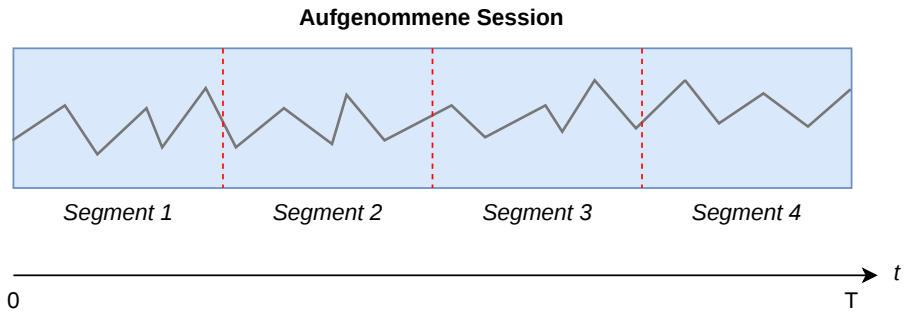


Abbildung 4.2: Aufteilung einer Session in vier gleich lange Segmente. So bleibt der zeitliche Verlauf erkennbar, statt nur einen Mittelwert zu bilden (erstellt mit draw.io).

Damit die Aufteilung der Session möglich ist, muss die Aufnahme eine Mindestlänge haben. Damit pro Segment mindestens ein vollständiges Analysefenster für die spektrale Berechnung zur Verfügung steht, sind bei vier Segmenten und einer Fenstergröße von 256 Werten mindestens

$$4 \text{ Segmente} \times 256 \text{ Werte (Fenster)} = 1024 \text{ Samples} \approx 4 \text{ s} \tag{4.2}$$

erforderlich. Wenn die Aufnahme zu kurz ist, um die Mindestlänge zu erfüllen, wird die Analyse abgebrochen und eine entsprechende Meldung angezeigt.

Die Fenstergröße ist variabel einstellbar. Eine größere Fenstergröße erhöht die Frequenzauflösung [24], erfordert jedoch eine längere Mindestdauer der Session. Für alle folgenden Untersuchungen wird mit der Standardfenstergröße von 256 Samples gearbeitet. Dies liegt an der Fourier-Transformation, bei der Zweierpotenzen für den Wert verwendet werden (Abschnitt 2.3.1). Dieser Wert liegt nahe der Abtastrate von 250 Hz des Unicorn Hybrid Black und entspricht damit einer Dauer von rund einer Sekunde. Nach Gleichung 2.2 ergibt sich daraus eine Frequenzauflösung von rund 1 Hz, womit sich die fünf Frequenzbänder aus Tabelle 2.1 noch trennen lassen. Dagegen würde eine Fenstergröße von 128 Samples eine Frequenzauflösung von rund 2 Hz ergeben und damit halbieren, was einen Verlust an Genauigkeit zur Folge hat. Bei 512 Samples würde sich die Mindestdauer verdoppeln, was jedoch zu weniger Fenstern je Segment führt.

4.1.2 Spektrale Merkmale

Die spektralen Merkmale werden für jedes Segment bestimmt, indem die Signalenergie auf die einzelnen Frequenzbänder verteilt wird. Die kanalweise Berechnung erfolgt dabei mit der Welch-Methode [24]. Hierfür wird das Signal eines Segments in überlappende Fenster unterteilt (Abbildung 4.3). Für jedes dieser Fenster wird das Leistungsspektrum berechnet, das anschließend über alle Fenster gemittelt wird. Durch diese Mittelung wird das resultierende Spektrum deutlich stabiler und weniger rauschanfällig als bei einer einzelnen FFT. Allerdings ist dann mit einer geringeren Frequenzauflösung zu rechnen [24].

Um den Gleichanteil (0 Hz) des Signals zu eliminieren, wird vor der Fourier-Transformation zunächst der Mittelwert jedes Fensters subtrahiert. Anschließend wird die Hann-Fensterfunktion (auch Hanning genannt) verwendet, um jedes Fenster zu gewichten [24]. Die Gewichtung wird verwendet, da es ansonsten zu einem direkten, abrupten Abschneiden des Signals kommt, was zu harten Übergängen an den Fenstergrenzen führt [24]. Durch diesen Vorgang entsteht eine spektrale Leckage. Die Hann-Funktion hilft gegen diese Leckage, indem sie die Amplitudenwerte an den Rändern des Fensters sanft abschwächt [24].

Die Fensterfunktion wird mathematisch wie folgt beschrieben:

$$w(n) = 0.5 - 0.5 \cos\left(\frac{2\pi n}{N-1}\right) \tag{4.3}$$

wobei N die Fenstergröße (Standard: 256) bezeichnet [24].

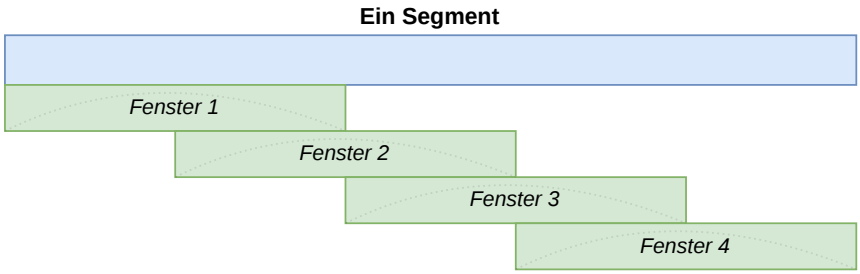


Abbildung 4.3: Zerlegung eines Segments in überlappende, mit einer Hann-Funktion gewichtete Analysefenster (50 % Überlappung) für die Welch-Methode (erstellt mit draw.io).

Jedes Fenster wird per FFT in den Frequenzbereich überführt, um das jeweilige lokale Leistungsspektrum (Periodogramm) zu berechnen [1, 24]. Die Leistung der einzelnen Frequenz-Bins wird den fünf Frequenzbändern Delta, Theta, Alpha, Beta und Gamma zugeordnet [1]. Dies erfolgt durch das Aufsummieren der Leistung aller Frequenz-Bins innerhalb der jeweiligen Bandgrenzen. Das Gamma-Band wird nach oben auf 45 Hz begrenzt. Störungen aus dem Stromnetz liegen je nach Land bei 50 oder 60 Hz [25] und fließen dadurch nicht in die Bandleistung ein. In der Regel schwanken die absoluten Leistungswerte stark und sind schwer interpretierbar. Daher wird die relative Bandleistung verwendet, die sich aus dem Verhältnis der Leistung eines Frequenzbandes zur Gesamtleistung ergibt. Dadurch lässt sich ablesen, welches Frequenzband im untersuchten Segment dominiert [1].

4.1.3 Zeitstatistische Merkmale

Neben den spektralen Merkmalen gibt es auch die zeitstatistischen Merkmale. Sie werden für jedes Segment berechnet [1]. Hierfür ist keine FFT notwendig, da die Merkmale direkt aus dem Zeitsignal extrahiert werden [1]. Zum einen gibt es die Spannweite (Peak-to-Peak-Amplitude), die die Differenz zwischen dem größten und dem kleinsten Amplitudenwert aufzeigt [23]. Der Vorteil dieser Herangehensweise ist, dass sie im Gegensatz zur Betrachtung eines absoluten Maximalwertes die Unabhängigkeit von einem potenziellen Gleichanteil des Signals gewährleistet. Aus diesem Grund stellt die Peak-to-Peak-Amplitude ein Kriterium dar, um extreme Signalausschläge und Drifts zu identifizieren, wie sie bei Artefakten auftreten können [23].

Des Weiteren wird zur Beurteilung der Übertragungsqualität der Anteil der ungültigen Messwerte betrachtet. Dies ist der Anteil der Datenpunkte, die nicht empfangen wurden und deshalb bei der Übertragung durch eine Kopie des letzten Samples ersetzt und als ungültig markiert wurden. Man kann durch diesen Indikator erkennen, wie lückenhaft eine Aufnahme ist, wobei er keine Aussage über die Qualität des abgeleiteten Signals trifft.

4.1.4 Aufbereitung für das Sprachmodell

Im letzten Schritt der Merkmalsextraktion werden die berechneten Merkmale in eine textuelle Form gebracht, die vom Sprachmodell verarbeitet werden kann. Dabei enthält der Text folgende Informationen:

- aggregierte Kennzahlen
- relative Bandleistung der fünf Frequenzbänder (pro Segment)
- Spannweite (Peak-to-Peak-Amplitude)
- Anteil der ungültigen Messwerte

Die Merkmale werden neben der zeitlichen Aufteilung über die acht Kanäle zusammengefasst. Dabei wird die Bandleistung je Segment über alle acht Kanäle summiert und dann relativ zur Gesamtleistung gesetzt. Bei der Spannweite selbst wird nicht vorher gemittelt. Stattdessen wird der Kanal mit dem größten Ausschlag genannt, da sonst einzelne starke Artefakte verdeckt werden könnten.

Dabei werden bewusst keine Bewertungen oder Interpretationen in den Text aufgenommen. Alle Informationen sind objektive Messwerte, deren Bedeutung allein dem Sprachmodell überlassen wird. Dadurch wird gewährleistet, dass die eigentliche Analysearbeit vom Modell erledigt wird.

Der aufbereitete Text der gesamten Session mit je vier Blöcken wird dem Modell mit einem einzigen Aufruf übergeben. Die Option, jeden Block einzeln zu übergeben, wurde bewusst vermieden. Die Idee ist es, dass das Modell die gesamte Session gemeinsam und auf einen Schlag interpretiert. Aussagen sollen nicht Schritt für Schritt erfolgen. Man müsste alle Ausgaben pro Schritt zusammenführen, was mehr Aufwand mit sich bringt. Außerdem beziehen sich die Latenzmetriken so auf genau einen Aufruf und bleiben eindeutig.

Die Merkmalsextraktion kostet wenig Rechenzeit. Die zeitstatistischen Merkmale brauchen einen Durchlauf über die Samples und wachsen linear mit der Länge der Session.

Die Aufbereitung rechnet danach nur noch mit den fertigen Merkmalen je Segment, also mit gleich vielen Werten, egal wie lang die Session war. Die Spektralanalyse ist am aufwendigsten. Das liegt daran, dass je Fenster die FFT verwendet wird und der Aufwand bei $N \log_2 N$ liegt (Abschnitt 2.3.1). Eine Messung, die gesondert durchgeführt wurde (nicht Teil der finalen Implementierung), zeigt, dass die Extraktion bei einer rund zweiminütigen Session 111,7 $\pm$ 14,3 ms benötigt (Mittel aus vier Wiederholungen, erste Messung verworfen). Gegenüber der Inferenz, die je nach Modell und Szenario zwischen 6,70 und 42,00 s liegt (Tabelle 6.1), fällt sie nicht ins Gewicht. Die Evaluation bezieht sich ohnehin auf die Sprachmodelle und nicht auf die vorgelagerte Verarbeitung in der Anwendung. Diese Entscheidung gilt nur für die Länge der Messungen, die in dieser Arbeit verwendet werden.

4.2 Modellauswahl

Wie schon in Abschnitt 3.1.1 beschrieben, stehen systemintegrierte Modelle auf dem verwendeten Testgerät nicht zur Verfügung. Daher konzentriert sich diese Arbeit auf frei deploybare Modelle, wie sie in Abschnitt 3.2 und Abschnitt 3.3 beschrieben sind.

Um eine geeignete Evaluierung zu ermöglichen, wird der Einfluss der Modellgröße unter konstanten Ausführungsbedingungen untersucht. Dazu werden drei Modelle vergleichend betrachtet: zum einen die kompakte Variante Gemma 3 1B [11, 17], zum anderen die parameterstärkere Gemma 2 2B als größeres Referenzmodell [10, 17], sowie das Modell Qwen 2.5 1.5B des Herstellers Alibaba [17, 35], dessen Größe zwischen den beiden Gemma-Modellen liegt. Da alle drei Modelle nativ über die MediaPipe-Runtime (LLM Inference API) laufen [17], lässt sich bei gleicher Laufzeitumgebung sowohl der Effekt der Modellgröße als auch der Einfluss des Herstellers auf die Systemperformanz untersuchen.

Alle drei Modelle werden in 8-Bit-Quantisierung und mit identischer Kontextgröße (1280 Token) ausgeführt, sodass sich der Vergleich einzig auf die Modellgröße und den Hersteller bezieht. Die Wahl einer Kontextgröße von 1280 Token ergibt sich aus den verfügbaren Modellvarianten. Für Gemma 3 1B und Qwen 2.5 1.5B liegen zwar auch Varianten mit größeren Kontextfenstern vor, für Gemma 2 2B dagegen ausschließlich die Variante mit 1280 Token [29–31]. Damit ist 1280 der größte Wert, der für alle drei Modelle einheitlich zur Verfügung steht. Zudem erfolgt die Token-Auswahl bei allen Modellen mit dem Standardwert der Schnittstelle von Top-K 40, was bedeutet, dass bei jedem Schritt nur die 40 wahrscheinlichsten Token als Kandidaten betrachtet werden [17]. Die im Code gesetzte Obergrenze von 64 (Listing 5.6) wird dabei nicht ausgeschöpft. Die Temperatur, die bei einem höheren Wert weniger stark auf das wahrscheinlichste Token setzt, sowie der Zufallsstartwert, bei dem die Ausgaben bei unveränderter Eingabe identisch bleiben, werden nicht berührt und liegen bei den Standardwerten 0,8 und 0 [17]. Diese Entscheidung ist bewusst getroffen, da beide Werte für alle Modelle gleich bleiben und den Vergleich dadurch nicht verzerren. Im Code wird nicht festgelegt, ob die Modelle auf der CPU oder GPU laufen. Wie die Logcat-Ausgabe beim Laden zeigt, läuft die Inferenz auf der CPU über den XNNPACK-Delegate von TensorFlow Lite.

4.3 Anwendungsszenarien

Um die Eignung der Modelle für die Analyse von EEG-Daten zu untersuchen, werden drei Anwendungsszenarien betrachtet. Dabei wird geprüft, wie ein Sprachmodell die extrahierten Merkmale einer oder mehrerer Sessions verarbeitet. Jedes Szenario besteht aus einem einmaligen Aufruf des Modells, der die Merkmale der Session(s) als Eingabe erhält. Es wird keine vorab bekannte Musterlösung benötigt. Die Szenarien orientieren sich an zwei Aufgabenklassen, zum einen an der automatischen Vorstrukturierung von Daten, zum anderen an der Unterstützung einfacher Analyseprozesse.

- **Session-Report (Vorstrukturierung):** Aus den Merkmalen einer Session wird ein zusammenhängender, lesbarer Bericht generiert.
- **Artefakt-Erklärung (Analyseunterstützung):** Das Modell erhält die Kennzahlen einer Session und erklärt auffällige Muster (z. B. hohe Peak-to-Peak-Amplituden oder einen hohen Anteil ungültiger Werte) in natürlicher Sprache.
- **Session-Vergleich (Analyseunterstützung):** Es werden die Merkmale zweier Sessions übergeben und darauffolgend verglichen.

Der Prompt-Aufbau ist in allen drei Szenarien und Modellen identisch. Er beginnt mit der szenariospezifischen Anweisung, gefolgt von einem textuell aufbereiteten Merkmalssatz. Das Niveau steigt dabei mit jedem Szenario. Während der Report lediglich ein Zusammenfassen erfordert, ist beim Artefakt-Erklärungsszenario zusätzlich das Deuten notwendig. Das Vergleichsszenario erfordert schließlich ein Schlussfolgern über zwei Datensätze hinweg. Dadurch kann man die Grenzen der Modelle in Bezug auf die Komplexität der Aufgabenstellung untersuchen.

Dabei wurde bewusst auf drei verschiedene Szenarien gesetzt, deren Fokus das Generieren von textuellen Inhalten ist. Sie unterstützen dabei, die EEG-Merkmale zu verstehen und in eine für Benutzer verständliche Sprache zu übersetzen. Auf Klassifikationsszenarien wurde bewusst verzichtet, da man für diese Vergleichswerte benötigt, die in dieser Arbeit nicht zur Verfügung stehen.

4.4 Messprotokoll (Benchmark)

Eine verlässliche Messung kann nur systematisch und unter kontrollierten Bedingungen ausgeführt werden. Da es sich um mehrere Messungen handelt, werden sie in kurzer Zeit automatisiert über alle Modell-Szenario-Kombinationen durchgeführt und in einer Comma-Separated Values (CSV)-Datei protokolliert. So wird sichergestellt, dass die Messungen eine reproduzierbare und auswertbare Datenbasis für die anschließende Evaluation liefern. Bevor die eigentliche Messung beginnt, wird einmalig eine Aufwärmphase durchgeführt, um Kaltstart-Effekte zu vermeiden. Ein solcher Kaltstart äußert sich darin, dass der erste Lauf eines Modells durch das Laden und Initialisieren deutlich länger ausfällt als die nachfolgenden. Dadurch wird verhindert, dass die erste Kombination verzerrt gemessen wird. Das Ergebnis dieser Messung wird nicht protokolliert und dient allein der Aufwärmung. Alle Messungen richten sich nach einer bestimmten Reihenfolge. Diese startet mit Gemma 3 1B, gefolgt von Gemma 2 2B, und endet mit Qwen 2.5 1.5B, jeweils in den Szenarien Report, Artefakt-Erklärung und Vergleich. Die Reihenfolge ist bewusst festgelegt und bleibt über alle Durchläufe gleich. Somit wird jedes Modell in einem identischen Ablauf gemessen, wodurch die Messreihe reproduzierbar bleibt. Eine zufällige

Reihenfolge würde zwar Reihenfolgeeffekte auf alle Modelle verteilen, erfordert jedoch transparentere Angaben, da sich die Effekte sonst nicht mehr nachvollziehen lassen.

Es wird jede Kombination von Modell und Anwendungsszenario N = 5 Mal gemessen, da eine Überhitzung des Geräts und parallel laufende Prozesse die Leistung beeinflussen können [21]. Um auch hier Kaltstart-Effekte zu vermeiden, wird aus jeder Kombination die erste Messung verworfen. Die zuvor beschriebene Aufwärm-Messung betrifft dagegen nur den einmaligen Systemstart. Die verbleibenden Werte werden gemittelt. Zusätzlich wird die Standardabweichung berechnet, die die Streuung der Messwerte um den Mittelwert beschreibt. Der Mittelwert $\bar{x}$ und die Standardabweichung s über die n einbezogenen Messwerte ergeben sich dabei wie folgt:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} \tag{4.4}$$

Dadurch wird die Stabilität der Messungen sichtbar. Ein hoher Wert deutet auf eine starke Streuung hin, während ein niedriger Wert eine geringe Streuung und damit eine hohe Stabilität der Messungen anzeigt.

Die anfängliche Aufwärm-Messung wird von der Anwendung selbst ausgeführt. Das Verwerfen der ersten Messung je Kombination, die Mittelung der verbleibenden Messungen sowie die Berechnung der Standardabweichung erfolgen dagegen nicht in der Anwendung. Sie werden stattdessen manuell auf Grundlage der in der CSV-Datei gespeicherten Rohwerte durchgeführt.

4.4.1 Metriken

Zur Bewertung der Modelle werden mehrere Metriken erfasst, die sich in Latenz, Ressourcenverbrauch und Stabilität gliedern. Dazu zählen unter anderem die Zeit bis zum ersten Token (TTFT) und der Speicherverbrauch als Proportional Set Size (PSS).

Tabelle 4.1: Übersicht der erfassten Metriken nach Latenz, Ressourcenverbrauch, Stabilität und Qualität. Bis auf die Ausgabequalität werden alle Werte automatisiert erhoben.

Kategorie	**Metrik**	**Beschreibung**
Latenz	Ladezeit	Zeit zum Laden des Modells
	TTFT	Zeit bis zum ersten erzeugten Token, in der Inferenzdauer enthalten
	Inferenzdauer	Dauer der gesamten Inferenz, ohne Ladezeit
	Tokens/s	Durchsatz bezogen auf die gesamte Inferenzdauer
Ressourcen	RAM (PSS)	Speicherverbrauch inkl. nativem Speicher
	Akku	Energieverbrauch (µAh) über eine Messreihe
Stabilität	Status	erfolgreich oder Fehler
Qualität	Ausgabequalität	qualitative Bewertung (Kapitel 6)

Die Zeitmessungen laufen alle über `System.nanoTime()`, bei der die Differenz in Nanosekunden durch eine Million geteilt wird. So erhält man die Angabe als Millisekunde.

Die Tokens pro Sekunde erlauben einen fairen Vergleich unabhängig von der Länge der Ausgabe. Eine reine Zeitmessung würde längere Antworten benachteiligen. Die Metrik erhält man, wie in folgender Gleichung dargestellt, indem man die Anzahl der erzeugten Token durch die gesamte Inferenzdauer teilt:

$$\text{Tokens/s} = \frac{N_{\text{Token}}}{t_{\text{Inferenz}}} \tag{4.5}$$

wobei N_{Token} die Anzahl der erzeugten Token und t_{Inferenz} die Inferenzdauer in Sekunden bezeichnet.

Der Speicherverbrauch wird über die PSS erfasst, da diese exklusiv von der Applikation genutzte Speicherseiten sowie den proportionalen Anteil an gemeinsam verwendeten Seiten (Shared Pages) berücksichtigt. Dadurch eignet sie sich zur präzisen Bestimmung des tatsächlichen Speicherbedarfs, da durch sie gemeinsam genutzte Ressourcen (wie beispielsweise Bibliotheken oder Systemdienste) nicht mehrfach gezählt werden [18]. Der Wert wird direkt nach dem Abschluss einer Inferenz ermittelt, während das Modell selbst noch geladen ist. Es handelt sich um einen aktuellen Wert, bei dem keine Speicherbereinigung ausgelöst wird. Bereiche, die noch nicht freigegeben wurden, werden mit eingeschlossen. Dabei sollten die erfassten Werte als obere Schranke des tatsächlichen Bedarfs behandelt werden.

Der Akkuverbrauch wird über den BatteryManager des Geräts vor und nach einer Messreihe ermittelt. Die Messung erfolgt in Mikroamperestunden (µAh), da diese eine feinere Auflösung als die Angabe in Prozent bietet [13].

Im Gegensatz zum Benchmark, bei dem es gleich fünf Messungen gibt, werden für die reine Analyse einer Session nur Latenzmetriken erfasst. Der Grund liegt hierbei an der Menge der Messungen. Der Energieverbrauch lässt sich nur über eine ganze Messreihe sinnvoll bestimmen, da er sich erst aus der Differenz des Akkustands über mehrere aufeinanderfolgende Durchläufe ergibt. Zudem schwankt der Arbeitsspeicherbedarf stark [18], sodass eine Messung keine verlässliche Aussage über den Speicherbedarf zulässt. Die Metriken Status und Ausgabequalität sind nur für die Evaluation relevant und werden daher nicht in der Analyse erfasst.

Bei der Ausgabequalität geht es um die Qualität der vom Modell gegebenen Antwort. Hierfür wird keine automatisierte Messung benötigt, da es keine feste Musterlösung gibt, mit der man sie vergleichen könnte. Ein eindeutiges Richtig oder Falsch existiert nicht. Stattdessen wird der Inhalt der Ausgabe anhand der folgenden vier Kriterien bewertet:

- **Korrektheit:** Stimmt die Aussage mit den extrahierten Merkmalen überein?
- **Halluzinationsfreiheit:** Werden keine Werte oder Begriffe erfunden, die nicht in den Daten stehen?
- **Verständlichkeit:** Ist die Ausgabe sprachlich klar und lesbar?
- **Formattreue:** Hält die Ausgabe die Vorgaben ein (Fließtext, kein Markdown, knappe Länge)?

4.4.2 Messbedingungen

Damit die Messungen unter vergleichbaren und technisch einheitlichen Bedingungen erfolgen können, werden sie unter den folgenden Rahmenbedingungen durchgeführt:

- Der Flugmodus im Testgerät ist aktiviert, um Netzwerkaktivitäten auszuschließen.
- Die Bildschirmhelligkeit wird auf einen festen Wert (ungefähr 50 %) eingestellt, um den Akkuverbrauch über alle Messungen hinweg vergleichbar zu halten.
- Das Handy befindet sich nicht im Ladezustand, da dies den Akkuverbrauch während der Messung verfälschen würde. Bei Start der Messung befindet sich der Akkustand bei ungefähr 60 %. Dieser Wert wird während aller Messungen nicht gehalten, sondern der Verbrauch wird ab der ersten Messung festgehalten. Dieser Verbrauch wird dann als eigentliche Messgröße verwendet.
- Alle unnötigen Hintergrundprozesse werden beendet, um die Systemlast zu minimieren.
- Alle Messungen finden möglichst innerhalb von 20 Minuten statt, um die Temperatur des Geräts konstant zu halten.
- Alle Messungen werden auf demselben Testgerät durchgeführt, um die Hardwarebedingungen konstant zu halten. Dabei handelt es sich um ein Samsung Galaxy S23 mit dem Prozessor Qualcomm Snapdragon 8 Gen 2 und 8 GB Arbeitsspeicher, betrieben unter Android 16 (One UI 8.5), mit einer Akkukapazität von 3900 mAh [2, 38].
- Für alle Messungen werden dieselben Sessions als Eingabe verwendet, sodass alle Metriken mit identischer Eingabe erfasst werden.
- Alle Modelle erhalten den identischen Prompt. Dieser ist bewusst auf das größte Modell, Gemma 2 2B, feinjustiert, um einen Referenzwert zu erhalten.
- Unmittelbar vor der Messung wird das Testgerät für mindestens 20 Minuten nicht genutzt, damit es abkühlen kann.
- Während der gesamten Messung bleibt das Testgerät eingeschaltet und die Session-Detailansicht geöffnet, da der Benchmark sonst unterbrochen wird.
- Alle Messungen erfolgen mit deutscher Spracheinstellung, sodass sämtliche Eingaben und Ausgaben deutschsprachig sind.

Auch wenn alle Modelle denselben szenariospezifischen Prompt erhalten, kann die Anzahl der Eingabe-Tokens je Modell schwanken. Jedes Modell besitzt einen eigenen Tokenizer mit einer anderen Implementierung eines Algorithmus und anderen Vokabulargrößen, um Textsequenzen in numerische Repräsentationen (Tokens) zu zerlegen [34]. Die konkreten Verfahren der verwendeten Modelle sind in Abschnitt 3.2 und Abschnitt 3.3 beschrieben. Für die Messbedingungen bedeutet das Folgendes: Der Top-K-Wert bleibt unbeeinflusst und ist von der Zerlegung selbst nicht betroffen. Die Kontextgröße von 1280 ist jedoch eine Größe, die je nach Tokenizer schneller (beispielsweise durch ein kleineres Vokabular) oder langsamer erreicht werden kann (Abschnitt 7.1).

5 Implementierung

Da die bestehende Anwendung bereits in Java umgesetzt ist und die Erweiterung auf sie aufbaut, wird sie ebenfalls in derselben Programmiersprache realisiert. Android Studio wird dabei als Entwicklungsumgebung verwendet, und der Build erfolgt über das Build-System Gradle. Die im Folgenden verwendeten Bibliotheken werden in den jeweiligen Abschnitten genannt. Der vollständige Quellcode der Anwendung liegt dem digitalen Anhang bei.

5.1 Architektur

Die Implementierung der Anwendung besteht aus den farblich gekennzeichneten Komponenten (Blau und Grün), die in Abbildung 5.1 dargestellt sind:

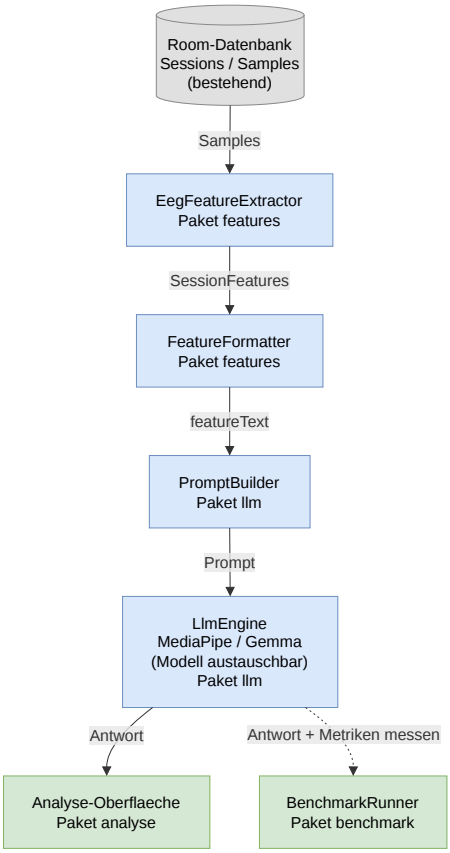


Abbildung 5.1: Architektur und Datenfluss der Anwendung. Blau und Grün kennzeichnen die neuen Komponenten, der Weg führt von der Datenbank bis zur Modellantwort (erstellt mit draw.io).

Der Weg startet über die Datenbank, die schon Teil der bestehenden Anwendung war und aus der die Samples abgerufen werden:

- **EegFeatureExtractor** (`features`)**:** Hier werden die Samples verarbeitet, indem Merkmale berechnet werden.
- **FeatureFormatter** (`features`)**:** Wandelt die Merkmale in ein für das Sprachmodell verständliches Format um.
- **PromptBuilder** (`llm`)**:** Baut die Anweisung für den Prompt (je Szenario).
- **LlmEngine** (`llm`)**:** Führt das Modell (Gemma oder Qwen via MediaPipe) aus und gibt die Antwort zurück.
- **Analyse-Oberfläche** (`analyse`)**:** Zeigt letztlich die Antwort an.
- **Benchmark** (`benchmark`)**:** Misst die Verarbeitung (Laufzeit, Speicherverbrauch etc.).

Durch die Trennung dieser Pakete bleibt der Code übersichtlich und erweiterbar.

Die Architektur enthält wichtige Merkmale, wie zum Beispiel, dass die gesamte Logik des Modells in der Klasse `LlmEngine` gekapselt ist. Dort wird eine Schnittstelle bereitgestellt, die das Laden, Anfragen und Freigeben ermöglicht. Äußere Änderungen beeinflussen die Klasse nicht, da Modell- und Laufzeitumgebung vom Rest der Anwendung unabhängig sind. Die Modelle Gemma 3 1B, Gemma 2 2B und Qwen 2.5 1.5B lassen sich daher einfach durch den Wechsel des Modellpfads austauschen und laden. Andere Modelle oder sogar Laufzeitumgebungen sind bei Bedarf auch möglich. Wenn das Gerät es unterstützt, können systemintegrierte Modelle eingebunden werden.

Das Gleiche lässt sich mit dem `PromptBuilder` erreichen. Dort lassen sich neue Szenarien ergänzen, ohne die restliche Anwendung anpassen zu müssen.

Auch mit dem `FeatureFormatter` ist eine einfache Änderung des Textes umsetzbar, da die Textdarstellung von der Berechnungslogik aller Merkmale entkoppelt ist.

Die Erweiterung baut auf der bestehenden Infrastruktur auf. So wird beispielsweise die bestehende Datenbank verwendet und Neuerungen implementiert, ohne die vorhandene Live-Chart-Verarbeitung zu verändern. Zudem werden die Sessions am Anfang auf ihre Verwertbarkeit validiert. Neue Ansichten fügen sich in die bestehenden Konzepte der Anwendung ein. Neben dem hellen Modus unterstützt die neue Implementierung den Dunkelmodus sowie die Sprachen Deutsch und Englisch.

Der Benchmark verwendet denselben Analyseablauf wie eine vom Nutzer ausgelöste Einzelanalyse.

Zusätzlich zum Architekturdiagramm zeigt die folgende Abbildung 5.2 den zeitlichen Ablauf einer Analyse.

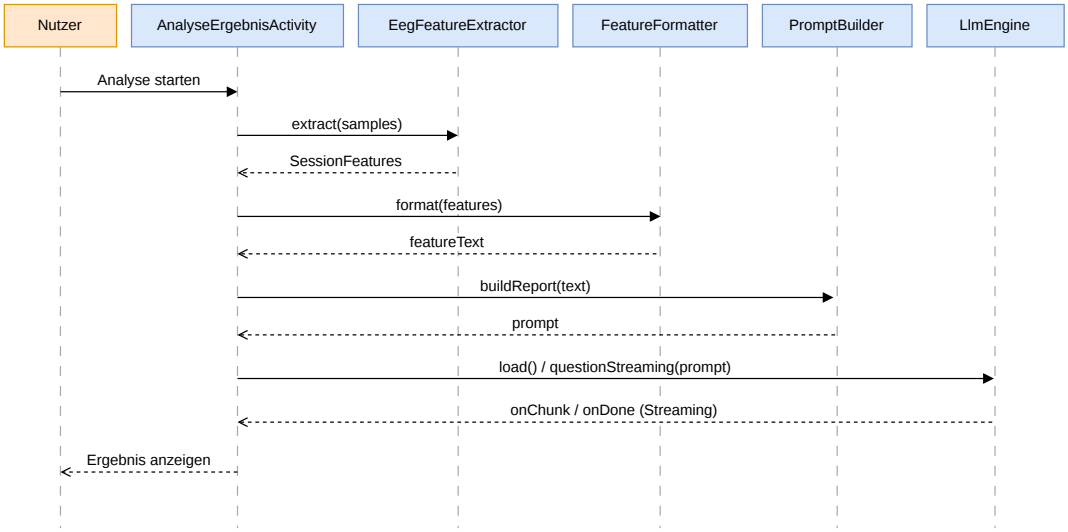


Abbildung 5.2: Sequenzdiagramm des Analyse-Ablaufs. Es zeigt das Zusammenspiel der Komponenten von der Auswahl im Dialog bis zur streamenden Ausgabe (erstellt mit draw.io).

Nun werden die einzelnen Komponenten der Architektur im Detail erläutert, beginnend mit der Merkmalsextraktion.

5.2 Implementierung der Merkmalsextraktion

Die Merkmalsextraktion ist im Paket `features` implementiert; zuständig dafür ist die Klasse `EegFeatureExtractor`. Sie durchläuft für jede Session eine feste Abfolge von Schritten: Als Erstes wird die Session über die Klasse `UnicornRepository` aus der Datenbank geladen, daraufhin wird sie auf ihre Verwertbarkeit geprüft. Die Datenbank war schon Teil der bestehenden Anwendung. Anschließend wird sie in gleich große Segmente aufgeteilt, bei denen dann jeweils die spektralen sowie zeitstatistischen Merkmale berechnet werden. Die Ergebnisse werden alle im Objekt `SessionFeatures` gesammelt und schließlich vom `FeatureFormatter` in einen lesbaren Text umgewandelt, den das Sprachmodell verarbeiten kann. Im Folgenden wird chronologisch auf die einzelnen Schritte genauer eingegangen.

5.2.1 Vorbereitung

Wenn die Klasse erzeugt wird, werden im Konstruktor alle wiederverwendbaren Bestandteile angelegt. Dazu gehört das Hann-Fenster, das für die Fourier-Transformation vorab berechnet wird, um bei jedem Fenster nicht erneut erzeugt zu werden. Außerdem wird das FFT-Objekt der Bibliothek JTransforms für die gewählte Fenstergröße instanziiert [42]. Der Standardwert für die Fenstergröße beträgt 256, kann aber variabel angepasst werden. Aus ihr und der Anzahl der Segmente wird die Mindestlänge `minSamples` der Session berechnet. Beide Werte werden multipliziert und ergeben so die Mindestanzahl der Samples.

5.2.2 Validierung

Die Methode `validate` prüft eine Session auf ihre Verwertbarkeit. Es gibt zwei Kriterien, die erfüllt sein müssen. Zum einen muss die Session mindestens so viele Samples enthalten, wie in `minSamples` berechnet wurde, ansonsten wird `TOO_SHORT` zurückgegeben. Zum anderen muss der Anteil ungültiger Samples unter 50 % liegen. Ist dies nicht der Fall, wird `TOO_MANY_INVALID` zurückgegeben. Sind beide Kriterien erfüllt, wird die Analyse mit der Rückgabe von `OK` fortgesetzt, ansonsten wird dem Nutzer eine entsprechende Meldung angezeigt.

5.2.3 Segmentierung

Die eigentliche Merkmalsextraktion beginnt mit der Methode `extract`. Dort wird die Session in `SEGMENT_COUNT` gleich große Segmente (hier vier) zerlegt. Die Methode `buildSegment` übernimmt jeweils ein Segment, für das dann die dazugehörigen Merkmale berechnet werden (Listing 5.1). Die Aufteilung in gleich große Stücke hilft, den zeitlichen Verlauf innerhalb einer Session grob abzubilden. Die einzelnen Segmente werden jeweils im `SessionFeatures`-Objekt abgelegt.

```
public SessionFeatures extract(List<SampleEntity> samples) {
    SessionFeatures features = new SessionFeatures();
    features.sessionId       = samples.get(0).sessionId;
    features.sampleCount     = samples.size();
    features.durationSeconds = samples.get(samples.size() - 1)
        .sampleCounterSeconds;
    features.segments        = new ArrayList<>();

    int segLength = samples.size() / SEGMENT_COUNT;
    for (int i = 0; i < SEGMENT_COUNT; i++) {
        int start = i * segLength;
        // das letzte Segment nimmt die restlichen Samples auf
        int end   = (i == SEGMENT_COUNT - 1) ? samples.size() : start
            + segLength;
        List<SampleEntity> slice = samples.subList(start, end);
        features.segments.add(buildSegment(slice));
    }
    return features;
}
```

Listing 5.1: Zerlegung der Session in Segmente. Das letzte Segment nimmt die verbleibenden Samples auf, damit keine Messwerte verloren gehen.

Die Anzahl der Samples ist nicht immer genau durch `SEGMENT_COUNT` teilbar. Daher werden am Ende alle restlichen Samples in das letzte Segment aufgenommen. Dadurch gehen keine Messwerte verloren.

In `buildSegment` werden zunächst Start- und Endzeit aus dem jeweils ersten sowie dem letzten Sample entnommen. Diese sind später für die aufbereiteten Zeitangaben je Segment wichtig. Anschließend werden die drei Merkmale berechnet. Dazu zählen die Band-Power je Kanal als spektrales Merkmal sowie die Spannweite je Kanal und der Anteil ungültiger Messwerte als zeitstatistische Merkmale. Die gesamten Werte werden, nachdem sie in einem Segment-Objekt gesammelt wurden, an `extract` zurückgegeben.

5.2.4 Spektrale Merkmale (Welch-Methode)

Für jeden der acht EEG-Kanäle wird die Leistung in den Frequenzbändern Delta (δ), Theta (θ), Alpha (α), Beta (β) und Gamma (γ) berechnet. Das wird durch die Welch-Methode (Listing 5.2) ermöglicht. Es wird also für 50 % überlappende Fenster des Signals das Leistungsspektrum durch die FFT berechnet und dann in Bänder einsortiert. Das passiert über alle Fenster hinweg, über die anschließend gemittelt wird. Durch dieses Verfahren gibt es weniger Anfälligkeit für Schwankungen, und es bietet ein stabileres Ergebnis (Abschnitt 4.1.2).

```
private double[][] computeBandPower(List<SampleEntity> slice) {
    double[][] result = new double[CHANNELS][NUM_BANDS];
    int hop = windowSize / 2;   // 50% Ueberlappung

    for (int i = 0; i < CHANNELS; i++) {
        double[] signal = extractChannelSignal(slice, i);
        double[] bandAccum = new double[NUM_BANDS];
        int windowCount = 0;

        // nur vollstaendige Fenster, ein angebrochenes Restfenster
        // am Ende entfaellt
        for (int start = 0; start + windowSize <= signal.length;
        start += hop) {
            // Kopie des Fensters
            double[] window = Arrays.copyOfRange(signal, start, start +
            windowSize);
            // Leistung je Frequenz-Bin (windowSize / 2 Werte)
            double[] power  = powerSpectrum(window);
            // Leistung je Band (5 Werte)
            double[] bands  = sumBands(power);
            for (int b = 0; b < NUM_BANDS; b++) bandAccum[b] +=
            bands[b];
            windowCount++;
        }
        if (windowCount > 0) {
            // ueber alle Fenster mitteln (Welch)
            for (int b = 0; b < NUM_BANDS; b++) {
                result[i][b] = bandAccum[b] / windowCount;
            }
        }
    }
    return result;
}
```

Listing 5.2: Band-Power je Kanal nach dem Welch-Verfahren. Das Signal wird in überlappende Fenster zerlegt, in Bänder einsortiert und gemittelt.

Die Band-Power wird zunächst getrennt nach Kanal berechnet. Erst bei der späteren Aufbereitung für das Sprachmodell wird sie über alle acht Kanäle zusammengefasst. Der Zähler `windowCount` hält fest, wie viele vollständige Fenster je Kanal verarbeitet wurden, und dient anschließend als Teiler bei der Mittelung.

Da jedes Sample des Unicorn Hybrid Black alle acht Kanäle gleichzeitig beinhaltet, wird in der Methode `extractChannelSignal` das Signal eines einzelnen Kanals (z. B. Kanal 1) über alle Samples eines Segments gesammelt. Dadurch entsteht ein durchgehender Signalverlauf dieses Kanals, auf den dann die Fensterung angewendet wird.

Die Methode `powerSpectrum` berechnet das Leistungsspektrum eines Fensters (Listing 5.3). Als erstes wird der Mittelwert (Gleichanteil) abgezogen. Danach wird das Hann-Fenster angewendet, um anschließend die Fourier-Transformation durchzuführen. Schließlich wird die Leistung je Frequenz-Bin berechnet, indem die Real- und Imaginärteile quadriert und summiert werden.

```
private double[] powerSpectrum(double[] window) {
    // 1. Mittelwert (Gleichanteil) des Fensters berechnen
    double mean = 0;
    for (double v : window) mean += v;
    mean /= window.length;

    // 2. Mittelwert abziehen und Hann-Fenster anwenden
    double[] data = new double[windowSize];
    for (int n = 0; n < windowSize; n++) {
        data[n] = (window[n] - mean) * hann[n];
    }

    // 3. FFT mit JTransforms, rechnet in-place im selben Array
    fft.realForward(data);

    // 4. Leistung je Frequenz-Bin: gerade Indizes Realteil,
    //    ungerade Imaginaerteil
    double[] power = new double[windowSize / 2];
    power[0] = data[0] * data[0];   // DC-Bin
    for (int k = 1; k < windowSize / 2; k++) {
        double re = data[2 * k], im = data[2 * k + 1];
        power[k] = re * re + im * im;
    }
    return power;
}
```

Listing 5.3: Berechnung des Leistungsspektrums eines Fensters. Vor der Transformation werden der Gleichanteil entfernt und das Hann-Fenster angewendet.

Die eigentliche Fourier-Transformation (`fft.realForward`) wird dabei durch die Bibliothek JTransforms bereitgestellt und nicht selbst implementiert [42]. Mit ihr wird die Fourier-Transformation in der Programmiersprache Java berechnet. Dafür wird der Aufruf `realForward` verwendet, der reelle Eingangssignale entgegennimmt. Die Ergebnisse werden dann in dasselbe Array geschrieben. Die geraden Indizes enthalten die Realteile, während die ungeraden die Imaginärteile der Frequenz-Bins enthalten.

5.2.5 Zuordnung zu den Frequenzbändern

Das Spektrum liefert die Leistung je Frequenz-Bin. Diese müssen noch den Frequenzbändern zugeordnet werden (Listing 5.4). Dazu wird jeder Bin-Index über die Formel $\text{freq} = i \cdot f_s / N$ in eine Frequenz umgerechnet. Der Faktor f_s / N entspricht dabei der Frequenzauflösung Δf (Gleichung 2.2), also dem Frequenzabstand zwischen zwei benachbarten Bins. Dadurch können für jedes Frequenzband die entsprechenden Bins summiert werden.

```
private double[] sumBands(double[] power) {
    double[] bandSum = new double[NUM_BANDS];
    // ab Bin 1, der Gleichanteil (Bin 0) gehoert zu keinem Band
    for (int i = 1; i < power.length; i++) {
        // Bin-Index -> Frequenz in Hz
        double freq = (double) (i * SAMPLE_RATE) / windowSize;
        for (FrequencyBand band : FrequencyBand.values()) {
            // untere Grenze inklusive, obere exklusiv
            if (freq >= band.lowHz && freq < band.highHz) {
                bandSum[band.ordinal()] += power[i];
            }
        }
    }
    return bandSum;
}
```

Listing 5.4: Zuordnung der Frequenz-Bins zu den Bändern. Jeder Bin-Index wird in eine Frequenz umgerechnet und dem passenden Band zugeordnet.

Die Einteilung in die Frequenzbänder ist im Aufzählungstyp (`enum`) `FrequencyBand` definiert, in dem jedes Band mit seiner unteren und oberen Grenzfrequenz hinterlegt ist. Die verwendeten Grenzen entsprechen den in Tabelle 2.1 genannten Bereichen, wobei das Gamma-Band auf 45 Hz begrenzt ist.

5.2.6 Zeitstatistische Merkmale

Als erstes der zwei zeitstatistischen Merkmale wird der Peak-to-Peak-Wert berechnet. Dieser stellt die Spannweite je Kanal dar. Er beschreibt die Differenz zwischen dem höchsten und dem niedrigsten Messwert. Dadurch sind stärkere Schwankungen oder Veränderungen gegenüber der Grundlinie in den Signalen erkennbar. Der zweite zeitstatistische Wert ist der Anteil der ungültigen Samples (`valid == 0`) an der Gesamtzahl im Segment. Er dient als Maß für die Vollständigkeit der Übertragung.

Bei der Berechnung des Peak-to-Peak-Werts wird das Segment einmal durchlaufen. Dabei werden alle acht Kanäle pro Sample verglichen, und das jeweils n-mal bis zum Ende eines Segments. Es merkt sich den niedrigsten sowie den höchsten Wert und kann anhand der Differenz aus beiden Werten die Spannweite berechnen. Bei dem Anteil der ungültigen Messwerte wird jedes Sample eines Segments auf sein Gültigkeitskennzeichen geprüft. Steht dieses auf 0, wird der Zähler an ungültigen Samples erhöht. Abschließend wird der Zähler durch die Gesamtzahl aller Samples dividiert. Dadurch erhält man den relativen Anteil an ungültigen Samples.

5.2.7 Ergebnis

Alle Schritte führen dazu, dass die berechneten Merkmale in einem Objekt `SessionFeatures` gesammelt werden. Es stellt einen Datencontainer dar und enthält die Daten der Session sowie die Liste der Segmente mit ihren Merkmalen. Das Ergebnis ist anschließend die Grundlage der Aufbereitung für das Sprachmodell.

Das Objekt beinhaltet die Kennung der Session, ihre Dauer, die Anzahl der Samples sowie die Liste der Segmente. Jedes Segment besteht aus seiner Start- und Endzeit, der Band-Power der acht Kanäle in jeweils fünf Bändern, also 40 Werten je Segment, dazu den Spannweiten je Kanal, also insgesamt acht Werten, und dem Anteil ungültiger Messwerte. Die Merkmale liegen an dieser Stelle noch kanalweise und als reine Zahlenwerte vor. Erst der `FeatureFormatter` fasst sie über die Kanäle zusammen und wandelt sie in Text um.

5.2.8 Aufbereitung für das Sprachmodell

Die Klasse `FeatureFormatter` wandelt die gesamten Merkmale in ein Format um, das für das Modell verständlicher ist. Die Band-Power wird hier je Band über alle acht Kanäle summiert. Diese wird dann durch die Summe aller Bänder geteilt, sodass sich die relative Band-Power als Prozentwert ergibt (Listing 5.5). Zusätzlich werden die Peak-to-Peak-Werte der acht Kanäle je Segment verglichen, um den Kanal mit dem größten Ausschlag zu bestimmen.

```
private double[] relativeBandPower(SessionFeatures.Segment seg) {
    int channelNumber = seg.bandPower.length;
    int bandNumber    = seg.bandPower[0].length;

    double[] bandTotal = new double[bandNumber];

    // Band-Power je Band ueber alle Kanaele summieren
    for (int i = 0; i < channelNumber; i++) {
        for (int a = 0; a < bandNumber; a++) {
            bandTotal[a] += seg.bandPower[i][a];
        }
    }
    double sumAll = 0;
    for (int b = 0; b < bandNumber; b++) {
        sumAll += bandTotal[b];
    }

    double[] rel = new double[bandNumber];

    // Anteil jedes Bands an der Gesamtleistung in Prozent
    if (sumAll > 0) {
        for (int c = 0; c < bandNumber; c++) {
            rel[c] = bandTotal[c] / sumAll * 100;
        }
    }
    return rel;
}
```

Listing 5.5: Umrechnung der absoluten Band-Power in relative Anteile. Die Werte werden über alle Kanäle summiert und als Prozentanteil ausgegeben.

Die Methode `format` erzeugt schließlich diesen aufbereiteten Text, der mit der szenariospezifischen Anweisung zu einem verwendbaren Prompt kombiniert wird (Abschnitt 5.4). Der Text wird Segment für Segment aufgebaut. Er beginnt mit einer Kopfzeile, die die Dauer der Session und die Anzahl der Kanäle nennt. Danach folgt für jedes Segment ein eigener Block mit dem Zeitraum, den fünf Bandanteilen, dem Anteil ungültiger Messwerte sowie dem Kanal mit dem größten Ausschlag samt seinem Wert in Mikrovolt. Die Bandanteile werden dabei auf ganze Prozent gerundet, der Anteil ungültiger Messwerte auf eine Nachkommastelle. Diese Rundung hält den Text kurz und vermeidet eine Genauigkeit, die für die Auswertung durch das Sprachmodell keine Rolle spielt.

Im erzeugten Text sind die Segmente als Abschnitte bezeichnet. Ein Beispiel dafür zeigt Abbildung 5.3.

```
EEG-Session, Dauer 60.0s, 8 Kanäle.
Abschnitt 1 (0.0–15.0s):
    Delta 42%, Theta 18%, Alpha 21%, Beta 14%, Gamma 5%
    Ungültige Messwerte: 2.0% ungültig, größter Ausschlag Kanal 3 (128 µV)
Abschnitt 2 (15.0–30.0s):
    Delta 38%, Theta 20%, Alpha 24%, Beta 13%, Gamma 5%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 5 (96 µV)
Abschnitt 3 (30.0–45.0s):
    Delta 51%, Theta 16%, Alpha 18%, Beta 11%, Gamma 4%
    Ungültige Messwerte: 6.0% ungültig, größter Ausschlag Kanal 3 (210 µV)
Abschnitt 4 (45.0–60.0s):
    Delta 40%, Theta 19%, Alpha 22%, Beta 14%, Gamma 5%
    Ungültige Messwerte: 1.0% ungültig, größter Ausschlag Kanal 2 (105 µV)
```

Abbildung 5.3: Vom `FeatureFormatter` erzeugter Feature-Text. Je Segment stehen dort Bandanteile, ungültige Messwerte und der größte Ausschlag (Werte illustrativ).

5.3 Integration des Sprachmodells

Die Integration des Sprachmodells ist im Paket `llm` implementiert. Dort befindet sich die Klasse `LlmEngine`, die die Kommunikation mit dem Modell übernimmt. Sie hat drei Kernaufgaben: das Laden, das Anfragen und das Freigeben des Modells. Für die lokale Ausführung wird die MediaPipe LLM Inference API verwendet [17]. Sie ist als Abhängigkeit `com.google.mediapipe:tasksgenai` eingebunden. Die quantisierten Modelle Gemma 3 1B, Gemma 2 2B und Qwen 2.5 1.5B liegen als `.task`-Dateien im Verzeichnis `/data/local/tmp/llm/` auf dem Gerät, wohin sie vorab per `adb` übertragen wurden. Diese Trennung von der Anwendung ist bewusst gewählt, denn die Modelle belegen so keinen Speicher innerhalb der Anwendung. In der verwendeten 8-Bit-Quantisierung belegen die `.task`-Dateien rund 1 GB (Gemma 3 1B), 1,6 GB (Qwen 2.5 1.5B) beziehungsweise 2,6 GB (Gemma 2 2B) [29–31]. Vor der ersten Analyse müssen sie daher auf das Gerät übertragen werden. Im Folgenden wird der Lebenszyklus eines Modells in seiner Ausführungsreihenfolge beschrieben.

5.3.1 Modellauswahl und Pfade

Die jeweils verwendeten Modelle sind als konstante Pfade hinterlegt. Diese werden mithilfe der Methode `pathFor` anhand einer kurzen Kennung wie `1b`, `2b` oder `qwen` selektiert. Falls die Kennung ungültig ist, wird automatisch das kleinste Modell ausgewählt. Die Auswahl des Modells geschieht zuvor im Analyse-Dialog oder im Benchmark, wobei die Kennung an die `LlmEngine` übergeben wird.

5.3.2 Laden und Konfiguration

Das Laden des Modells besteht aus dem Konfigurieren der Optionen (Listing 5.6). Hierzu werden nach dem Builder-Muster in einem `LlmInferenceOptions`-Objekt die Pfadangabe, `maxTopK` und `maxTokens` festgelegt. Die Obergrenze der wählbaren Token wird auf 64 gesetzt. Als maximale Anzahl der Token wird 1280 festgelegt. Hierbei gelten diese Werte

über alle Modelle hinweg, um einen technisch einheitlichen Vergleich zu bieten (Kapitel 4). Nach dem Aufruf von `createFromOptions` ist das Modell schließlich einsatzbereit.

```
public void load(Context context) {
    LlmInferenceOptions options = LlmInferenceOptions.builder()
            .setModelPath(modelPath)
            // nur Obergrenze, gesampelt wird mit dem
            // Standardwert Top-K 40
            .setMaxTopK(64)
            // Kontext fuer Eingabe und Ausgabe zusammen
            .setMaxTokens(1280)
            .build();

    llm = LlmInference.createFromOptions(context, options);
}
```

Listing 5.6: Laden und Konfigurieren des Modells. Kontextgröße und Sampling-Obergrenze sind für alle Modelle identisch gesetzt.

5.3.3 Streamende Ausgabe

Die Antwort eines Modells erfolgt in einem Stream, bei dem die Token nach und nach geliefert werden (Listing 5.7). Der vom `PromptBuilder` erzeugte Prompt wird über `generateResponseAsync` an das Modell übergeben. Dabei wird jedes Teilstück über einen Callback gemeldet. So wird der Verlauf der Entstehung der Antwort in Echtzeit an die Benutzeroberfläche weitergeleitet. Gleichzeitig wird der Time-To-First-Token gemessen. Dieser wird mit der vollständigen Antwort samt Inferenzdauer zurückgegeben.

```
public void questionStreaming(String prompt, StreamCallback callback) {
    StringBuilder full = new StringBuilder();
    long start = System.nanoTime();
    // Array, damit der Wert im Lambda gesetzt werden kann
    long[] ttft = {-1};

    llm.generateResponseAsync(prompt, (partial, done) -> {
        // erstes Teilstueck -> TTFT festhalten
        if (ttft[0] < 0) {
            ttft[0] = (System.nanoTime() - start) / 1_000_000;
        }
        full.append(partial);
        // Teilstueck an die Oberflaeche weiterreichen
        callback.onChunk(partial);
        if (done) {
            long totalMs = (System.nanoTime() - start) / 1_000_000;
            callback.onDone(full.toString(), ttft[0], totalMs);
        }
    });
}
```

Listing 5.7: Streamende Ausgabe mit Messung der Latenz. Beim ersten Teilstück wird die TTFT festgehalten, am Ende zusätzlich die Inferenzdauer.

Abgesehen von der streamenden Ausgabe gibt es noch eine einfache Anfrage, die auf die vollständige Antwort wartet und sie am Stück zurückgibt. Diese Anfrage wird im Benchmark für die Aufwärmmessung genutzt, da weder eine Live-Anzeige noch die Latenzwerte benötigt werden.

5.3.4 Zählen der Token

Die `LlmEngine` stellt die Methode `tokenCount` bereit, die die Anzahl der Tokens berechnet. Diese sind für die Metriken der Evaluation wichtig. Dabei ruft `tokenCount` die Methode `sizeInTokens` der MediaPipe-Schnittstelle auf. Gezählt wird immer anhand des Tokenizers, den das jeweils verwendete Modell bereitstellt. Angewendet wird das an zwei Stellen. Der Prompt selbst ergibt die Anzahl der Eingabe-Tokens, die anschließende Ausgabe des Modells die Anzahl der Ausgabe-Tokens. Aus dieser und der Inferenzdauer werden die Tokens pro Sekunde berechnet. Der Aufruf erfolgt dabei jeweils außerhalb des Callbacks der MediaPipe-Schnittstelle.

5.3.5 Freigabe

Am Ende wird das Modell über `close` freigegeben. Dabei wird die MediaPipe-Instanz geschlossen und die Referenz zurückgesetzt. Das ist nötig, weil ein geladenes Modell mehrere Gigabyte Arbeitsspeicher belegt, der sonst bis zum Beenden der Anwendung reserviert bliebe. In der Analyse geschieht das nach dem Ende der Ausgabe, im Benchmark nach jeder Konfiguration.

5.4 Prompt-Design und iterative Optimierung

Wie schon in Abschnitt 4.3 erwähnt, besteht der Prompt aus den aufbereiteten Merkmalen mit einer szenariospezifischen Anweisung. Dieser ist für alle Modelle identisch. Die Eingabe wird hierbei als beschrifteter Text mit allen Merkmalen übergeben. So ist jeder Wert mit seiner Bezeichnung, seiner Einheit und dem zugehörigen Abschnitt im Text enthalten. Es sind keine Zuordnungen von Spalten nötig, wie sie in einer Tabelle üblich sind. Eine Tabelle würde zusätzliche Trennzeichen erfordern, die Tokens kosten würden, ohne überhaupt sinnvolle Information zusätzlich zu bieten. Der Prompt wurde in der Klasse `PromptBuilder` realisiert. Der Weg bis zum finalen Prompt war iterativ. Die erste Version enthielt je Szenario die jeweilige Aufgabe, eine Formatvorgabe ohne Begrüßung und den Hinweis, nichts zu erfinden. Diese wurde an Gemma 2 2B geprüft und in zwei Durchgängen angepasst. Als Erstes wurde der Merkmalstext geändert, danach der Prompt. Wie sich der Prompt entwickelt hat und welche Probleme dadurch verhindert wurden, wird im Folgenden aufgezeigt.

Dabei ergaben sich bei der Optimierung des Prompts Design-Vorgaben, die jeweils die direkte Antwort auf ein zuvor aufgetretenes Problem sind. Die erste betrifft die Einhaltung der verwendeten Daten. Das wird dem Modell klargestellt, da sonst wie in früheren Ausgaben Begriffe wie „Dominanzindex“ auftreten. Ebenso wird ein reines Textformat vorgegeben. Die Ausgabe des Modells soll textuelle Informationen erzeugen, weshalb Sonderzeichen und Markdown verboten werden. Zuvor entstanden Formatierungszeichen wie `**` in den Ausgaben.

Eine weitere Vorgabe ist die eindeutige Merkmalsbenennung. Der `FeatureFormatter` gibt den Anteil ungültiger Werte deshalb als „Ungültige Messwerte: X %“ aus. Zuvor hieß die

Zeile „Qualität: X %“, was das Modell fälschlich als schlechte Qualität las. Hinzu kommt die Begrenzung der Interpretation. Der Prompt untersagt falsche Interpretationen wie zum Beispiel Deutungen in Richtung medizinischer Diagnosen, die davor ein Problem dargestellt haben. Als Letztes wird gefordert, die Ausgabe kompakt zu halten. Die Antwort soll aus wenigen Sätzen bestehen, ohne Begrüßung und ohne Rückfragen.
Die Optimierung endete, sobald Gemma 2 2B als Referenzmodell die Vorgaben einhielt. Die Eingabe wird nicht an jedes Modell einzeln optimiert, sondern nur an das Referenzmodell Gemma 2 2B. Ansonsten könnten Unterschiede zwischen den Modellen verdeckt bleiben. Welche Auswirkungen dies dementsprechend hat, wird in Abschnitt 7.2 eingeordnet. Der finale Prompt wurde eingefroren und bildete unverändert die Grundlage für alle Messungen und den Benchmark. Listing 5.8 zeigt die finalen Prompts je Szenario.

```
// Szenario 1: lesbarer Session-Bericht aus den Messwerten
public String buildReport(String featureText) {
    return "Fasse die folgenden EEG-Messwerte in 3 bis 4 Saetzen
        sachlich zusammen. "
         + "Schreibe nur den Bericht: keine Begruessung, keine
             Rueckfragen, kein Schlusssatz. "
         + "Schreibe reinen Fliesstext ohne Sonderzeichen (kein
             Markdown). "
         + "Nenne das dominante Frequenzband, die Signalqualitaet und
             auffaellige Ausschlaege. "
         + "Erfinde nichts und nutze nur die folgenden Werte:\n\n"
         + featureText;
}
// Szenario 2: auffaellige Muster / moegliche Artefakte erklaeren
public String buildArtefaktErklaerung(String featureText) {
    return "Analysiere die folgenden EEG-Messwerte und beziehe dich
        konkret auf die genannten Werte. "
         + "Benenne die auffaelligsten Punkte dieser Session (z. B.
             sehr hohe Ausschlaege, "
         + "ungueltige Daten oder ein stark dominantes Band) und
             erklaere kurz ihre moegliche "
         + "technische Ursache (z. B. Bewegung, Elektroden, Verbindung
             ). Stelle keine "
         + "medizinischen Diagnosen. Schreibe wenige Saetze als
             sachlichen Fliesstext, ohne "
         + "Begruessung und ohne Sonderzeichen (kein Markdown).
             Erfinde nichts und nutze nur "
         + "die folgenden Werte:\n\n"
         + featureText;
}
// Szenario 3: zwei Sessions vergleichen
public String buildVergleich(String featureTextA, String featureTextB)
     {
    return "Vergleiche die folgenden zwei EEG-Sessions und beschreibe
        die wichtigsten "
         + "Unterschiede in einfachen Worten (z. B. Banddominanz,
             Signalqualitaet, Ausschlaege). "
         + "Schreibe sachlichen Fliesstext ohne Sonderzeichen (kein
             Markdown). Erfinde keine "
         + "Kennzahlen oder Begriffe. Schreibe nur den Vergleich,
             keine Begruessung. "
         + "Nutze nur die folgenden Werte.\n\n"
         + "Session A:\n" + featureTextA
         + "\n\nSession B:\n" + featureTextB;
}
```

Listing 5.8: Aufbau der Prompts je Szenario in der finalen, eingefrorenen Fassung. Alle drei enden mit dem aufbereiteten Merkmalstext.

Je nachdem, welche Sprache in den App-Einstellungen ausgewählt wurde, werden die Ausgaben in Deutsch oder Englisch erzeugt. Die Übersetzung funktioniert anhand überladener Methoden im `PromptBuilder`, die die bestehenden Methoden aufrufen und im Falle der englischen Sprache einen entsprechenden Zusatz an den Prompt anhängen.

5.5 Benutzeroberfläche

Für die Benutzeroberfläche werden zwei verschiedene Arten verwendet. Zum einen eine Activity, die das Fenster bereitstellt, in dem die Anwendung ihre Oberfläche zeichnet und das in der Regel den gesamten Bildschirm ausfüllt [16]. Zum anderen ein Dialog, also ein kleines Fenster, das den Bildschirm nicht ausfüllt und eine Entscheidung oder eine Eingabe des Nutzers verlangt [14]. Als Grundlage für das Auslösen der neuen Funktionen dient die `SessionDetailActivity`, die es schon in der ursprünglichen Anwendung gab (Abbildung 5.4). Hinzugekommen sind zwei neue Knöpfe. Die Benutzeroberfläche, die für die KI-Analyse zuständig ist, befindet sich im Paket analyse. Die Oberfläche startet mit dem Auslösen des Analyseknopfes. Daraufhin erfolgt ein Dialog zum Einstellen der Parameter und anschließend die Anzeige der Ergebnisse. Zudem gibt es einen Benchmark-Knopf, der über einen weiteren Dialog die automatisierte Messreihe startet.

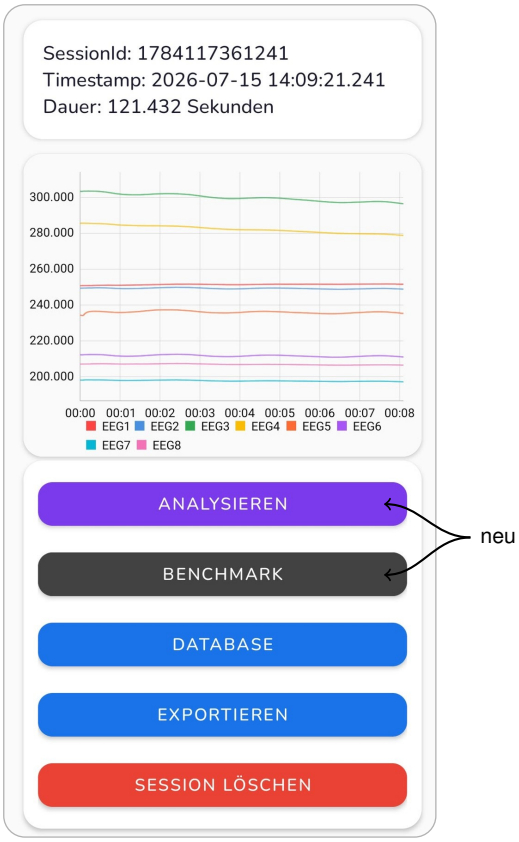


Abbildung 5.4: Session-Detailansicht als Einstieg in die neuen Funktionen. Die markierten Knöpfe starten die KI-Analyse und die automatisierte Messreihe.

5.5.1 Analyse-Dialog

Nachdem man auf „Analysieren“ drückt, öffnet sich ein Dialog, also ein kompaktes Fenster auf derselben Oberfläche, in dem der Nutzer die Parameter der Analyse festlegen kann. Dazu zählen die Szenarien (Report, Artefakt-Erklärung oder Vergleich) sowie die Sprachmodelle (Gemma 3 1B, Gemma 2 2B oder Qwen 2.5 1.5B). Für Entwickler gibt es unten im Dialog weitere Optionen. So lassen sich die Fenstergröße einstellen und über einen Schalter Messmetriken aktivieren. Wird das Szenario Vergleich gewählt, kann eine zusätzliche Session ausgewählt werden, die als Vergleich herangezogen wird. Der Dialog ist in der Klasse `AnalyseDialog` implementiert und in Abbildung 5.5 dargestellt. Nachdem der Start-Knopf betätigt wird, werden die ausgewählten Parameter als Intent-Extras an die Klasse `AnalyseErgebnisActivity` übergeben, in der die Analyse beginnt.

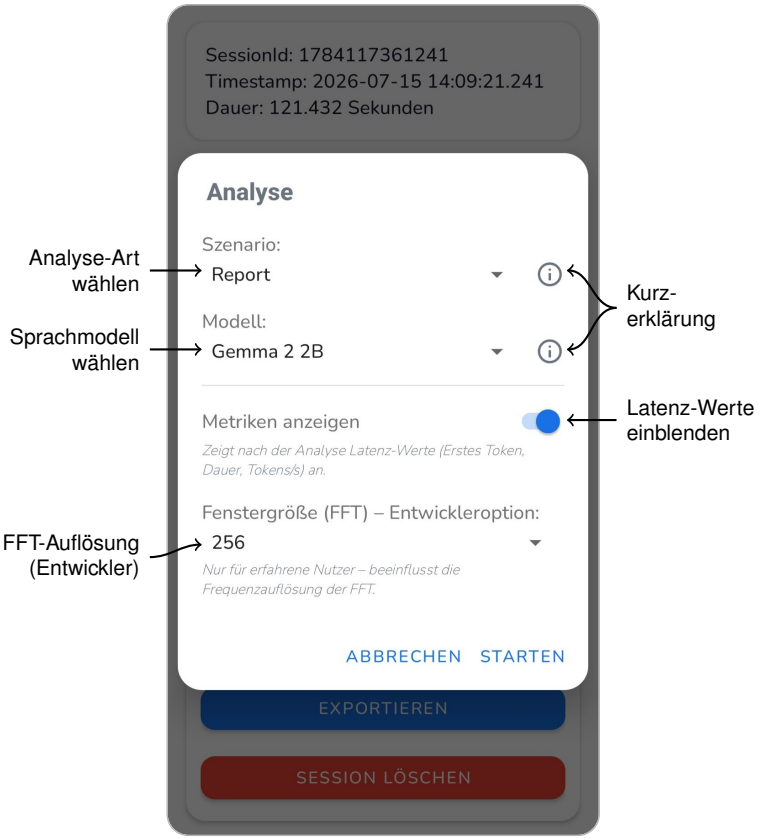


Abbildung 5.5: Analyse-Dialog zur Auswahl der Parameter. Neben Szenario und Sprachmodell stehen unten die Entwickleroptionen für Fenstergröße und Metriken.

5.5.2 Ergebnis-Ansicht

Die Logik der Ergebnis-Ansicht befindet sich in der Klasse `AnalyseErgebnisActivity`. Anhand der ausgewählten Parameter wird zunächst die gesamte Eingabe erstellt. Diese wird dann über die in Abschnitt 5.3 beschriebene `LlmEngine` an das Sprachmodell übergeben. Da die Ausgabe streamend verläuft, ist als Callback ein Interface `LlmEngine.StreamCallback` implementiert (Listing 5.9). Dort befinden sich die Methoden `onChunk` und `onDone`. Für die Anzeige der Ausgabe ist die Methode `onChunk` zuständig. Diese sorgt für die fortlaufende Aktualisierung der Antwort vom Modell an die Ergebnis-Ansicht. Mit `onDone` wird das Ende der Ausgabe signalisiert, sodass die Metriken nachträglich angezeigt werden können.

```
@Override
public void onChunk(String partial) {
    runOnUiThread(() -> {
        // Ladeanzeige ausblenden
        progressBar.setVisibility(View.GONE);
        // Text live anhaengen statt ersetzen
        tvReport.append(partial);
    });
}
```

Listing 5.9: Live-Anzeige der streamenden Ausgabe. Jedes Teilstück wird angehängt statt gesetzt, damit der Text während der Erzeugung wächst.

Ein Modell kann mehrere Gigabyte groß sein, weshalb die Analyse in einem eigenen Thread läuft. Ansonsten könnte das Laden die Oberfläche blockieren. Änderungen an der Benutzeroberfläche können in Android nur im Haupt-Thread erfolgen, weshalb dafür `runOnUiThread` verwendet wird. Falls beim Vorbereiten der Daten oder beim Laden des Modells ein Fehler auftreten sollte, wird eine dementsprechende Fehlermeldung im Textbereich angezeigt, sodass kein Absturz erfolgt.

Die Ergebnis-Ansicht (Abbildung 5.6) zeigt als Erstes eine Ladeanimation an. Währenddessen wird das Modell geladen. Sobald die Ausgabe beginnt, wächst der Text aufgrund der Streaming-Mechanik nach und nach. Ganz oben ist sichtbar, welches Modell und Szenario ausgewählt wurde. Wenn der Metrik-Schalter im Dialog aktiviert wird, sind zusätzlich die Latenz-Werte (erstes Token, Dauer und Tokens pro Sekunde) sichtbar. Sobald die Ausgabe vollständig ist, erscheint unten rechts ein Knopf zum Teilen der Analyse.

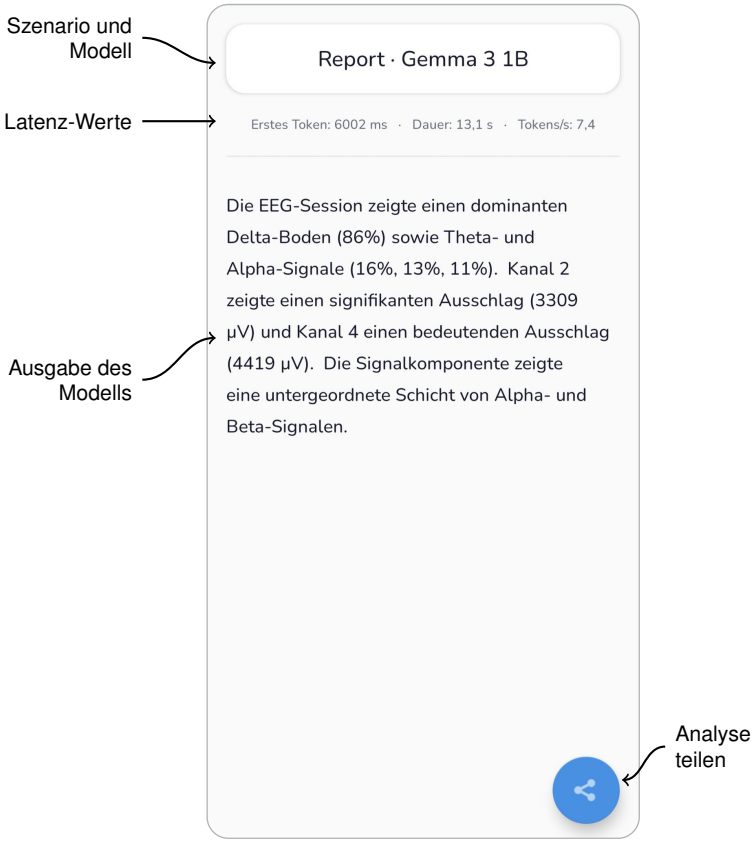


Abbildung 5.6: Ergebnis-Ansicht der KI-Analyse. Oben stehen Szenario, Modell und die optionalen Latenzwerte, darunter wächst die Ausgabe während der Erzeugung.

Mit dem Knopf kann man die Ausgabe als .txt-Datei teilen. Für diese Funktion wird ein `FileProvider` verwendet, der in der bestehenden Anwendung bereits für den Export der Messdaten eingerichtet ist. Beim Scrollen wird die Deckkraft des Knopfes auf 30 % reduziert, damit der Nutzer den kompletten Text unverdeckt lesen kann. Nach einer Sekunde ohne weitere Scrollbewegung erlischt der Effekt und die Deckkraft steigt wieder auf das Maximum.

Zusätzlich wird geprüft, ob eine Aufnahme die Mindestlänge erfüllt und die Schwelle der ungültigen Samples nicht überschreitet. Ist dies nicht der Fall, wird die Analyse abgebrochen und eine entsprechende Meldung angezeigt (Abschnitt 5.2).

5.5.3 Benchmark-Dialog

Neben dem Analyse-Knopf gibt es in derselben Ansicht noch einen Benchmark-Knopf, über den man die automatisierte Messreihe starten kann. Auch dort startet zuvor ein Dialog (Abbildung 5.7), mit dem man für das Vergleichsszenario eine Session auswählen muss.

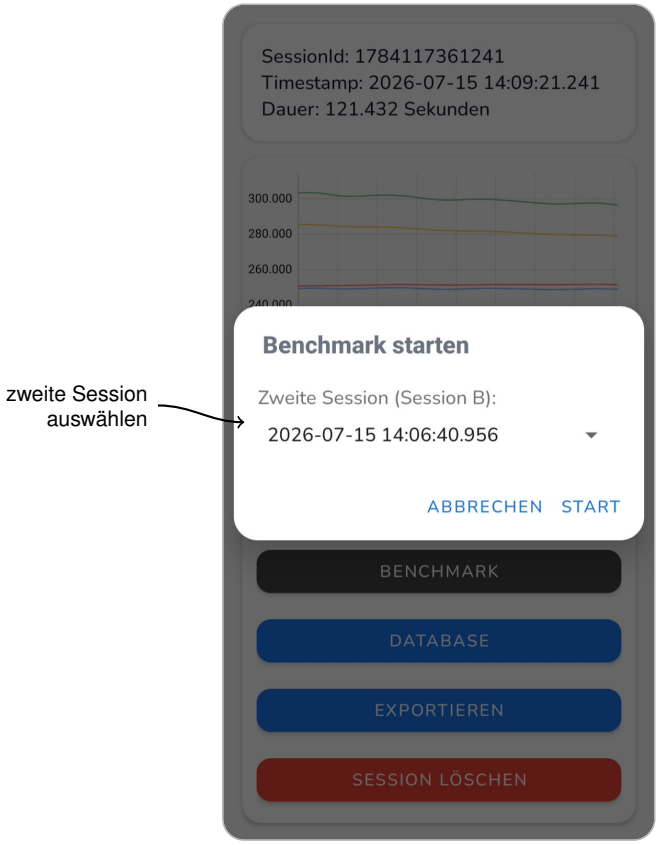


Abbildung 5.7: Benchmark-Dialog vor dem Start der Messreihe. Hier wird die zweite Session festgelegt, die im Vergleichsszenario genutzt wird.

Zuständig für den Benchmark-Dialog ist die Methode `showBenchmarkDialog`. Diese ist in keiner eigenen Klasse, sondern in `SessionDetailActivity`, die schon zur bestehenden Anwendung gehört. Die restliche Benchmark-Logik ist in Abschnitt 5.6 beschrieben.

5.6 Benchmark

Die gesamte Logik des Benchmarks befindet sich im Paket `benchmark`. Von dort aus werden alle Messungen, die in Abschnitt 4.4 definiert sind, automatisiert durchgeführt. Dabei werden alle Kombinationen durchlaufen und in die CSV-Datei geschrieben. Die Implementierung wird in drei Klassen aufgeteilt: `BenchmarkRunner` steuert den Ablauf, `Metrics` liefert die Messwerte für Speicher und Akku, und `BenchmarkLogger` schreibt die Ergebnisse. Den Start bildet der Benchmark-Button in der Session-Detailansicht. Dieser Ablauf ist in Abbildung 5.8 dargestellt.

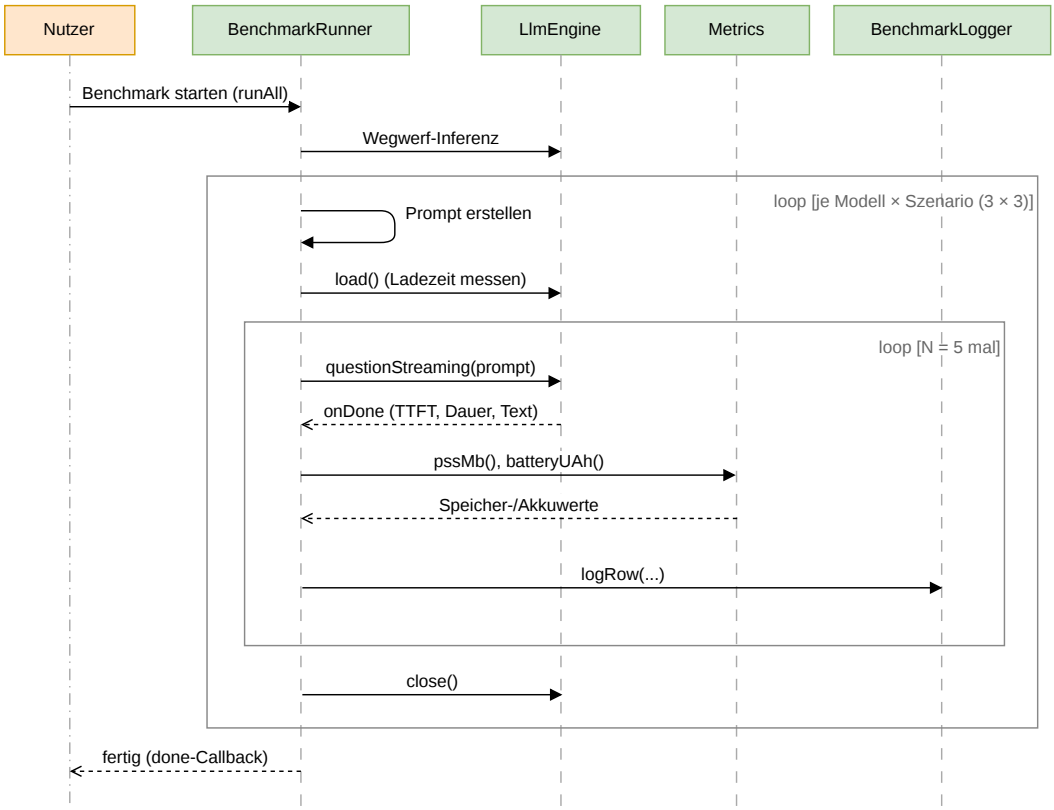


Abbildung 5.8: Sequenzdiagramm des Benchmark-Ablaufs. Es zeigt das Zusammenspiel von Steuerung, Messwerterfassung und Protokollierung (erstellt mit draw.io).

Die einzelnen Schritte dieses Ablaufs werden in den folgenden Abschnitten anhand des Codes näher erläutert.

5.6.1 Ablauf

Der Hintergrund-Thread `runAll` ist für den gesamten Messlauf verantwortlich (Listing 5.10). Dieser sorgt dafür, dass die Oberfläche nicht blockiert wird. Zum Start wird eine einzelne Wegwerf-Messung durchgeführt, um einen Kaltstart zu vermeiden. Danach startet die eigentliche Messung über alle Kombinationen. Ist der gesamte Lauf beendet, wird der übergebene `done`-Callback aufgerufen, über den die Oberfläche informiert wird.

```
public void runAll(long sessionA, long sessionB, int numberConfig,
Runnable done) {
    new Thread(() -> {
        String[] modelle   = {"1b", "2b", "qwen"};
        String[] szenarien = {"report", "artefakt", "vergleich"};

        // Aufwaermphase: Wegwerf-Inferenz gegen Kaltstart-Effekte,
        // wird nicht gespeichert
        try {
            LlmEngine warm = new LlmEngine(LlmEngine.
            pathFor(modelle[0]));
            warm.load(context);
            warm.question("Test");
            warm.close();
        } catch (Exception ignored) {}

        for (String modell : modelle) {
            for (String szenario : szenarien) {
                runConfig(modell, szenario, sessionA, sessionB,
                numberConfig);
            }
        }
        // Oberflaeche ueber das Ende der Messreihe informieren
        if (done != null) done.run();
    }).start();
}
```

Listing 5.10: Ablauf des Benchmarks mit Aufwaermphase. Vor der eigentlichen Messreihe wird eine Wegwerf-Inferenz ausgefuehrt.

5.6.2 Messung je Konfiguration

Für jede Kombination wird `runConfig` einmal aufgerufen. Dabei wird das Modell geladen und die Ladezeit gemessen, bevor dieselbe Anfrage n = 5 mal wiederholt wird. `questionStreaming` ist für die asynchrone Verarbeitung zuständig. Diese wird mithilfe eines `CountDownLatch` synchronisiert, der das Warten bei jeder Wiederholung übernimmt. Die Schleife wartet bei `await`, bis der `onDone`-Callback per `countDown` das Ende der Inferenz meldet. Erst danach werden die Speicher- und Akkuwerte ausgelesen und als eine Zeile gespeichert. Bei einem Fehler wird dies in der CSV-Datei gekennzeichnet.

Die Prompts werden immer vor der Wiederholungsschleife erzeugt. Das Modell wird einmal geladen und dabei die Ladezeit sowie die Anzahl der Eingabe-Tokens bestimmt. Daher bleiben beide Werte innerhalb einer Kombination aus Szenario und Modell über alle fünf Messungen identisch. Der Benchmark verwendet dabei immer die Standardfenstergröße von 256 Samples, unabhängig davon, was im Analyse-Dialog eingestellt ist.

Die beschriebene Wiederholung mit der Synchronisation über den `CountDownLatch` ist in Listing 5.11 dargestellt.

```
for (int i = 0; i < nc; i++) {
    // Arrays, damit der Callback die Werte setzen kann
    long[]   ttftHolder  = {0};
    long[]   totalHolder = {0};
    String[] textHolder  = {""};
    CountDownLatch latch = new CountDownLatch(1);

    engine.questionStreaming(prompt, new LlmEngine.StreamCallback() {
        @Override public void onChunk(String partial) {
            /* im Benchmark nicht benoetigt */ }
        @Override public void onDone(String fullText, long ttftMs,
        long totalMs) {
            ttftHolder[0]  = ttftMs;
            totalHolder[0] = totalMs;
            textHolder[0]  = fullText;
            latch.countDown();          // Riegel oeffnen
        }
    });

    latch.await();                 // Schleife wartet, bis onDone kam

    long inferMs = totalHolder[0];
    long ttftMs  = ttftHolder[0];
    int outputTokens = engine.tokenCount(textHolder[0]);
    double tokensPerSec = outputTokens / (inferMs / 1000.0);

    // Speicher und Akku erst nach der Inferenz auslesen
    long pssMb   = Metrics.pssMb();
    long battUAh = Metrics.batteryUAh(context);
    int  battPct = Metrics.batteryPct(context);

    logger.logRow(modell, szenario, promptTokens, outputTokens,
                  loadMs, inferMs, ttftMs, tokensPerSec,
                  pssMb, battUAh, battPct, "ok");
}
```

Listing 5.11: Wiederholte Messung mit Synchronisation ueber CountDownLatch. Die Schleife wartet, bis die asynchrone Ausgabe abgeschlossen ist.

5.6.3 Erfassung der Ressourcen

Die Klasse `Metrics` ist eine Hilfsklasse, die die Speicher- und Akkuwerte liefert. Der Speicherverbrauch wird als PSS über `Debug.MemoryInfo` ausgelesen und von Kilobyte in Megabyte umgerechnet. Über den `BatteryManager` wird der aktuelle Ladezustand des Akkus in Prozent und Mikroamperestunden (µAh) ermittelt.

Der Speicherwert wird für den gesamten Prozess der Anwendung ermittelt. Dazu zählt nicht nur das geladene Modell selbst, sondern auch der übrige Speicherbedarf der App. Der Akkuwert beschreibt zudem den momentanen Akkuzustand und nicht den Verbrauch selbst. Dieser ergibt sich schließlich aus der Differenz zweier Akkuwerte über eine Messreihe hinweg (Abschnitt 4.4.1).

5.6.4 Protokollierung

Die Klasse `BenchmarkLogger` schreibt die Ergebnisse in die Datei `benchmark.csv`. Ist die Datei schon vorhanden, wird die bestehende gelöscht und eine neue erstellt. Sie enthält eine Kopfzeile mit allen Metriken und darunter die einzelnen Zeilen, die jeweils eine Messung darstellen. Die so entstehende CSV bildet die Datengrundlage für die Evaluation (Kapitel 6). Jede Zeile enthält einen Zeitstempel, das Modell, das Szenario, die Anzahl der

Eingabe- und Ausgabe-Tokens, die Ladezeit, die Inferenzdauer, die TTFT, die Tokens pro Sekunde, den Speicherwert sowie die Akkuwerte in Mikroamperestunden und Prozent. Abgeschlossen wird sie durch den Status der Messung.

6 Evaluation

Dieses Kapitel präsentiert die Durchführung (Abschnitt 4.4.2) sowie die Ergebnisse der Metriken (Abschnitt 4.4.1), um zu beurteilen, inwiefern sich die lokalen Modelle für die Verarbeitung von EEG-Daten eignen.

6.1 Durchführung der Messungen

Wie schon in Abschnitt 4.4 beschrieben, wird die Eingabe für alle Modelle identisch gehalten. Insgesamt werden so alle neun Kombinationen aus drei Modellen und drei Szenarien auf dem Samsung Galaxy S23 vermessen und anschließend in einer neu erstellten CSV-Datei protokolliert. Dies geschieht je fünfmal, wobei die erste Messung jeder Kombination verworfen wird, da sie durch das Initialisieren des Modells länger ausfallen kann. In den Rohdaten ist dieser Effekt bei einzelnen Kombinationen deutlich sichtbar, in anderen tritt er dagegen nicht auf. Ein Beispiel ist Gemma 3 1B, denn dort unterscheidet sich im Report-Szenario die Inferenzdauer bei der ersten Messung mit 13,1 s gegenüber 6,7 s in den folgenden vier Läufen. In die Mittelwerte fließen je Kombination die verbleibenden vier Messungen ein. Die rohen Messwerte liegen vollständig in Tabelle B.1. Vor der ersten Messung wird ein Aufwärmlauf durchgeführt. Als Eingabe für das Modell werden zwei Sessions verwendet. Beide sind beim Tragen des Unicorn-Hybrid-Headsets durch den Verfasser entstanden und haben eine Laufzeit von knapp über 120 Sekunden. Im Report- und Artefakt-Szenario wird allein Session A übergeben (Abbildung A.1), im Vergleichsszenario zusätzlich Session B (Abbildung A.2).

6.2 Latenz

Im Folgenden werden die Ergebnisse der Latenzmessungen vorgestellt.

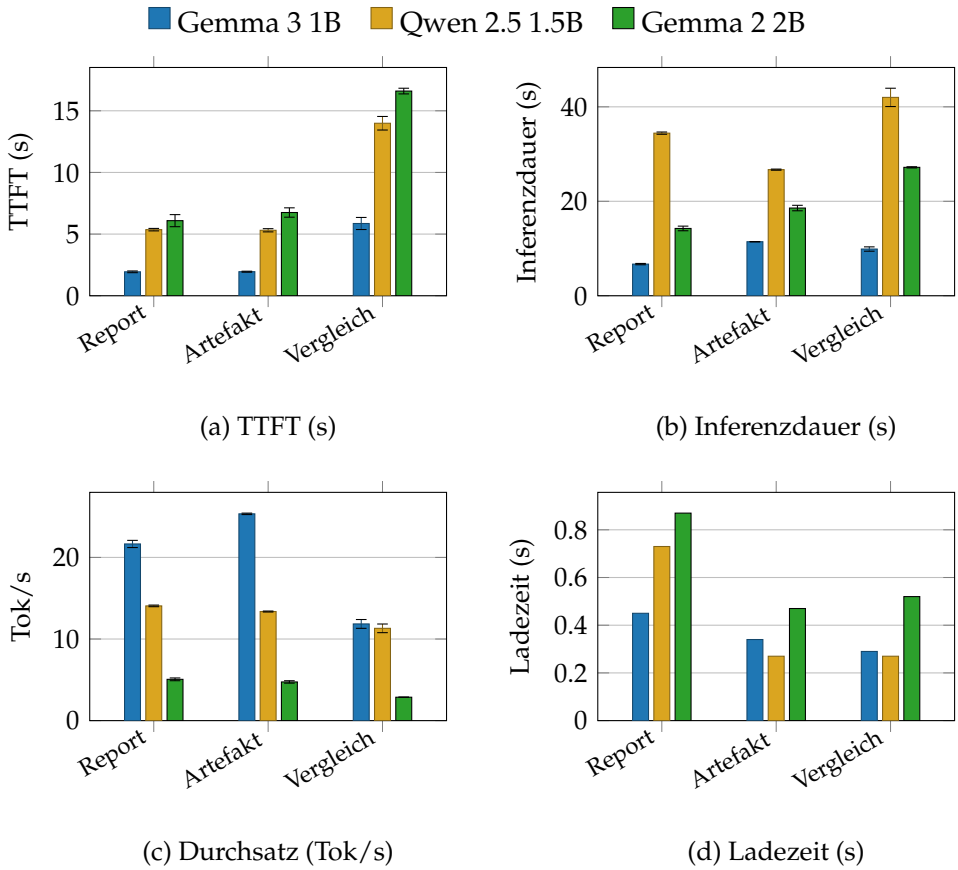
Tabelle 6.1: Latenzmetriken je Modell und Szenario (Mittel aus vier Wiederholungen ± Standardabweichung; die Ladezeit wird je Konfiguration einmalig gemessen).

Modell	Szenario	Ladezeit (s)	TTFT (s)	Inferenzdauer (s)	Tok/s
Gemma 3 1B	Report	0,45	1,94 ± 0,07	6,70 ± 0,14	21,65 ± 0,44
	Artefakt	0,34	1,95 ± 0,04	11,44 ± 0,04	25,34 ± 0,09
	Vergleich	0,29	5,86 ± 0,49	9,89 ± 0,46	11,85 ± 0,54
Qwen 2.5 1.5B	Report	0,73	5,36 ± 0,10	34,43 ± 0,24	14,06 ± 0,10
	Artefakt	0,27	5,31 ± 0,13	26,70 ± 0,12	13,37 ± 0,06
	Vergleich	0,27	13,99 ± 0,55	42,00 ± 1,94	11,31 ± 0,53
Gemma 2 2B	Report	0,87	6,09 ± 0,49	14,25 ± 0,49	5,06 ± 0,17
	Artefakt	0,47	6,75 ± 0,38	18,57 ± 0,58	4,74 ± 0,15
	Vergleich	0,52	16,60 ± 0,23	27,19 ± 0,13	2,87 ± 0,01

Tabelle 6.1 zeigt, dass der **Durchsatz (Tok/s)** bei dem Modell Gemma 3 1B am höchsten ist (bis zu 25,34 Tok/s), während das Modell Gemma 2 2B den geringsten Durchsatz aufweist (minimal 2,87 Tok/s). Der Durchsatz ist dabei im Vergleichsszenario über alle Modelle hinweg am geringsten. Die **Ladezeit** ist bei Gemma 2 2B am höchsten; die beiden kleineren Modelle Gemma 3 1B und Qwen 2.5 1.5B laden schneller. Sie liegt durchweg unter einer Sekunde (zwischen 0,27 und 0,87 s). Die **TTFT** ist bei Gemma 3 1B am geringsten, während sie bei Gemma 2 2B am höchsten ist. Mit Ausnahme von Qwen 2.5 1.5B/Artefakt steigt die TTFT mit dem Szenarioniveau an und erreicht ihren Höchstwert bei Gemma 2 2B mit 16,60 s. Die **Inferenzdauer** reicht von 6,70 bis 42,00 s und variiert stark zwischen den Modellen und Szenarien.

Die **Standardabweichungen** fallen überwiegend gering aus. Von den 27 erfassten Werten liegt bei 26 eine Streuung von unter eins vor, was auf eine stabile Messung hinweist. Lediglich bei Qwen 2.5 1.5B/Vergleich ist die Standardabweichung mit 1,94 s (Inferenzdauer) deutlich höher als bei allen anderen Messungen. Beobachten lässt sich, dass die Modelle bei identischer Eingabe dieselbe Ausgabe liefern. Der Inhalt bleibt gleich, ebenso die Anzahl der Tokens (Tabelle B.1). Die verbleibende Streuung geht dementsprechend auf die Messumgebung zurück und nicht auf unterschiedlich lange Antworten.

Zur besseren Vergleichbarkeit sind die Latenzmetriken in Abbildung 6.1 zusätzlich grafisch dargestellt.



(a) TTFT (s)

(b) Inferenzdauer (s)

(c) Durchsatz (Tok/s)

(d) Ladezeit (s)

Abbildung 6.1: Latenzmetriken je Modell und Szenario (Fehlerbalken: Standardabweichung aus vier Wiederholungen; Ladezeit ohne Fehlerbalken, da je Konfiguration einmalig gemessen).

Die TTFT kann im Allgemeinen von der Länge der Eingabe abhängen. Wie schon in Abschnitt 4.4.2 beschrieben, kann sich die Anzahl der Eingabe-Tokens trotz gleicher Promptlänge je Modell aufgrund der verschiedenen verwendeten Tokenizer unterscheiden. Tabelle 6.2 stellt diese Werte dar.

Tabelle 6.2: Anzahl der Eingabe-Tokens je Modell und Szenario. Die Werte stammen aus dem Tokenizer des Modells und fallen trotz gleichem Prompt unterschiedlich aus.

Modell	**Report**	**Artefakt**	**Vergleich**
Gemma 3 1B	417	446	740
Qwen 2.5 1.5B	439	482	770
Gemma 2 2B	415	444	736

Die Eingabe-Tokens fallen im Vergleichsszenario über alle Modelle hinweg am größten aus. Zudem zerlegt Qwen den Prompt über alle Szenarien hinweg in die meisten Tokens.

6.3 Ressourcenverbrauch

Darauffolgend werden die Ergebnisse der Messungen zum Ressourcenverbrauch vorgestellt.

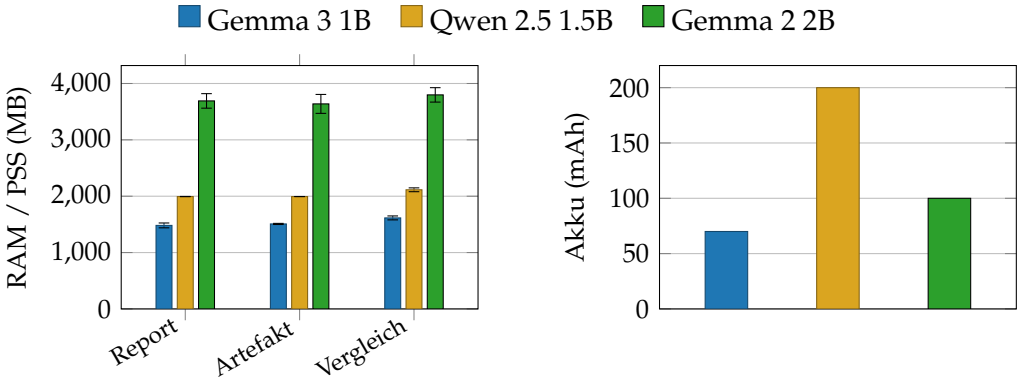
Tabelle 6.3: Ressourcenverbrauch je Modell (RAM als Mittel $\pm$ Standardabweichung).

Modell	**Szenario**	**RAM / PSS (MB)**	**Akku (mAh)***
Gemma 3 1B	Report	1482 ± 43	~70
	Artefakt	1508 ± 10	
	Vergleich	1615 ± 35	
Qwen 2.5 1.5B	Report	1994 ± 2	~200
	Artefakt	1994 ± 1	
	Vergleich	2114 ± 34	
Gemma 2 2B	Report	3691 ± 129	~100
	Artefakt	3638 ± 168	
	Vergleich	3798 ± 128	

*Verbrauch über den gesamten Messblock (15 Läufe) des jeweiligen Modells.

Tabelle 6.3 zeigt, dass der **RAM (PSS)** eine klare Rangfolge zwischen den Modellen besitzt. Während Gemma 3 1B mit 1482 MB den geringsten Wert aufweist, liegt Qwen in der Mitte (ca. 2000 MB) und Gemma 2 2B am höchsten (3798 MB). Gemma 3 1B liegt beim Punkt **Akkuverbrauch** mit ca. 70 mAh vorne, dagegen liegen Qwen 2.5 1.5B mit ca. 200 mAh und Gemma 2 2B mit ca. 100 mAh deutlich höher, wobei Qwen sogar über dem 2B-Modell liegt. Auffällig ist, dass das Modell Qwen am meisten Akku verbraucht. Über die gesamte Messreihe fällt die Restladung von rund 2234 mAh auf 1830 mAh, was einem Gesamtverbrauch von rund 404 mAh in gut 16 Minuten entspricht (Tabelle B.1).

Der Ressourcenverbrauch ist in Abbildung 6.2 zusätzlich grafisch dargestellt.



(a) RAM / PSS (MB)

(b) Akku (mAh)

Abbildung 6.2: Ressourcenverbrauch je Modell (RAM/PSS mit Fehlerbalken als Standardabweichung; Akku als Näherungswert über den gesamten Messblock von 15 Läufen, daher ein Wert je Modell).

6.4 Stabilität

Alle 45 Messungen wurden mit dem Status „ok“ protokolliert. Das bedeutet, dass in keinem der Läufe eine Ausnahme auftrat, die der Benchmark abgefangen und in der CSV als Fehler vermerkt hätte (Abschnitt 5.6). Zusätzlich fehlt keine der 45 Zeilen in der Datei, was bei einem vorzeitigen Abbruch eines Durchlaufs der Fall wäre. Ein Absturz der Anwendung, eine Meldung über fehlenden Arbeitsspeicher oder ein Einfrieren der Oberfläche traten während der Messungen nicht auf. Das größere Modell Gemma 2 2B läuft ebenso stabil, obwohl es mit ca. 3798 MB den meisten RAM verbraucht.

6.5 Ausgabequalität

Die Ausgaben werden anhand der in Abschnitt 4.4.1 definierten Kriterien bewertet. Dies geschieht anhand mehrerer Beispiele. Da alle drei Modelle denselben Prompt (Abschnitt 5.4) verwenden, ist es möglich, die Qualität der Ausgaben direkt miteinander zu vergleichen.

Für die Bewertung wird eine artefaktbehaftete Session verwendet, die eine Delta-Dominanz aufweist. Der Fokus liegt auf dem Report-Szenario für alle drei Modelle, bei dem sie im Detail betrachtet werden. Anschließend werden die anspruchsvolleren Szenarien Artefakt-Erklärung und Vergleich zusammengefasst. Dadurch ist erkennbar, wie die Modelle mit steigenden Anforderungen umgehen.

Die an die Modelle übergebenen Feature-Texte beider Sessions sind in Abbildung A.1 und Abbildung A.2 im Anhang abgedruckt und ermöglichen den Abgleich der Ausgaben mit der tatsächlichen Eingabe.

> Das dominante Frequenzband war Delta, dessen Anteil in allen Abschnitten zwischen 56 % und 86 % lag. Die Signalqualität der Messungen war in allen Abschnitten gut. Auffällig waren Ausschlagsignale in den Abschnitten 1 und 4, wobei Kanal 4 und Kanal 2 jeweils die höchsten Werte erreichte.

Abbildung 6.3: Report-Szenario: unveränderte Ausgabe von Gemma 2 2B. Genannt werden das dominante Band, die Signalqualität und die auffälligen Kanäle.

Die Ausgabe von Gemma 2 2B (Abbildung 6.3) erkennt die Delta-Dominanz korrekt, bewertet die Signalqualität zutreffend und nennt die auffälligen Kanäle. Sie ist knapp und hält das Format ein. Alle vier Kriterien sind erfüllt.

> Die EEG-Session verzeichnete eine Konzentration von Delta-Zuständen (86 %), Theta-Zuständen (16 %), Alpha-Zuständen (13 %), Beta-Zuständen (6 %) und Gamma-Zuständen (5 %). Der größte Ausschlag wurde am Kanal 2 (3309 µV) festgestellt. Der Schwerpunkt lag hauptsächlich in den Sekundenbereichen 0–30, 30–60 und 60–91 Sekunden, wobei Delta- und Theta-Zustände am stärksten ausgeprägt waren. Es gab einige ungültige Messwerte, darunter ein signifikanter Ausschlag am Kanal 2.

Abbildung 6.4: Report-Szenario: unveränderte Ausgabe von Gemma 3 1B. Die aufgeführten Bandanteile summieren sich auf über 100 %.

Bei der Ausgabe von Gemma 3 1B (Abbildung 6.4) gibt es trotz übereinstimmender Delta-Dominanz einen logischen Fehler. Die erwähnten Bandanteile summieren sich auf über 100 %, da Werte verschiedener Segmente vermischt werden. Außerdem wird behauptet, dass es einen Anteil ungültiger Werte gibt, obwohl keine vorliegen. Korrektheit und Halluzinationsfreiheit sind daher nur eingeschränkt erfüllt.

> ### Bericht
> Die EEG-Messungen umfassen die Zeitraum von 0.0 s bis 121.432 s und wurden auf 8 KanÃ¤len gezählt. Die Signalqualität ist gut mit einer overall Signalqualität von 86 %. [. . .] Die dominante Frequenzbänder sind Delta (16 %), Theta (33 %), Alpha (60 %), Beta (15 %) und Gamma (13 %), wobei Delta und Theta die hauptsächlichste Frequenz bilden. [. . .]

Abbildung 6.5: Report-Szenario: unveränderte, gekürzte Ausgabe von Qwen 2.5 1.5B. Die Ausgabe enthält Formatierungszeichen und fehlerhaft kodierte Umlaute.

Bei der Ausgabe von Qwen 2.5 1.5B (Abbildung 6.5) treten mehrere Fehler auf. Vor allem die Formatvorgabe wird deutlich verletzt. Zunächst beginnt die Ausgabe mit einer Markdown-Überschrift (###), darüber hinaus enthält die Ausgabe fehlerhaft kodierte Umlaute wie „KanÃ¤len“ und ist zu lang. Zudem sind die Bandanteile falsch (Alpha mit 60 % als stärkstes Band, Summe über 100 %) und die Signalqualität ist frei erfunden. Keines der vier Kriterien wird in diesem Fall zuverlässig erfüllt.

Diese Erkenntnisse lassen sich auch in den anspruchsvolleren Szenarien beobachten. Obwohl Gemma 2 2B in der Artefakt-Erklärung korrekte technische Ursachen wie Bewegung, Elektroden oder Verbindung benennt, wird am Ende eine falsche Schlussfolgerung gezogen („das hohe Delta-Niveau stellt sicher, dass die Daten präzise sind“). Bei Gemma 3 1B werden neue Fachbegriffe wie „Delta-/Theta-/Gamma-Zell-Schwellenwert“ erfunden und weiterhin ungültige Messwerte behauptet. Qwen 2.5 1.5B liefert eine sehr schwache

Ausgabe, bei der die Bandzuordnungen widersprüchlich sind und Begriffe wie „Ungültiger Messergegenstand“ erfunden werden. Zudem treten hier wieder Formatierungsfehler auf. Gemma 2 2B vergleicht im Vergleich-Szenario die zwei Sessions sauber, bezeichnet die Ausschläge jedoch fälschlicherweise als zu gering, obwohl Werte über 4000 µV auftreten. Gemma 3 1B widerspricht sich selbst, indem beiden Sessions zugleich der größere Ausschlag an Kanal 2 zugeschrieben wird. Qwen 2.5 1.5B schneidet erneut schlecht ab. Es halluziniert mit Begriffen wie „Abgassen“ statt Frequenzbänder und gibt Steuerzeichen wörtlich aus („`\n\n`“). Auch hier werden erneut Formatierungsfehler gemacht.

Über alle Szenarien hinweg nehmen die Fehler mit steigender Komplexität zu, und die Modelle trennen sich klar nach Fähigkeit.

6.6 Zusammenfassende Gegenüberstellung

In Abbildung 6.6 sind jeweils die Stärken und Schwächen jedes Modells im direkten Vergleich zusammengefasst:

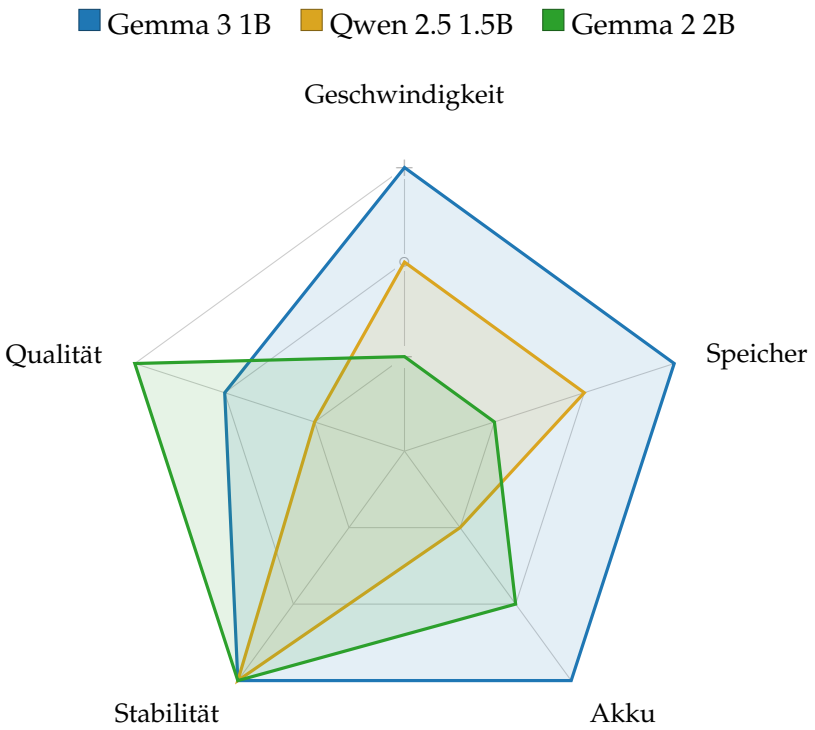


Abbildung 6.6: Netzdiagramm der zusammenfassenden Gegenüberstellung (weiter außen bedeutet besser).

Der Vergleich zeigt, dass kein Modell in allen Bereichen überlegen ist. Während Qwen 2.5 1.5B am schwächsten ausfällt, besitzen die Gemma-Modelle jeweils unterschiedliche Stärken. Gemma 3 1B ist in den Punkten hohe Effizienz sowie wenig Speicher- und Akkuverbrauch Vorreiter, bei der Qualität liegt es jedoch hinter Gemma 2 2B zurück. Letzteres liefert die höchste Ausgabequalität, verbraucht aber mehr Ressourcen und ist langsamer.

Interessant wird es bei der Frage, ob oder welches Modell sich für den praktischen Einsatz eignet und inwiefern, was nachfolgend in Kapitel 7 besprochen wird.

7 Diskussion

In diesem Kapitel werden die Ergebnisse der Evaluation eingeordnet und gedeutet. Anschließend werden die Einschränkungen der Arbeit diskutiert und Handlungsempfehlungen für den praktischen Einsatz lokaler Sprachmodelle in mobilen BCI-Anwendungen abgeleitet.

7.1 Einordnung der Ergebnisse

Die beiden Gemma-Modelle unterscheiden sich in ihren Stärken. Gemma 3 1B ist aufgrund seiner geringen Größe am effizientesten und hat den geringsten Speicher- und Akkubedarf sowie die höchste Geschwindigkeit. Die Parameterzahl beeinflusst dabei den Speicher- und Rechenaufwand je Token (Abschnitt 2.4.2). Innerhalb der Gemma-Familie zeigt sich das größere Gemma 2 2B als das Modell mit der höchsten Ausgabequalität.

Qwen 2.5 1.5B zeigt jedoch, dass die Größe allein die Qualität nicht bestimmt: Obwohl es sich von der Parameterzahl her in der Mitte der drei Modelle einordnet, liefert es die schlechtesten Ausgaben. Die technischen Bedingungen waren für alle Modelle gleich (Kapitel 4). Qwen 2.5 1.5B hat die höchste Inferenzdauer und verbraucht am meisten Akku, obwohl es kleiner als Gemma 2 2B ist. Das Modell pendelt sich aber bei dem Rest, bis auf die Ladezeit im Artefakt- und Vergleichsszenario, bei der es mit 0,27 s am schnellsten ist, in der Mitte ein. Der Grund für die lange Inferenzdauer liegt in der Länge der Antworten. Ein Zusammenhang ist zu erkennen: Je mehr Text ein Modell erzeugt, desto länger dauert die Berechnung und desto mehr Energie verbraucht sie. Qwen zeigt in den Messungen eine klar erhöhte Ausgabe an Tokens (vgl. Tabelle B.1). Diese Ausführlichkeit ist zugleich ein Qualitätsproblem, denn Qwen hält sich schlecht an die Vorgaben: Trotz der klaren Formatvorgaben im Prompt fällt die Antwort zu lang aus. Die Ausgabe ist so nicht nur inhaltlich am schwächsten, sondern kostet auch am meisten Zeit und Energie. Beides tritt bei Qwen gemeinsam auf, möglicherweise durch das Nichteinhalten der Längenvorgaben oder eine ungeeignete Promptwahl. Ein fester Zusammenhang lässt sich jedoch aus den Messungen nicht ableiten.

Mögliche Gründe für das schlechte Einhalten der Vorgaben bei Qwen lassen sich aus den Messungen allein nicht klären. Das Kontextfenster ist ausgeschlossen, da selbst im Vergleichsszenario mit 770 Eingabe- und 474 Ausgabe-Tokens die Grenze von 1280 Tokens nicht erreicht wird (Tabelle B.1). Die Quantisierung spielt auch kaum eine Rolle, da alle Modelle mit 8 Bit ausgeführt werden. Wahrscheinlich liegt es an der Feinjustierung des Prompts, die speziell an das Modell Gemma 2 2B angepasst wurde (Abschnitt 7.2). Denkbar ist zudem, dass sich die Modelle darin unterscheiden, wie strikt sie Längen- und Formatvorgaben umsetzen.

Zu erwähnen ist, dass Qwen 2.5 1.5B einen größeren Nachteil hat als die Gemma-Modelle. Gemma 3 1B kommt aus derselben Modellfamilie wie der Vorgänger und hat dadurch wahrscheinlich einen größeren Mehrwert durch die Prompt-Feinjustierung des Vorgängers. Qwen kommt von einem anderen Hersteller mit einer eigenen Architektur und

einem eigenen Tokenizer (Abschnitt 3.3), wodurch eine negative Beeinflussung nicht ausgeschlossen ist. Die schwächeren Ergebnisse von Qwen sind daher nicht allein als geringere Fähigkeit zu lesen, sondern zum Teil als Folge eines Prompts, der nicht auf dieses Modell abgestimmt ist.

Die TTFT ist im Vergleichsszenario bei allen drei Modellen deutlich länger als bei Report und Artefakt-Erklärung. Das liegt an der längeren Prompteingabe, bei der gleich zwei Merkmalstexte (einer je Session) verarbeitet werden. Je mehr Text gelesen wird, desto länger dauert es, bis die Antwort generiert wird. Dies bestätigt sich in den Eingabe-Tokenzahlen (Tabelle 6.2), die im Vergleichsszenario am größten ausfallen. Qwen zeigt eine erhöhte Zerlegung des Prompts, bei der die meisten Tokens entstehen. Da es gegenüber Gemma 3 1B nur wenige Prozent (4 bis 8) mehr sind, lässt sich die klar erhöhte TTFT nicht mit diesem Unterschied begründen. Gemma 2 2B erreicht mit nahezu gleich vielen Eingabe-Tokens wie Gemma 3 1B sogar die höchste TTFT. Dieser Unterschied zwischen den Modellen in der Zerlegung kann durch das kleinere Vokabular (Abschnitt 4.4.2) entstehen, ebenso können die abweichenden Zerlegungsverfahren oder die Struktur des Prompts die Ursache sein. Welcher dieser Einflüsse überwiegt, bleibt offen, da es aus den Daten nicht sicher abgeleitet werden kann.

Die Tokens pro Sekunde werden direkt von der längeren Vorlaufzeit beeinflusst. Die Metrik ergibt sich aus den erzeugten Tokens geteilt durch die gesamte Inferenzdauer (Abschnitt 4.4.1), bei der die TTFT einen großen Anteil ausmachen kann. So entfallen im Vergleichsszenario bei Gemma 3 1B rund 59 Prozent und bei Gemma 2 2B rund 61 Prozent der Inferenzdauer auf die Phase vor dem ersten Token, im Report-Szenario sind es 29 beziehungsweise 43 Prozent. Da bei Qwen 2.5 1.5B der Anteil aufgrund der längeren Ausgaben bei nur 33 Prozent liegt, fällt dort auch der Durchsatz am wenigsten ab (Tabelle 6.1). Rechnet man die Vorlaufzeit heraus, bleibt die reine Erzeugungsrate weitgehend gleich, bei Gemma 3 1B 30,5 gegenüber 29,0 und bei Qwen 2.5 1.5B 16,7 gegenüber 16,9 Tokens pro Sekunde. Nur bei Gemma 2 2B sinkt sie von 8,8 auf 7,4. Der Einbruch beschreibt damit weniger eine langsamere Erzeugung als die wachsende Bedeutung der Eingabeverarbeitung.

Durch den Verbrauch in PSS kann man den von der Anwendung benutzten RAM ins Verhältnis zum gesamten RAM von 8 GB setzen. Gemma 2 2B belegt mit ca. 3,7 GB rund 45 Prozent der verfügbaren 8 GB, Gemma 3 1B mit ca. 1,5 GB rund 18 Prozent und Qwen 2.5 1.5B mit ca. 2,0 GB rund 24 Prozent. Bei dem 2B-Modell wären es auf einem Gerät mit 4 GB Arbeitsspeicher ca. 90 Prozent und damit an der Grenze. Da der PSS-Wert eine obere Schranke darstellt (Abschnitt 4.4.1), sind dies Höchstwerte. Zu beachten ist, dass einer Anwendung nie der gesamte Arbeitsspeicher netto zur Verfügung steht, da das System den Speicher unter Systemprozessen und Anwendungen aufteilt und bei Knappheit Prozesse beendet [18]. Daraus lässt sich ableiten, dass 4 GB für das 2B-Modell sehr wahrscheinlich zu klein wären. Wahrscheinlich sind 6 GB oder 8 GB das Mindestmaß, das für das 2B-Modell benötigt wird. Geräte mit mehr RAM können je nach Kompatibilität, Hardware und Android-Version größere Modelle verwenden.

Die Ergebnisse zeigen somit, dass sich von der Modellgröße nicht unmittelbar auf die Ausgabequalität schließen lässt. Verschiedene Hersteller unterscheiden sich in Aufbau und Training der Modelle [10, 35], sodass die Größe als Anhaltspunkt nicht verlässlich genug ist. Bei der Stabilität unterscheiden sich die Modelle hingegen nicht. Alle Kombinationen laufen fehlerfrei durch. Nur Qwen 2.5 1.5B weist einen erhöhten Streuungswert im

Vergleichsszenario auf, was mit seiner langen Laufzeit unter Dauerlast zusammenhängen kann. Für die Forschungsfrage ist das Wichtigste, dass die Modelle einwandfrei und stabil ihre Aufgaben erfüllen und einen Mehrwert bieten. Solange die Latenz in einem vertretbaren Rahmen liegt (bei den vorliegenden Modellen ist das wahrscheinlich der Fall), ist die Ausgabequalität das wichtigste Kriterium.

7.2 Einschränkungen

Während der gesamten Arbeit gibt es Einschränkungen, die die Ergebnisse beeinflussen können. Dazu gehören unter anderem Limitierungen durch Hardware, Designentscheidungen oder Entscheidungen bezogen auf die Messungen. Die Arbeit basiert auf nur einem Testgerät, dem Samsung Galaxy S23. Es ist nicht sicher, wie die Evaluation auf anderen Hardwarekonfigurationen ausfallen würde. Das Testgerät schränkt zudem die Auswahl der Modelle ein. Aufgrund seiner begrenzten Unterstützung ist es nicht möglich, systemintegrierte Modelle wie Gemini Nano einzubeziehen [20]. Zwar unterstützt das Testgerät Galaxy AI, dabei handelt es sich jedoch um vordefinierte Endnutzerfunktionen [37] und nicht um eine Schnittstelle, über die eigene Prompts an ein Sprachmodell übergeben werden könnten. Für den hier untersuchten Anwendungsfall ist es deshalb nicht einsetzbar. Auch bei den frei deploybaren Modellen ist die Auswahl begrenzt. Durch die selbst getroffene Wahl von MediaPipe als Laufzeitumgebung entfallen viele neuere Modelle, da die Schnittstelle nur eine begrenzte Auswahl unterstützt [17] oder die Modelle für mobile Geräte gar nicht optimiert sind [44]. Zudem wird für einen technisch einheitlichen Vergleich darauf geachtet, dass alle mit einer Kontextgröße von 1280, einer 8-Bit-Quantisierung und dem .task-Format laufen, was zur Folge hat, dass noch mehr Modelle ausgeschlossen werden.

Die gesamte Promptfeinjustierung basiert auf dem Modell Gemma 2 2B, wodurch das Setup auf dieses Modell zugeschnitten ist. Davon betroffen ist sehr wahrscheinlich die Ausgabequalität sowie aufgrund der Länge der Ausgabe die Inferenzdauer und der Akkuverbrauch. Da die betroffenen Werte als Ergebnis unter günstigen Bedingungen entstanden sind, stellt sich die Frage, ob Gemma 2 2B in den Vergleich gezogen werden soll. Da Ladezeit, TTFT, Durchsatz und Speicherbedarf davon unberührt bleiben, wird das Modell im Vergleich belassen. Die betroffenen Werte sind jedoch entsprechend einzuordnen. Der Zuschnitt wirkt zudem nicht nur auf Gemma 2 2B. Da Gemma 3 1B derselben Modellfamilie angehört, dürfte es von der Feinjustierung teilweise mitprofitieren, während Qwen 2.5 1.5B als Modell eines anderen Herstellers keinen solchen Vorteil hat.

Beim Messaufbau ist die Reihenfolge der Messungen bewusst festgelegt (Abschnitt 4.4). Trotz einer Abkühlphase lässt sich nicht ausschließen, dass die zuletzt gemessenen Modelle durch das wärmere Gerät leicht benachteiligt werden (Abschnitt 2.4.2). Dasselbe gilt für den Ladezustand, der über die Messreihe hinweg sinkt. Der verbleibende Einfluss bleibt offen. Alle Messungen erfolgen zudem in deutscher Sprache, daher bleibt es offen, wie sich die Ausgabequalität und Tokenanzahl in englischer Sprache verhalten. Schließlich sind die drei Szenarien in ihrer Aufgabenart identisch, nämlich in der textuellen Beschreibung von EEG-Sessions (Abschnitt 4.3). Der Unterschied liegt im Anspruch und nicht in der Art der Aufgabe. Daher bleibt es offen, wie die Modelle bei anderen Aufgaben wie der Klassifikation abschneiden würden.

Wie in Abschnitt 4.1.4 beschrieben, wächst der Aufwand der Merkmalsextraktion linear mit der Länge der Session. Die Inferenzdauer ist davon nicht beeinflusst, da unabhängig

von der Länge immer vier Segmente entstehen. Bei längeren Sessions von vielen Minuten könnte sich ihr Einfluss deutlich erhöhen und die Extraktion stärker ins Gewicht fallen.

7.3 Handlungsempfehlungen

In diesem Abschnitt werden Handlungen auf Basis der Erkenntnisse dieser Arbeit empfohlen. Diese leiten sich aus den Ergebnissen der Evaluation und aus der Umsetzung ab. Die folgenden Empfehlungen gelten für den in dieser Arbeit untersuchten Rahmen, also für die beschriebene Implementierung mit der in Abschnitt 5.4 festgelegten Prompt-Struktur und der gewählten Konfiguration, für die drei Anwendungsszenarien aus Abschnitt 4.3 und für das Testgerät aus Abschnitt 4.4.2. Auf andere Geräte, Prompts oder Aufgaben lassen sie sich nicht ohne Weiteres übertragen.

7.3.1 Allgemeine Empfehlungen

Die Prompts sollten im besten Fall kurz und klar gehalten werden, damit sie in den Kontext passen. Die Länge beeinflusst ebenso die Zeit bis zum ersten Token (Abschnitt 7.1). Das Modell sollte die Merkmale in einer klar verständlichen Form erhalten, ohne selbst überfordert zu sein, also keine Rohdaten, sondern aggregierte Merkmale. Darüber hinaus sollte man je nach Szenario das passende Modell auswählen, da die Ausgabequalität je nach Komplexität der Aufgabe variiert. Da die Modelle jeweils 1,5 GB, 2,0 GB und 3,7 GB im Arbeitsspeicher belegen (Tabelle 6.3), sollten sie erst nach der Prüfung der Eingabe geladen werden. Nach der Ausgabe können sie schließlich wieder freigegeben werden. Die Inferenz der Modelle sollte auf einen Hintergrund-Thread verlagert werden, da eine Anfrage bis zu 42 s dauern kann und die Oberfläche einfrieren würde (Tabelle 6.1). Das Modell selbst sollte hinter einer eigenen Schnittstelle gekapselt werden. In dieser Arbeit ließen sich die drei Modelle allein über den Modellpfad austauschen (Abschnitt 5.1), sodass ein Wechsel des Modells oder der Laufzeitumgebung die übrige Anwendung nicht betrifft. Für die Benutzerfreundlichkeit ist es auch sinnvoll, eine wie hier verwendete Streaming-Mechanik einzubinden, um die gefühlte Wartezeit zu verringern. Dabei sollte bei der Ausgabe das Format nach Bedarf angepasst werden. Bei Qwen 2.5 1.5B ist es beispielsweise sinnvoll, die Antwort zu kürzen und formatierungstechnisch zu vereinfachen. Selbst das größte Modell Gemma 2 2B hat keine fehlerfreien Ausgaben geliefert, weshalb man sich in Bereichen wie der Medizin nicht allein auf solche Modelle im Rahmen dieser Arbeit verlassen sollte.

7.3.2 Modellempfehlung

Wenn der Fokus auf der Qualität liegen soll, geht die Empfehlung an das Modell Gemma 2 2B. Es hält sich am besten an die Vorgaben und bietet die beste Ausgabequalität. Dafür verbraucht es am meisten Speicher und ist am langsamsten, mit einer geringen Token-Rate und der längsten TTFT. Aufgrund des Speicherbedarfs von ca. 3,7 GB für den gesamten Prozess der Anwendung empfiehlt es sich, ein Gerät mit mindestens 6 bis 8 GB Arbeitsspeicher zu nutzen (Abschnitt 7.1). Mit Betriebssystem, einem Puffer und möglicherweise weiteren Anwendungen kann der Speicherbedarf ansteigen.

Wer hingegen auf Geschwindigkeit, Speicher- und Akkuverbrauch setzen möchte, ist mit dem kleinsten Modell Gemma 3 1B am besten aufgehoben. Es ist für Geräte mit wenig Arbeitsspeicher die beste Wahl, da das Modell in diesem Punkt die geringsten Anforderungen stellt.

Qwen 2.5 1.5B ist in diesem Rahmen nicht zu empfehlen. Es schneidet in puncto Qualität und Akkuverbrauch trotz seiner Größe am schlechtesten ab. Die Geschwindigkeit und der Speicherbedarf pendeln sich, mit Ausnahme der Inferenzdauer, wie erwartet in der Mitte ein, können jedoch nicht die mangelnde Ausgabequalität rechtfertigen. Dabei ist zu berücksichtigen, dass der Prompt an Gemma 2 2B ausgerichtet wurde und Qwen dadurch benachteiligt ist (Abschnitt 7.2).

Je nach Einsatzzweck haben die beiden Gemma-Modelle in dieser Untersuchung Vorteile. Für schnelle Antworten mit einer geringen TTFT sowie einer niedrigen Inferenzdauer liegt Gemma 3 1B vorne. Wenn hingegen Qualität wichtig und Zeit gegeben ist, beispielsweise als Hintergrundprozess ohne nötige sofortige Rückmeldung, ist Gemma 2 2B die beste Wahl.

8 Fazit und Ausblick

Abschließend werden die Ergebnisse dieser Arbeit zusammengefasst. Darüber hinaus wird die Forschungsfrage zur Eignung lokaler Sprachmodelle für mobile BCI-Anwendungen beantwortet und daraufhin ein Ausblick auf mögliche Weiterentwicklungen oder bessere Ansätze in zukünftigen Arbeiten gegeben.

8.1 Fazit

Die bestehende EEG-Anwendung wurde um neue Funktionalitäten erweitert, darunter die Merkmalsextraktion, die Anbindung lokaler Sprachmodelle, ein Benchmark und neue Benutzeroberflächen.

Die Forschungsfrage, inwieweit sich lokal auf Android-Geräten ausgeführte Sprachmodelle für die Verarbeitung von EEG-Daten im Rahmen mobiler Brain-Computer-Interface-Anwendungen eignen, kann weder mit einem klaren Ja noch mit einem Nein beantwortet werden. Rein von der technischen Eignung ist alles gegeben. Alle drei Modelle ließen sich problemlos, speicherfehlerfrei und absturzfrei auf dem Testgerät ausführen. In jeder der 45 Messungen wurde ein Ergebnis geliefert. Die Inferenzdauer betrug maximal 42 Sekunden und lag damit in einem wahrscheinlich vertretbaren Bereich für Nutzer.

Jedoch fällt die Antwort inhaltlich enger aus. Nur Gemma 2 2B konnte alle vier Bewertungskriterien erfüllen, und das auch nur im einfachsten Szenario. Mit steigendem Niveau nahmen die Fehler zu. Zu beachten ist auch, dass der Prompt auf Gemma 2 2B abgestimmt wurde, was seinen besseren Ergebnissen entgegenkommt. Lokale Sprachmodelle eignen sich damit als unterstützende Funktion, die die Messwerte in verständliche Sprache übersetzen kann. Für eine eigenständige Deutung, die ohne Prüfung durch den Nutzer verlaufen kann, reichen die verwendeten Modelle nicht aus.

Die Metriken TTFT, Durchsatz und Speicherbedarf folgen im Rahmen dieser Arbeit der Modellgröße, Ausgabequalität und Akkuverbrauch nicht. Kein Modell ist in allen Bereichen überlegen. Daher ist der richtige Einsatzzweck entscheidend.

Die im Folgenden genannten Empfehlungen sind im Rahmen dieser Implementierung, mit der genannten Struktur des Prompts und der gewählten Konfiguration sowie im Gebiet, bei dem es um die Auswertung von EEG-Sessions auf dem verwendeten Testgerät geht, zu verstehen. Das 2B-Modell von Gemma ist die beste Wahl, wenn Zeit und Ressourcen zweitrangig sind und die Qualität im Vordergrund stehen soll. Es kann unter anderem als Hintergrundprozess verwendet werden. Das 1B-Modell von Gemma ist für schnelle Antworten auf ressourcenärmeren Geräten die beste Wahl. Es empfiehlt sich für Fälle, bei denen der Nutzer eine sofortige Rückmeldung benötigt.

8.2 Ausblick

Die Antwort auf die Forschungsfrage gilt für einen festen Rahmen: ein Testgerät, drei frei deploybare Modelle unter einer Laufzeitumgebung mit fester Konfiguration und eine Aufgabenart. Die folgenden Punkte geben Optionen an, an welchen Stellen in diesem Rahmen die Erweiterung erfolgen müsste, um eine vollständige Antwort auf die Frage geben zu können.

- **Andere Hardwareklassen:** Die Antwort wurde mithilfe eines Geräts der Leistungsklasse des Samsung Galaxy S23 gegeben (Abschnitt 4.4.2). Es ist nicht sicher, wie andere Chipsätze oder Hersteller die Ergebnisse beeinflussen würden. Schwächere Hardware kann ein entscheidender Faktor für den verfügbaren Speicher und die Latenz sein. Zu prüfen ist, ab welcher Geräteklasse die Latenzen den nutzbaren Bereich verlassen und ob die in Abschnitt 7.1 abgeschätzte Untergrenze von 6 bis 8 GB für das größte Modell zutrifft.

- **Systemintegrierte Modelle:** Die Antwort deckt nur frei deploybare Modelle ab (Abschnitt 3.1.1). Die Aufgabenstellung sah vor, einen Vergleich zwischen frei deploybaren und systemintegrierten Modellen anzustellen, wobei dies mit dem vorhandenen Testgerät nicht möglich war. Ein Vergleich könnte zeigen, ob ein systemintegriertes Modell wie Gemini Nano bei derselben Aufgabe schneller antwortet und weniger Speicher belegt.

- **Aussagekräftigere Sessions:** Es gab in den verwendeten Sessions keinen vordefinierten mentalen Zustand, anhand dessen die Qualität der Antwort abgeglichen werden konnte (Abschnitt 6.1). Mit einem Zustand wie dem Schlafen oder der Konzentration ließe sich prüfen, ob die Ausgaben inhaltlich zutreffend sind.

- **Andere Merkmalsdarstellung:** Es wurde mit einer festen Darstellung gearbeitet, also einer Segmentanzahl von vier und einer Fenstergröße von 256 (Abschnitt 4.1.1). Es ist offen, wie andere Werte das Ergebnis beeinflussen könnten. Mit anderen Werten lässt sich prüfen, ob mehr Segmente die Ausgabequalität verbessern oder nur die Eingabe verlängern.

- **Neuere Modelle und Laufzeitumgebungen:** Die Antwort ist an MediaPipe und die dort verfügbaren Modelle gebunden (Abschnitt 3.1.2). Da sich MediaPipe in einem Wartungsmodus befindet [17], würde eine Wiederholung mit einer aktuellen Laufzeitumgebung wie LiteRT-LM zeigen, ob die beobachteten Grenzen an den Modellen oder an der Laufzeitumgebung liegen.

- **Andere Aufgabenarten:** Die Antwort ergibt sich aus der textuellen Beschreibung einer Session (Abschnitt 4.3). Ob sich das Ergebnis auf andere Aufgaben wie die Klassifikation übertragen lässt, ist aus den Messungen nicht ableitbar. Sobald Vergleichswerte vorliegen, kann untersucht werden, ob die Modelle eine Session anhand fester Vorgaben einordnen können.

- **Andere Konfiguration:** Die Ergebnisse sind für eine feste Konfiguration mit 8-Bit-Quantisierung, einem Top-K-Wert von 40 und einer Kontextgröße von 1280 Token (Abschnitt 4.2) zu betrachten. Weitere Parameter wie die Temperatur oder ein Zufallsstartwert wurden nicht verändert (Abschnitt 3.1.2). Man kann prüfen, ob das Verändern dieser Werte die Ergebnisse beeinflusst.

- **Anpassung der Modelle:** Alle Modelle wurden unverändert übernommen, ihre Gewichte wurden also nicht nachtrainiert. Das Training war nicht Teil der Aufgabenstellung, die verwendete Schnittstelle erlaubt jedoch das Einbinden eines LoRA-Modells [17]. So könnte man zeigen, ob ein für EEG-Merkmale angepasstes Modell die Ausgabequalität verbessert.
- **Absicherung der Rangfolge:** Die Messreihenfolge ist fest definiert worden (Abschnitt 4.4). Zu klären ist, ob der verbleibende Wärmeeffekt und der sinkende Ladezustand die Rangfolge der Modelle beeinflussen. Dafür müsste die Reihenfolge randomisiert werden.
- **Neutraler Prompt:** Der Prompt wurde an Gemma 2 2B ausgerichtet (Abschnitt 7.2). Es wäre sinnvoll zu prüfen, wie sich die Rangfolge der Modelle ändert, wenn jedes Modell einen eigens angepassten Prompt erhält oder man ein Referenzmodell wählt, das nicht in die Evaluation einbezogen wird.

Lokale Sprachmodelle bieten im mobilen BCI-Bereich Ansatzpunkte für weiterführende Arbeiten. Sie können den Einstieg erleichtern, indem die aufbereiteten Merkmale in eine verständliche Sprache gebracht werden, wie zum Beispiel im Lehrkontext, in dem das Gerät eingesetzt wird. Die Verarbeitung läuft dabei offline, ohne dass die Daten das Gerät verlassen. Die Deutung selbst bleibt aufseiten des Nutzers.

Literatur

[1] Nisreen Said Amer und Samir Brahim Belhaouari. „EEG Signal Processing for Medical Diagnosis, Healthcare, and Monitoring: A Comprehensive Review“. In: *IEEE Access* 11 (2023), S. 143116–143142. DOI: 10.1109/ACCESS.2023.3341419.

[2] Android Headlines. *One UI 8.5 Update Reaches Galaxy S23 Series Globally*. 2026. URL: https://www.androidheadlines.com/2026/05/one-ui-8-5-update-reaches-galaxy-s23-series-globally-whats-new.html (besucht am 19. 07. 2026).

[3] Naseem Babu, Jimson Mathew und A. P. Vinod. *Large Language Models for EEG: A Comprehensive Survey and Taxonomy*. Techn. Ber. arXiv, 2025. URL: https://arxiv.org/abs/2506.06353.

[4] Sarah Blum, Stefan Debener, Reiner Emkes, Nils Volkening, Sebastian Fudickar und Martin G. Bleichner. „EEG Recording and Online Signal Processing on Android: A Multiapp Framework for Brain-Computer Interfaces on Smartphone“. In: *BioMed Research International* 2017 (2017), S. 3072870. DOI: 10.1155/2017/3072870.

[5] DeepSeek-AI. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. Techn. Ber. DeepSeek, 2025. URL: https://arxiv.org/abs/2501.12948.

[6] g.tec medical engineering. *Unicorn Android API*. URL: https://github.com/unicorn-bi/UnicornAndroidAPI (besucht am 02. 07. 2026).

[7] g.tec medical engineering. *Unicorn Bluetooth Protocol*. URL: https://github.com/unicorn-bi/Unicorn-Suite-Hybrid-Black/blob/master/Unicorn%20Bluetooth%20Protocol/UnicornBluetoothProtocol.pdf (besucht am 02. 07. 2026).

[8] g.tec medical engineering. *Unicorn Hybrid Black – User Manual*. URL: https://github.com/unicorn-bi/Unicorn-Suite-Hybrid-Black-User-Manual/blob/main/UnicornHybridBlack.md (besucht am 02. 07. 2026).

[9] g.tec medical engineering. *Unicorn Hybrid Black BCI Platform*. URL: https://www.gtec.at/product/unicorn-hybrid-black-bci-platform/ (besucht am 02. 07. 2026).

[10] Gemma Team. *Gemma 2: Improving Open Language Models at a Practical Size*. Techn. Ber. Google DeepMind, 2024. URL: https://arxiv.org/abs/2408.00118.

[11] Gemma Team. *Gemma 3 Technical Report*. Techn. Ber. Google DeepMind, 2025. URL: https://arxiv.org/abs/2503.19786.

[12] Gemma Team. *Gemma 4 – Model Card*. Techn. Ber. Google DeepMind, 2026. URL: https://ai.google.dev/gemma/docs/core/model_card_4?hl=de.

[13] Google. *BatteryManager – Android API reference*. 2024. URL: https://developer.android.com/reference/android/os/BatteryManager (besucht am 12. 07. 2026).

[14] Google. *Dialogs*. 2025. URL: https://developer.android.com/develop/ui/views/components/dialogs (besucht am 19. 09. 2026).

[15] Google. *Gemini Nano*. 2024. URL: https://developer.android.com/ai/gemini-nano (besucht am 24. 06. 2026).

[16] Google. *Introduction to activities*. 2025. URL: https://developer.android.com/guide/components/activities/intro-activities (besucht am 19. 09. 2026).

[17] Google. *LLM Inference Guide – MediaPipe*. 2024. URL: https://developers.google.com/edge/mediapipe/solutions/genai/llm_inference (besucht am 24. 06. 2026).

[18] Google. *Memory allocation among processes*. 2024. URL: https://developer.android.com/topic/performance/memory-management (besucht am 12. 07. 2026).

[19] Google. *OutOfMemoryError – Android API reference*. 2024. URL: https://developer.android.com/reference/java/lang/OutOfMemoryError (besucht am 20. 07. 2026).

[20] Google. *Overview of the ML Kit GenAI APIs*. 2025. URL: https://developers.google.com/ml-kit/genai (besucht am 09. 07. 2026).

[21] Qingzhe Guo, Tu Ouyang und An Wang. „Large Language Models on Mobile Devices: A Measurement Study of Single- and Multi-Instance Execution“. In: *Proceedings of the 2nd International Workshop on Edge and Mobile Foundation Models (EdgeFM '25)*. Hong Kong, China: ACM, 2025, S. 43–48. DOI: 10.1145/3737902.3768359.

[22] IBM. *Was ist ein Kontextfenster?* 2024. URL: https://www.ibm.com/de-de/think/topics/context-window (besucht am 12. 07. 2026).

[23] Mainak Jas, Denis A. Engemann, Yousra Bekhti, Federico Raimondo und Alexandre Gramfort. „Autoreject: Automated artifact rejection for MEG and EEG data“. In: *NeuroImage* 159 (2017), S. 417–429. DOI: 10.1016/j.neuroimage.2017.06.030.

[24] Dah-Jing Jwo, Wei-Yeh Chang und I-Hua Wu. „Windowing Techniques, the Welch Method for Improvement of Power Spectrum Estimation“. In: *Computers, Materials & Continua* 67.3 (2021), S. 3983–4003. DOI: 10.32604/cmc.2021.014752.

[25] Nick Kane, Jayant Acharya, Sandor Beniczky, Luis Caboclo, Simon Finnigan, Peter W. Kaplan, Hiroshi Shibasaki, Ronit Pressler und Michel J. A. M. van Putten. „A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the EEG findings. Revision 2017“. In: *Clinical Neurophysiology Practice* 2 (2017), S. 170–185. DOI: 10.1016/j.cnp.2017.07.002.

[26] Nick Kane, Jayant Acharya, Sandor Beniczky, Luis Caboclo, Simon Finnigan, Peter W. Kaplan, Hiroshi Shibasaki, Ronit Pressler und Michel J. A. M. van Putten. „Corrigendum to: A revised glossary of terms most commonly used by clinical electroencephalographers and updated proposal for the report format of the EEG findings. Revision 2017“. In: *Clinical Neurophysiology Practice* 4 (2019), S. 133. DOI: 10.1016/j.cnp.2019.06.001.

[27] Jonathan W. Kim, Ahmed Alaa und Danilo Bernardo. *EEG-GPT: Exploring Capabilities of Large Language Models for EEG Classification and Interpretation*. Techn. Ber. arXiv, 2024. URL: https://arxiv.org/abs/2401.18006.

[28] Thomas Kuttner. *Praxiswissen Schwingungsmesstechnik*. 1. Aufl. Wiesbaden: Springer Vieweg, 2015. ISBN: 978-3-658-04637-8. DOI: 10.1007/978-3-658-04638-5.

[29] LiteRT Community. *Gemma2-2B-IT (LiteRT)*. 2025. URL: https://huggingface.co/litert-community/Gemma2-2B-IT (besucht am 22. 08. 2026).

[30] LiteRT Community. *Gemma3-1B-IT (LiteRT)*. 2025. URL: https://huggingface.co/litert-community/Gemma3-1B-IT (besucht am 22. 08. 2026).

[31] LiteRT Community. *Qwen2.5-1.5B-Instruct (LiteRT)*. 2025. URL: https://huggingface.co/litert-community/Qwen2.5-1.5B-Instruct (besucht am 16. 07. 2026).

[32] Llama Team. *The Llama 3 Herd of Models*. Techn. Ber. Meta AI, 2024. URL: https://arxiv.org/abs/2407.21783.

[33] Akshaj Murhekar, Christina Liu, Abhijit Mishra, Shounak Roychowdhury und Jacek Gwizdka. „SENSE: Efficient EEG-to-Text via Privacy-Preserving Semantic Retrieval“. In: *Proceedings of the ACM International Conference on Multimodal Interaction (ICMI)*. 2026. URL: https://arxiv.org/abs/2603.17109.

[34] Aleksandar Petrov, Emanuele La Malfa, Philip H. S. Torr und Adel Bibi. „Language Model Tokenizers Introduce Unfairness Between Languages“. In: *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. 2023. URL: https://proceedings.neurips.cc/paper_files/paper/2023/file/74bb24dca8334adce292883b4b651eda-Paper-Conference.pdf.

[35] Qwen Team. *Qwen2.5 Technical Report*. Techn. Ber. Alibaba Group, 2024. URL: https://arxiv.org/abs/2412.15115.

[36] Qwen Team. *Qwen3 Technical Report*. Techn. Ber. Alibaba Group, 2025. URL: https://arxiv.org/abs/2505.09388.

[37] Samsung Electronics. *Galaxy AI – Funktionen*. 2024. URL: https://www.samsung.com/de/support/mobile-devices/galaxy-ai-funktionen/ (besucht am 12. 08. 2026).

[38] Samsung Electronics. *Galaxy S23 – Technische Daten*. 2023. URL: https://www.samsungmobilepress.com/media-assets/galaxy-s23?tab=specs (besucht am 19. 07. 2026).

[39] Steven W. Smith. *The Scientist and Engineer's Guide to Digital Signal Processing*. San Diego, CA: California Technical Publishing, 1997. ISBN: 978-0966017632. URL: https://www.dspguide.com/.

[40] Ashish Vaswani, Noam Shazeer, Niki Parmar u. a. „Attention Is All You Need“. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017.

[41] Xin Wang, Ting Dang, Xinyu Zhang, Vassilis Kostakos, Michael Witbrock und Hong Jia. *HealthSLM-Bench: Benchmarking Small Language Models for Mobile and Wearable Healthcare Monitoring*. Techn. Ber. arXiv, 2025. URL: https://arxiv.org/abs/2509.07260.

[42] Piotr Wendykier. *JTransforms*. URL: https://github.com/wendykierp/jtransforms (besucht am 02. 07. 2026).

[43] Jonathan R. Wolpaw. „Brain–computer interfaces“. In: *Neurological Rehabilitation*. Hrsg. von Michael P. Barnes und David C. Good. Bd. 110. Handbook of Clinical Neurology. Elsevier, 2013, S. 67–74.

[44] Yue Zheng, Yuhao Chen, Bin Qian, Xiufang Shi, Yuanchao Shu und Jiming Chen. „A Review on Edge Large Language Models: Design, Execution, and Applications“. In: *ACM Computing Surveys* 57.8 (2025). DOI: 10.1145/3719664.

[45] Yang Zhou, Feng Liang, Ting-wu Chin und Diana Marculescu. „Play It Cool: Dynamic Shifting Prevents Thermal Throttling“. In: *DyNN Workshop at the 39th International Conference on Machine Learning (ICML)*. Baltimore, MD, USA, 2022. URL: https://arxiv.org/abs/2206.10849.

Abbildungsverzeichnis

2.1 Zeit- und Frequenzbereich 4

3.1 Verwendete Sprachmodelle 10
3.2 Komponenten des verwendeten EEG-Geräts g.tec Unicorn Hybrid Black (eigene Beschriftung, erstellt mit draw.io) [9]. 11

4.1 Datenfluss der Merkmalsextraktion 15
4.2 Segmentierung einer Session 16
4.3 Zerlegung eines Segments in überlappende, mit einer Hann-Funktion gewichtete Analysefenster (50 % Überlappung) für die Welch-Methode (erstellt mit draw.io). 17

5.1 Architektur der Anwendung 25
5.2 Sequenzdiagramm der Analyse 27
5.3 Beispiel eines Feature-Texts 34
5.4 Session-Detailansicht 38
5.5 Analyse-Dialog 39
5.6 Ergebnis-Ansicht 41
5.7 Benchmark-Dialog 42
5.8 Sequenzdiagramm des Benchmarks 43

6.1 Latenzmetriken je Modell und Szenario (Fehlerbalken: Standardabweichung aus vier Wiederholungen; Ladezeit ohne Fehlerbalken, da je Konfiguration einmalig gemessen). 48
6.2 Ressourcenverbrauch je Modell (RAM/PSS mit Fehlerbalken als Standardabweichung; Akku als Näherungswert über den gesamten Messblock von 15 Läufen, daher ein Wert je Modell). 50
6.3 Ausgabe von Gemma 2 2B 51
6.4 Ausgabe von Gemma 3 1B 51
6.5 Ausgabe von Qwen 2.5 1.5B 51
6.6 Netzdiagramm der zusammenfassenden Gegenüberstellung (weiter außen bedeutet besser). 52

A.1 Feature-Text der Session A 73
A.2 Feature-Text der Session B 73

Tabellenverzeichnis

2.1 EEG-Frequenzbänder 4

3.1 Aufbau eines Samples 12

3.2 Einordnung gegenüber verwandten Arbeiten 13

4.1 Übersicht der Metriken 21

6.1 Latenzmetriken je Modell und Szenario (Mittel aus vier Wiederholungen ± Standardabweichung; die Ladezeit wird je Konfiguration einmalig gemessen). 47
6.2 Eingabe-Tokens 49
6.3 Ressourcenverbrauch je Modell (RAM als Mittel ± Standardabweichung). 49

B.1 Rohdaten der Messungen 75

Listings

5.1 Zerlegung in Segmente 28
5.2 Band-Power je Kanal 29
5.3 Leistungsspektrum eines Fensters 30
5.4 Zuordnung zu den Bändern 31
5.5 Relative Band-Power 32
5.6 Laden des Modells 35
5.7 Streamende Ausgabe 35
5.8 Prompts je Szenario 37
5.9 Live-Anzeige der Ausgabe 40
5.10 Ablauf des Benchmarks 44
5.11 Wiederholte Messung 45

Abkürzungsverzeichnis

API Programmierschnittstelle
BBPE Byte-Level Byte-Pair Encoding
BCI Brain-Computer-Interface
CPU Hauptprozessor
CSV Comma-Separated Values
EEG Elektroenzephalographie
FFT Fast Fourier Transform
GPU Grafikprozessor
ID Identifikationsnummer
LLM Large Language Model
LoRA Low-Rank Adaptation
OOM Out of Memory
PSS Proportional Set Size
RAM Arbeitsspeicher
SNR Signal-Rausch-Verhältnis
TTFT Zeit bis zum ersten Token

Anhang

A Aufbereitete Feature-Texte der Evaluation

Die folgenden Feature-Texte (Abbildung A.1, Abbildung A.2) wurden vom `FeatureFormatter` aus den beiden Sessions erzeugt und den Modellen als Eingabe übergeben (vgl. Abschnitt 6.5). Sie ermöglichen es, die Modellausgaben gegen die tatsächliche Eingabe zu prüfen.

```
EEG-Session, Dauer 121.432s, 8 Kanäle.

Abschnitt 1 (0.0–30.352s):
    Delta 86%, Theta 4%, Alpha 5%, Beta 3%, Gamma 2%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 4 (4419 µV)

Abschnitt 2 (30.356–60.708s):
    Delta 59%, Theta 16%, Alpha 13%, Beta 7%, Gamma 5%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (3309 µV)

Abschnitt 3 (60.712–91.064s):
    Delta 56%, Theta 18%, Alpha 13%, Beta 7%, Gamma 6%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (2874 µV)

Abschnitt 4 (91.068–121.432s):
    Delta 63%, Theta 11%, Alpha 11%, Beta 8%, Gamma 8%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (2948 µV)
```

Abbildung A.1: Feature-Text der Session A, wie er den Modellen übergeben wurde. Er ist die Grundlage für das Report- und das Artefakt-Szenario.

```
EEG-Session, Dauer 122.128s, 8 Kanäle.

Abschnitt 1 (0.0–30.528s):
    Delta 86%, Theta 5%, Alpha 3%, Beta 4%, Gamma 2%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (5230 µV)

Abschnitt 2 (30.532–61.06s):
    Delta 77%, Theta 9%, Alpha 6%, Beta 5%, Gamma 3%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (4772 µV)

Abschnitt 3 (61.064–91.592s):
    Delta 73%, Theta 10%, Alpha 6%, Beta 7%, Gamma 4%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (3878 µV)

Abschnitt 4 (91.596–122.128s):
    Delta 66%, Theta 15%, Alpha 8%, Beta 6%, Gamma 5%
    Ungültige Messwerte: 0.0% ungültig, größter Ausschlag Kanal 2 (3518 µV)
```

Abbildung A.2: Feature-Text der Session B, wie er den Modellen übergeben wurde. Er wird nur im Vergleichsszenario als zweite Session genutzt.

B Rohdaten der Benchmark-Messungen

In Tabelle B.1 sind alle 45 Messungen vollständig aufgelistet. Diese dienen zur Nachvollziehbarkeit der Evaluation.

Tabelle B.1: Rohdaten aller Benchmark-Durchläufe. `Load` bezeichnet die Ladezeit, `Infer` die Inferenzdauer, die im Haupttext getrennt von der Ladezeit ausgewiesen wird.

Zeit	Modell	Szenario	Prompt (Tok.)	Ausgabe (Tok.)	Load (ms)	Infer (ms)	TTFT (ms)	Tok/s	PSS (MB)	Akku (µAh)	Akku (%)	Status
19:32:07	1b	report	417	145	447	13116	4120	11.06	1854	2234115	59	ok
19:32:14	1b	report	417	145	447	6906	2047	21.00	1489	2234115	59	ok
19:32:21	1b	report	417	145	447	6639	1919	21.84	1527	2234115	59	ok
19:32:27	1b	report	417	145	447	6597	1883	21.98	1424	2234115	59	ok
19:32:34	1b	report	417	145	447	6658	1908	21.78	1488	2234115	59	ok
19:32:47	1b	artefakt	446	290	339	11596	2013	25.01	1502	2211885	59	ok
19:32:58	1b	artefakt	446	290	339	11476	1974	25.27	1503	2211885	59	ok
19:33:10	1b	artefakt	446	290	339	11401	1910	25.44	1503	2197065	58	ok
19:33:21	1b	artefakt	446	290	339	11424	1985	25.39	1504	2197065	58	ok
19:33:33	1b	artefakt	446	290	339	11477	1912	25.27	1523	2197065	58	ok
19:33:45	1b	vergleich	740	117	289	10107	5890	11.58	1568	2178540	58	ok
19:33:54	1b	vergleich	740	117	289	9494	5444	12.32	1633	2178540	58	ok
19:34:05	1b	vergleich	740	117	289	10529	6554	11.11	1635	2178540	58	ok
19:34:15	1b	vergleich	740	117	289	9918	5852	11.80	1628	2163720	58	ok
19:34:24	1b	vergleich	740	117	289	9606	5582	12.18	1562	2163720	58	ok
19:34:42	2b	report	415	72	871	15173	6877	4.75	3500	2148900	57	ok
19:34:56	2b	report	415	72	871	14264	6133	5.05	3497	2148900	57	ok
19:35:10	2b	report	415	72	871	14095	5896	5.11	3757	2137785	57	ok
19:35:26	2b	report	415	72	871	14907	6747	4.83	3757	2137785	57	ok
19:35:40	2b	report	415	72	871	13735	5577	5.24	3753	2126670	57	ok
19:35:58	2b	artefakt	444	88	467	16864	6440	5.22	3494	2126670	57	ok
19:36:17	2b	artefakt	444	88	467	18489	6723	4.76	3494	2111850	56	ok
19:36:35	2b	artefakt	444	88	467	17780	6225	4.95	3494	2111850	56	ok
19:36:55	2b	artefakt	444	88	467	18987	7037	4.63	3755	2100735	56	ok
19:37:14	2b	artefakt	444	88	467	19005	7034	4.63	3810	2089620	56	ok
19:37:43	2b	vergleich	736	78	516	26207	16549	2.98	3606	2078505	55	ok
19:38:10	2b	vergleich	736	78	516	27347	16459	2.85	3605	2067390	55	ok
19:38:38	2b	vergleich	736	78	516	27050	16408	2.88	3864	2059980	55	ok
19:39:05	2b	vergleich	736	78	516	27143	16916	2.87	3861	2059980	55	ok
19:39:33	2b	vergleich	736	78	516	27229	16618	2.86	3861	2048865	55	ok
19:40:11	qwen	report	439	484	729	36294	6744	13.34	1992	2030340	54	ok
19:40:46	qwen	report	439	484	729	34373	5242	14.08	1992	2015520	54	ok

Fortsetzung auf der nächsten Seite

Zeit	Modell	Szenario	Prompt (Tok.)	Ausgabe (Tok.)	Load (ms)	Infer (ms)	TTFT (ms)	Tok/s	PSS (MB)	Akku (µAh)	Akku (%)	Status
19:41:20	qwen	report	439	484	729	34215	5335	14.15	1994	2004405	53	ok
19:41:55	qwen	report	439	484	729	34371	5389	14.08	1995	1993290	53	ok
19:42:29	qwen	report	439	484	729	34775	5487	13.92	1996	1978470	53	ok
19:42:58	qwen	artefakt	482	357	266	27101	5489	13.17	1993	1967355	52	ok
19:43:25	qwen	artefakt	482	357	266	26562	5265	13.44	1993	1952535	52	ok
19:43:52	qwen	artefakt	482	357	266	26847	5493	13.30	1995	1941420	52	ok
19:44:18	qwen	artefakt	482	357	266	26712	5253	13.36	1995	1926600	51	ok
19:44:45	qwen	artefakt	482	357	266	26670	5212	13.39	1994	1915485	51	ok
19:45:27	qwen	vergleich	770	474	272	39502	13959	12.00	2095	1904370	51	ok
19:46:06	qwen	vergleich	770	474	272	39482	13806	12.01	2096	1893255	50	ok
19:46:48	qwen	vergleich	770	474	272	41471	13328	11.43	2096	1863615	50	ok
19:47:32	qwen	vergleich	770	474	272	43520	14214	10.89	2098	1852500	49	ok
19:48:15	qwen	vergleich	770	474	272	43523	14613	10.89	2165	1830270	49	ok

Kolophon

Dieses Dokument wurde mit der LaTeX-Vorlage für Abschlussarbeiten an der htw saar im Bereich Informatik/Mechatronik-Sensortechnik erstellt (Version 2.25, August 2024). Die Vorlage wurde von Yves Hary und André Miede entwickelt (mit freundlicher Unterstützung von Thomas Kretschmer, Helmut G. Folz und Martina Lehser). Daten: (F)10.95 – (B)426.79135pt – (H)688.5567pt